

AI SCIENTIST

FASE 1 | AULA 01 -

COMO RESPONDER PERGUNTAS COM DADOS

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
MERCADO, CASES E TENDÊNCIAS	20
O QUE VOCÊ VIU NESTA AULA?	21
REFERÊNCIAS.....	22

EMANIP

O QUE VEM POR AÍ?

Entraremos em uma nova etapa da nossa jornada: colocar em prática o processo analítico usando Python.

Depois de compreender o papel investigativo da pessoa cientista de dados, a formulação de perguntas, a exploração dos dados (EDA), a escolha dos gráficos e o storytelling, chegou a hora de transformar esses conceitos em código e experimentação.

Vamos aprender a traduzir hipóteses em análises reais, explorando dados com pandas, matplotlib e seaborn, além de aplicar boas práticas para organizar e interpretar resultados de forma estruturada.

Cada passo seguirá a mesma lógica científica que vimos até aqui: observar, questionar, testar e comunicar.

Prepare-se para unir teoria e prática, e dar vida às suas análises com Python. Vamos nessa?

HANDS ON

Vamos vivenciar o papel da pessoa cientista de dados como investigador(a), formulando perguntas de negócio, explorando os dados (EDA), escolhendo os gráficos adequados e, por fim, construindo uma narrativa analítica que comunique os resultados de forma clara e fundamentada.

A proposta é seguir o fluxo completo do pensamento científico: perguntar, explorar, visualizar e contar a história que os dados revelam.

Mais do que gerar números ou gráficos, o objetivo é desenvolver a capacidade de responder perguntas com propósito e evidência, unindo raciocínio crítico e comunicação eficaz.

SAIBA MAIS

Introdução: o papel do(a) cientista de dados como investigador(a)

Em um mundo cada vez mais orientado por dados, o papel do(a) cientista de dados transcende a mera execução técnica. Ele(a) assume uma postura investigativa, analítica e crítica diante da informação. Não se trata apenas de coletar, limpar e visualizar dados, mas de compreender fenômenos, formular hipóteses e buscar explicações fundamentadas em evidências empíricas. A pessoa cientista de dados atua, portanto, investigando conhecimentos, alguém que utiliza o método científico para responder perguntas complexas sobre o comportamento humano, o desempenho de sistemas e as dinâmicas dos negócios.

Essa figura investigativa emerge da necessidade de interpretar a realidade a partir de evidências quantitativas. Em um cenário em que a abundância de dados pode gerar mais ruído do que clareza, esse(a) profissional precisa desenvolver a capacidade de discernir o que realmente é relevante. Seu trabalho se assemelha ao de um pesquisador: ele(a) observa um fenômeno, formula hipóteses, coleta evidências e testa suas suposições até chegar a uma conclusão sustentada de forma lógica e transparente. Essa abordagem, baseada na curiosidade e na validação sistemática, é o que diferencia a ciência de dados da simples análise de dados descritiva (PROVOST; FAWCETT, 2016).

Enquanto a análise tradicional busca responder ao **“o que aconteceu?”**, o(a) cientista de dados investigativo se concentra no **“por que aconteceu?”**. Essa distinção, embora sutil, é essencial. A primeira descreve; a segunda explica. A primeira observa padrões; a segunda procura causas. O papel do(a) investigador é, portanto, conectar dados a contextos, métricas a comportamentos, números a decisões. Ele(a) se move entre a observação e a inferência, entre o dado bruto e a interpretação significativa. (KNAFLIC, 2019).

Essa mentalidade científica se fundamenta em um princípio básico: **toda análise deve partir de uma pergunta bem formulada**. É a pergunta que orienta o olhar, delimita o escopo e define o propósito da investigação. Uma boa pergunta de negócio — “por que a taxa de cancelamento aumentou nos últimos meses?”, “quais fatores explicam o crescimento regional das vendas?” ou “que variáveis estão

associadas à melhora dos indicadores de saúde?” — pode se transformar em uma poderosa pergunta analítica, capaz de guiar todo o processo exploratório. Assim, o(a) cientista de dados atua como tradutor entre o problema organizacional e a linguagem estatística que pode representá-lo. (PROVOST; FAWCETT, 2016).

Para cumprir esse papel, o(a) profissional precisa cultivar três competências centrais: **curiosidade, raciocínio lógico e rigor metodológico**. A curiosidade impulsiona a explorar o desconhecido, questionar resultados e buscar explicações alternativas. O raciocínio lógico permite construir inferências coerentes e estruturar hipóteses de forma consistente, e o rigor metodológico garante que as conclusões sejam sustentadas por evidências e não por percepções intuitivas. É essa combinação que torna a prática do(a) cientista de dados próxima à de um cientista tradicional — ainda que seus instrumentos sejam diferentes.

Ao adotar uma postura investigativa, o(a) cientista de dados reconhece que o dado, isoladamente, não possui significado. O valor surge da interpretação contextualizada. Um número só ganha sentido quando inserido em um sistema de relações: uma taxa de crescimento é relevante em comparação a um período anterior; um indicador de desempenho só é interpretável quando associado a um objetivo estratégico; uma variável só revela seu papel quando analisada em conjunto com outras. Assim, o processo analítico é sempre uma atividade de construção de sentido.

Esse olhar crítico também implica em reconhecer as limitações dos próprios dados. Todo conjunto de informações é, em algum nível, uma simplificação da realidade. Há lacunas, vieses, erros de medição e restrições metodológicas que precisam ser considerados. O(a) investigador(a) é, por natureza, cético: ele duvida antes de aceitar, questiona antes de afirmar, testa antes de concluir. Essa prudência é essencial para evitar interpretações equivocadas ou conclusões precipitadas, especialmente em contextos em que decisões estratégicas dependem diretamente das análises realizadas. (PROVOST; FAWCETT, 2016).

No ambiente corporativo, essa postura investigativa se manifesta em diversas etapas do trabalho analítico. Antes de aplicar modelos preditivos ou construir dashboards, a pessoa cientista de dados busca compreender o problema em profundidade, analisando o contexto, identificando as variáveis relevantes e reconhecendo as relações de causa e efeito que podem estar ocultas. Durante o processo de exploração dos dados, observa padrões, anomalias e correlações que

podem levantar novas hipóteses. Por fim, interpreta os resultados à luz do objetivo inicial, comunicando-os de forma clara e fundamentada para apoiar decisões. (KNAFLIC, 2019).

Mais do que descobrir padrões, o(a) cientista de dados tem a responsabilidade de produzir conhecimento útil. Isso significa transformar dados em narrativas analíticas que orientem a ação. A informação, por si só, não gera valor; o que gera valor é a capacidade de conectar essa informação a um propósito, de transformá-la em compreensão e, finalmente, em decisão. Essa transição — do dado ao insight, e do insight à decisão — define o impacto real da ciência de dados nas organizações.

Nesse sentido, o(a) profissional investigativo é também um(a) mediador(a) entre mundos. Ele(a) transita entre o domínio técnico da estatística e da programação e o domínio estratégico dos negócios e da gestão. Deve ser capaz de dialogar com executivos(as) e gestores(as) sem recorrer a jargões, apresentando resultados de maneira compreensível e fundamentada. Sua análise precisa ser não apenas correta, mas convincente. O domínio técnico é o alicerce; a clareza comunicativa é o diferencial (PROVOST; FAWCETT, 2016).

Por fim, reconhecer o papel do(a) cientista de dados como investigador(a) é entender que a ciência de dados não é um fim em si mesma, mas um meio para compreender a realidade com mais precisão. É uma disciplina que combina método, raciocínio e criatividade.

A essência desse papel está em formular perguntas relevantes, investigar causas e comunicar descobertas com clareza. Ao adotar essa postura, o(a) profissional deixa de ser apenas um(a) executor(a) de análises e passa a atuar como um(a) verdadeiro agente de conhecimento — alguém capaz de revelar histórias escondidas nos dados e, a partir delas, contribuir para decisões mais inteligentes e conscientes. **Como nasce uma pergunta de negócio**

Toda investigação científica começa com uma pergunta, e na ciência de dados, não é diferente.

A qualidade das respostas que obtemos depende diretamente da qualidade das perguntas que formulamos. Perguntas mal definidas conduzem a análises superficiais; perguntas bem estruturadas iluminam caminhos antes invisíveis.

Por isso, **formular boas perguntas é o primeiro passo — e talvez o mais importante — de todo processo analítico.**

Em muitas organizações, a prática analítica ainda se inicia de forma reativa: alguém solicita um relatório, pede um gráfico ou uma métrica, e a pessoa analista se limita a atender à demanda. No entanto, quem atua como cientista de dados investigativo(a) não se contenta em responder apenas “quantos” ou “quanto”. Busca entender o **porquê** e o **como**. (PROVOST; FAWCETT, 2016).

Antes de responder, devemos questionar a origem da dúvida: o que exatamente estamos tentando entender? Qual é o fenômeno que queremos explicar? Quais hipóteses estão sendo consideradas, ainda que de forma implícita?

Essa capacidade de refinar perguntas é o que transforma um pedido operacional em uma investigação estratégica.

O nascimento de uma pergunta relevante

Perguntas de negócio surgem, na maioria das vezes, de **inquietações sobre desempenho, comportamento ou resultado**. Um(a) gestor(a) percebe uma queda nas vendas, um aumento na taxa de evasão de clientes, uma diferença entre regiões, ou um comportamento inesperado de usuários. Diante desse cenário, ele(a) busca entender o que está acontecendo e por quê. (DUARTE, 2021).

O papel do(a) cientista de dados é traduzir essa inquietação em uma pergunta analítica **clara, mensurável e testável** (PROVOST; FAWCETT, 2016).

Tomemos como exemplo a seguinte situação: uma empresa observa que suas vendas caíram no último trimestre. A pergunta inicial pode ser: “**Por que as vendas diminuíram?**”. Embora válida, essa formulação ainda é vaga. O(a) cientista de dados precisa decompor o problema em elementos observáveis:

- As vendas diminuíram em todos os produtos ou apenas em algumas categorias?
- Houve variação de preço ou de promoção no período?
- O número de clientes ativos caiu?
- A queda foi regional, sazonal ou pontual?

A partir dessas indagações, a pergunta evolui para algo como: “Quais fatores explicam a redução de 15% nas vendas da categoria de eletrônicos no Sudeste no terceiro trimestre, considerando preço, estoque e sazonalidade?”

Perceba que agora a pergunta é **específica, contextualizada e orientada por hipóteses implícitas**. Essa é a essência do pensamento científico aplicado aos dados: transformar dúvidas amplas em questões que possam ser analisadas de maneira estruturada (DUARTE, 2021).

Do problema à hipótese

Uma boa pergunta de negócio é aquela que pode ser convertida em uma hipótese testável. A hipótese serve como bússola da investigação. Ela orienta quais dados devem ser coletados, quais variáveis precisam ser analisadas e quais métodos são adequados para o teste (PROVOST; FAWCETT, 2016).

Dessa forma, o(ia) cientista de dados deixa de ser um(a) mero(a) executor(a) de consultas e se torna uma pessoa condutora do raciocínio analítico, definindo o que deve ser verificado e como isso será feito, garantindo que a análise tenha propósito e validade lógica.

Formular hipóteses não significa buscar confirmações, mas testar suposições. Muitas vezes, a hipótese inicial será refutada — e isso é parte natural do processo. Em ciência de dados, refutar uma hipótese é tão valioso quanto confirmá-la, pois cada resultado contribui para o avanço da compreensão do fenômeno. O importante é manter a integridade do método: a pergunta deve guiar a análise, e não o contrário (DUARTE, 2021).

Tipos de perguntas analíticas

De acordo com Duarte (2021), as perguntas em ciência de dados podem ser classificadas em quatro níveis de maturidade:

- Descritivas — O que aconteceu?
 1. Exemplo: qual foi o volume de vendas no último trimestre?
 - Objetivo: observar e relatar fatos.
- Diagnósticas — Por que aconteceu?
 2. Exemplo: quais fatores contribuíram para a queda nas vendas?

- Objetivo: identificar causas e correlações.
- Preditivas — O que pode acontecer?
- 3.** Exemplo: qual é a probabilidade de o cliente cancelar a assinatura nos próximos 30 dias?
 - Objetivo: antecipar comportamentos futuros com base em padrões históricos.
- Prescritivas — O que devemos fazer a respeito?
- 4.** Exemplo: qual estratégia de retenção tende a reduzir a evasão de clientes em 20%?
 - Objetivo: propor ações ou intervenções baseadas em modelos e simulações.

Esses níveis não são estanques, mas complementares. Uma análise preditiva precisa estar apoiada em uma sólida compreensão descritiva e diagnóstica. Da mesma forma, qualquer recomendação prescritiva deve ser sustentada por evidências empíricas. Assim, a pergunta orienta não apenas o tipo de análise, mas também a profundidade e a complexidade do raciocínio adotado.

A importância do contexto

Perguntas devem considerar o contexto, pois o mesmo dado pode ser interpretado de diferentes formas. Conhecer o cenário organizacional, o público e os objetivos estratégicos é fundamental para criar perguntas relevantes (KNAFLIC, 2019).

Em projetos de ciência de dados aplicados a negócios, a falta de clareza sobre o contexto é uma das principais causas de análises irrelevantes ou conclusões imprecisas.

O(a) profissional precisa, portanto, atuar de forma interdisciplinar. Deve compreender a linguagem do negócio, os indicadores que orientam a decisão e as limitações operacionais que influenciam os resultados.

Essa sensibilidade contextual é o que torna a pergunta analítica significativa e útil — não apenas correta do ponto de vista técnico, mas pertinente do ponto de vista prático.

Do questionamento à descoberta

Uma boa pergunta inicia a descoberta, estimula a curiosidade, orienta a análise e define como apresentar os resultados. Responder perguntas com dados é, antes de tudo, um exercício de pensamento estruturado, que combina criatividade e disciplina (DUARTE, 2021)

Enquanto a criatividade ajuda a formular hipóteses originais e conexões inesperadas, a disciplina garante que o processo siga critérios de rigor e verificabilidade. O equilíbrio entre ambos transforma o(a) cientista de dados em um profissional capaz de gerar conhecimento e não apenas informação.

Perguntar é, portanto, um ato intelectual. É um gesto de dúvida e de busca, de quem reconhece que os dados não falam por si mesmos — eles respondem, mas apenas quando são interrogados com clareza.

É essa atitude investigativa, orientada por boas perguntas, que sustenta toda a prática da ciência de dados e distingue o(a) cientista do(a) executor(a). A partir daqui, cada etapa — da exploração inicial à comunicação dos resultados — será guiada por esse princípio fundamental: perguntas bem formuladas produzem descobertas valiosas (PROVOST; FAWCETT, 2016).

Exploração Inicial (EDA – Exploratory Data Analysis)

Toda investigação em ciência de dados chega inevitavelmente ao momento em que é preciso confrontar as hipóteses com a realidade empírica. É nesse ponto que a Análise Exploratória de Dados (Exploratory Data Analysis — EDA) se torna protagonista.

Mais do que uma etapa técnica, a EDA é uma postura analítica. Ela representa a fase em que o(a) cientista de dados observa o conjunto de informações de forma aberta, questionadora e sistemática, buscando padrões, tendências, inconsistências e indícios que sustentem — ou refutem — suas hipóteses iniciais (GRUS, 2021).

A análise exploratória é, portanto, o primeiro contato significativo entre o(a) pesquisador(a) e os dados.

Antes de aplicar modelos preditivos, estatísticas inferenciais ou algoritmos de machine learning, é preciso compreender profundamente o comportamento do conjunto de dados com o qual se está trabalhando (GRUS, 2021)

Esse entendimento inicial é o alicerce sobre o qual todas as análises posteriores serão construídas. Sem ele, corre-se o risco de basear conclusões em interpretações equivocadas ou em dados mal compreendidos.

O propósito da análise exploratória

O objetivo central da EDA é compreender a estrutura, a qualidade e as características fundamentais dos dados. Trata-se de um processo investigativo que visa responder a perguntas como:

- Quais variáveis estão disponíveis e como se relacionam?
- Há valores ausentes, duplicados ou inconsistentes?
- Como estão distribuídas as variáveis numéricas e categóricas?
- Existem padrões sazonais, concentrações ou dispersões relevantes?
- Há indícios de correlação entre as variáveis que podem ser explorados?

Responder a essas perguntas iniciais é essencial para transformar dados brutos em conhecimento potencial. A EDA permite identificar problemas de qualidade, detectar tendências e anomalias, e — talvez o mais importante — reformular hipóteses com base em evidências.

Em muitos casos, o processo exploratório revela aspectos do fenômeno que não haviam sido antecipados na formulação original das perguntas de negócio, o que leva a novas interpretações e descobertas.

O olhar crítico sobre os dados

Um erro comum entre profissionais em formação é considerar a EDA como uma tarefa meramente descritiva — uma sequência de gráficos e estatísticas resumidas. Na verdade, ela exige interpretação e raciocínio crítico. Observar uma distribuição ou uma correlação é apenas o começo; o passo seguinte é compreender o que essa informação significa no contexto da investigação (GRUS, 2021).

Um valor atípico, por exemplo, pode ser um erro de registro, mas também pode representar um caso excepcional que merece estudo detalhado. Uma correlação positiva pode indicar uma relação causal, mas também pode ser resultado de uma variável oculta não observada.

Por isso, a EDA é um exercício de equilíbrio entre o rigor quantitativo e a sensibilidade interpretativa.

A importância da familiaridade com o conjunto de dados

Nenhuma técnica estatística, por mais sofisticada que seja, substitui o conhecimento profundo do conjunto de dados. Compreender o contexto de origem — como os dados foram coletados, quais limitações o processo possui, quais unidades de medida estão envolvidas, quais transformações já foram aplicadas — é parte inseparável da análise exploratória.

Essa familiaridade permite que o(a) cientista de dados reconheça padrões artificiais, ruídos e distorções que poderiam comprometer a interpretação.

Além disso, a análise exploratória permite que analistas e stakeholders alinhem o vocabulário do projeto, esclarecendo o significado dos dados e prevenindo confusões entre métricas. Um entendimento claro, essencial para análises consistentes, é construído nessa etapa (GRUS, 2021).

Da observação à hipótese revisada

A análise exploratória é iterativa: o(a) cientista de dados observa, interpreta e ajusta perguntas à medida que surgem novos padrões, frequentemente reformulando hipóteses iniciais. Por exemplo, uma hipótese de que “as vendas caíram por falta de estoque” pode ser reavaliada ao se observar que a queda ocorreu principalmente em uma região onde o número de pontos de venda diminuiu.

Assim, a exploração de dados é também um processo de aprendizado — tanto sobre o fenômeno quanto sobre o próprio conjunto de informações. Essa característica iterativa reforça o caráter científico da análise: não há respostas definitivas, mas aproximações sucessivas de compreensão.

Cada rodada de observação e interpretação amplia a precisão das hipóteses e direciona novas investigações. É um ciclo contínuo de pergunta, análise e descoberta.

O valor da intuição guiada por evidências

Embora a análise exploratória seja guiada por dados, ela também exige intuição. Nesse contexto, intuição não significa especulação, mas a capacidade de reconhecer padrões com base na experiência acumulada e na compreensão do domínio de negócio.

A pessoa cientista de dados experiente utiliza a intuição como ponto de partida para formular hipóteses, mas recorre aos dados para validá-las ou refutá-las.

A intuição sem dados é suposição; os dados sem intuição são fragmentos sem direção. A força da EDA está justamente na integração equilibrada entre ambos.

Da exploração à comunicação

A exploração inicial prepara o terreno para a etapa seguinte: a comunicação dos achados. Durante a EDA, o(a) cientista de dados identifica não apenas números e gráficos, mas histórias potenciais que serão contadas posteriormente.

Essas histórias ainda estão em estado bruto, esperando ser organizadas em narrativas claras e visualmente compreensíveis. Por isso, a análise exploratória deve ser conduzida com o olhar voltado à comunicação: quais descobertas merecem destaque? O que pode surpreender o público? Que evidências sustentam as conclusões mais relevantes? (DUARTE, 2021).

Ao final dessa etapa, o(a) cientista de dados não deve possuir apenas um conjunto de descrições estatísticas, mas uma compreensão integrada do fenômeno estudado. É essa compreensão que permitirá, nas próximas etapas, escolher visualizações adequadas, construir argumentos consistentes e apresentar resultados de forma convincente.

Escolha de gráficos e visual storytelling

A visualização de dados é, ao mesmo tempo, uma arte e uma técnica. É a arte de traduzir números em percepções visuais que provoquem compreensão imediata; e é a técnica de comunicar informações de forma precisa, evitando interpretações equivocadas (DUARTE, 2021)

No contexto da ciência de dados, a escolha de gráficos é uma etapa estratégica, pois o modo como apresentamos os dados influencia diretamente o modo como eles serão compreendidos. Um bom gráfico não é apenas esteticamente agradável: ele revela relações, enfatiza contrastes e conduz o olhar do leitor para o essencial. Cada decisão — tipo de gráfico, escala, cores, ordem das categorias — é uma escolha de narrativa (KNAFLIC, 2019)

Por isso, o(a) cientista de dados que deseja comunicar descobertas precisa dominar não apenas a análise, mas também o design da comunicação visual. **A função do gráfico: comunicar, não decorar**

O primeiro princípio da visualização de dados é simples: o gráfico existe para esclarecer, não para enfeitar. Ele deve servir à pergunta de negócio e à hipótese investigada, nunca à estética isolada. Um gráfico visualmente impactante, mas sem propósito analítico, é apenas ruído visual.

O objetivo é **sempre a clareza**: o leitor deve ser capaz de compreender a principal mensagem em poucos segundos. Isso significa que a escolha do gráfico não é arbitrária — ela depende do tipo de informação que se deseja comunicar (KNAFLIC, 2019).

Antes de decidir “qual gráfico usar”, o(a) cientista de dados deve responder:

- O que quero mostrar?
- Que tipo de relação estou tentando evidenciar?
- Qual é o insight mais importante que o público precisa compreender?

Escolha do tipo de gráfico

A resposta às perguntas sobre o que se deseja comunicar determinará a forma visual mais adequada. Em termos gerais, os gráficos são instrumentos que expressam relações entre variáveis. Cada tipo de variável — numérica, categórica, temporal ou geográfica — possui formas específicas de representação (KNAFLIC, 2019).

A seguir, exemplos que ajudam a sistematizar essas escolhas.

- Comparações: quando o objetivo é comparar valores entre categorias ou grupos.
 - Gráficos recomendados: barras, colunas, boxplots.
 - Exemplos de perguntas: “Qual região teve maior volume de vendas?” ou “Como varia o tempo médio de atendimento entre hospitais?”.
- Distribuições: quando se deseja observar a frequência, dispersão ou concentração dos dados.

- Gráficos recomendados: histogramas, gráficos de densidade, violino.
- Exemplos: “Como está distribuída a idade dos pacientes?” ou “Há concentração de valores em determinada faixa de renda?”.
- Relações: quando o foco é mostrar a interação entre duas ou mais variáveis.
 - Gráficos recomendados: dispersão (scatter plot), matriz de correlação, heatmap.
 - Exemplos: “Existe relação entre o número de atendimentos e a taxa de satisfação?” ou “Quais variáveis apresentam maior correlação com o tempo de internação?”.
- Evoluções temporais: quando o interesse é observar mudanças ao longo do tempo.
 - Gráficos recomendados: linhas, áreas, colunas empilhadas.
 - Exemplos: “Como evoluíram as vendas mensais?” ou “Qual a tendência do número de casos por semana?”.
- Composições: quando se busca evidenciar proporções ou participação relativa.
 - Gráficos recomendados: barras empilhadas, treemaps, áreas proporcionais (e, com cautela, gráficos de pizza).
 - Exemplos: “Qual a participação de cada categoria no total de despesas?” ou “Como se distribuem os tipos de atendimento por faixa etária?”.

A escolha adequada do tipo de gráfico não é apenas uma questão de conveniência estética, mas de integridade analítica. Um gráfico inadequado pode distorcer relações, amplificar diferenças ou esconder padrões. Assim, compreender as propriedades visuais de cada formato é parte essencial da formação do cientista de dados.

Percepção visual e clareza cognitiva

A boa visualização respeita os limites e as capacidades da percepção humana. O cérebro humano é naturalmente eficiente em identificar comprimentos, posições e direções, mas muito menos preciso ao comparar ângulos, volumes e cores sem referência (KNAFLIC, 2019).

Por isso, gráficos de barras são mais precisos que gráficos de pizza, pois as diferenças de altura são mais facilmente percebidas do que as diferenças de área. Da mesma forma, as cores devem ser usadas para destacar relações, e não para gerar confusão visual.

Um gráfico claro é aquele que reduz o esforço cognitivo do leitor. Quanto menos o público precisar “decifrar” o que está sendo mostrado, mais eficaz será a comunicação. Títulos explicativos, legendas objetivas e escalas consistentes contribuem para esse objetivo (KNAFLIC, 2019)

O(a) cientista de dados deve se perguntar constantemente: “Este gráfico facilita ou dificulta a compreensão da mensagem que quero transmitir?”.

A narrativa visual: do dado ao insight

A visualização de dados vai além de apresentar: ela conta uma história. Cada gráfico faz parte de uma narrativa que conecta contexto, evidência e conclusão. Por isso, fala-se em Data Storytelling: o processo de transformar análises em histórias que comunicam significado e provocam reflexão.

Uma boa história com dados tem estrutura. Ela começa com um contexto (“Por que este tema é relevante?”), apresenta um conflito ou descoberta (“O que os dados revelam?”) e termina com uma mensagem ou implicação (“O que aprendemos com isso?”) (KNAFLIC, 2019)

A sequência dos gráficos, a escolha do foco e o ritmo da apresentação devem seguir essa lógica narrativa.

O(a) cientista de dados, nesse sentido, atua como um(a) curador(a) de informações, decidindo o que merece destaque, o que deve ser simplificado e o que pode ser omitido. Essa curadoria exige responsabilidade: omitir ou exagerar elementos visuais pode alterar a percepção da realidade. O compromisso ético do(a) cientista é com a veracidade e a transparência das evidências.

O equilíbrio entre forma e conteúdo

Embora o design visual tenha papel importante, o conteúdo analítico deve permanecer no centro da comunicação. Cores, ícones, animações e interações podem enriquecer a experiência visual, desde que não desviem a atenção da mensagem principal.

Encontrar o equilíbrio entre estética e clareza é uma competência essencial: gráficos simples e bem estruturados costumam ser mais eficazes do que visualizações complexas que exigem esforço interpretativo excessivo.

Além disso, a escolha visual deve considerar o público. Gráficos voltados a equipes técnicas podem explorar mais detalhes e métricas; já apresentações para executivos(as) devem enfatizar síntese, tendências e implicações (KNAFLIC, 2019).

A pessoa cientista de dados precisa adaptar o nível de detalhamento ao perfil do(a) leitor(a) — comunicando a complexidade sem ser confuso(a), e a simplicidade sem ser simplista.

A visualização como instrumento de persuasão ética

Todo gráfico é em certa medida um ato de persuasão, mesmo quando não há intenção explícita, a forma de representar os dados influencia as conclusões do público.

Escalas truncadas, eixos invertidos, paletas de cores inadequadas ou destaques seletivos podem distorcer percepções e induzir interpretações equivocadas. A responsabilidade do(a) cientista de dados é, portanto, comunicar de forma ética, assegurando que o formato visual reflita fielmente a realidade estatística (KNAFLIC, 2019).

A integridade na comunicação visual é parte da integridade científica. Visualizações devem ser precisas, proporcionais e transparentes quanto às limitações dos dados. O compromisso não é apenas informar, mas educar o olhar do público, estimulando uma leitura crítica das evidências (DUARTE, 2021).

Construindo uma narrativa com dados

A análise de dados só atinge seu verdadeiro valor quando é capaz de comunicar descobertas de forma clara e significativa. O Data Storytelling é o processo de transformar dados em narrativas compreensíveis, conectando evidências a contextos e permitindo que o público extraia sentido das informações apresentadas (KNAFLIC, 2019).

Em essência, trata-se de unir análise, comunicação e propósito. Contar histórias com dados não é embelezar relatórios, mas estruturar o raciocínio analítico

em uma sequência lógica. Toda boa narrativa possui três elementos: contexto, descoberta e conclusão.

O contexto explica o problema e sua relevância; a descoberta apresenta as evidências e padrões observados; e a conclusão traduz essas evidências em implicações práticas (DUARTE, 2021).

Outro aspecto essencial é a intencionalidade. Cada gráfico, número e frase deve cumprir uma função dentro da mensagem central. O(a) cientista de dados deve escolher o que enfatizar e o que omitir, com base naquilo que sustenta o argumento principal.

Sem intenção, a comunicação se torna dispersa; com intenção, transforma-se em aprendizado. Assim como nas etapas anteriores, o Data Storytelling também exige responsabilidade ética. Toda narrativa é uma seleção — e essa seleção deve ser honesta. O compromisso do(a) cientista de dados é com a veracidade e a transparência: apresentar as conclusões sustentadas pelas evidências, reconhecendo limitações e incertezas (KNAFLIC, 2019).

No fim, contar histórias com dados é dar significado às análises e utilidade às descobertas. É o momento em que a técnica se transforma em compreensão e a evidência em decisão.

MERCADO, CASES E TENDÊNCIAS

Para aprofundar sua visão sobre o papel da pessoa cientista de dados no mercado e compreender como gerar impacto real com análises, recomendamos duas referências fundamentais.

O livro “Data Science para Negócios”, de Foster Provost e Tom Fawcett (2016), apresenta uma visão estratégica sobre como a ciência de dados apoia decisões e gera vantagem competitiva, com diversos cases que ilustram a aplicação prática em diferentes setores.

Complementarmente, “Data Science do Zero”, de Joel Grus (2021), oferece conceitos essenciais e exemplos introdutórios com Python, permitindo que você desenvolva o raciocínio analítico necessário para resolver problemas reais com dados.

Esses livros, combinados, oferecem uma compreensão completa das competências exigidas no mercado atual e das tendências que moldam a atuação de um(a) AI Scientist mais crítico(a), aplicado(a) e preparado(a) para desafios reais.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você compreendeu o papel do(a) cientista de dados como investigador, alguém que vai além da simples análise e busca entender o porquê dos fenômenos observados.

Aprendeu a formular boas perguntas de negócio, transformando curiosidade em hipóteses que podem ser testadas por evidências concretas.

Explorou o conceito de Análise Exploratória de Dados (EDA) como etapa essencial para conhecer, questionar e interpretar o comportamento dos dados, identificando padrões, relações e inconsistências.

Entendeu que a visualização e o storytelling são ferramentas estratégicas para comunicar descobertas com clareza, precisão e propósito — transformando dados em histórias que orientam decisões.

Por fim, reconheceu que a prática da ciência de dados vai além de técnicas e ferramentas: ela exige pensamento crítico, ética e intenção analítica.

Responder perguntas com dados é, sobretudo, um exercício de investigação e comunicação científica, que transforma informações em conhecimento e conhecimento em ação.

REFERÊNCIAS

DUARTE, N. **DataStory**: explique dados e inspire ações por meio de histórias. Rio de Janeiro: Alta Books, 2021. 316 p.

GRUS, J. **Data Science do zero**: noções fundamentais com Python. 2. ed. Rio de Janeiro: Alta Books, 2021. 336 p.

KNAFLIC, C.N. **Storytelling com dados**: um guia sobre visualização de dados para profissionais de negócios. Rio de Janeiro: Alta Books, 2019. 256 p.

PROVOST, FosterF; FAWCETT, TOM. **Data Science para negócios**. Rio de Janeiro: Alta Books, 2016. 408 p.

PALAVRAS-CHAVE

Dados. Storytelling. Negócios.

EMAP

The background is a dark, abstract digital space. It features a complex network of glowing blue lines and patterns that resemble a circuit board or a data network. The lines are arranged in a way that creates a sense of depth and perspective, with some lines converging towards the center. In the center of the image, the word "POSTECH" is written in a white, stylized, sans-serif font. The letters are slightly transparent, allowing the glowing blue patterns to be visible through them. The overall aesthetic is futuristic and technological.

POSTECH