

AI SCIENTIST

FASE 1 | AULA 02 -

PROJETO PRÁTICO: CONSTRUINDO UM EDA

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
MERCADO, CASES E TENDÊNCIAS	31
O QUE VOCÊ VIU NESTA AULA?	31
REFERÊNCIAS.....	33

O QUE VEM POR AÍ?

Agora que você já aprendeu a questionar e explorar um dataset de forma estruturada, é hora de colocar tudo isso em prática. Nas próximas aulas, vamos aplicar os conceitos do EDA em um conjunto de dados real: os indicadores do IDHM (Índice de Desenvolvimento Humano Municipal). Esse tema nos permite mergulhar em questões sociais brasileiras de forma analítica, investigando como diferentes dimensões de desenvolvimento impactam o país ao longo do tempo.

Vamos trabalhar diretamente no Python, utilizando ferramentas como pandas, matplotlib e seaborn para investigar como variáveis relacionadas à educação, renda e longevidade se comportam em diferentes regiões do Brasil. Será uma oportunidade para enxergar como dados públicos podem revelar desigualdades, tendências regionais, avanços locais e também os desafios que ainda fazem parte do nosso cenário social.

O objetivo é que você desenvolva a capacidade de fazer perguntas inteligentes, identificar padrões e extrair insights relevantes que façam sentido para o mundo real. Aqui, o foco não será apenas gerar gráficos bonitos, mas investigar como cientistas: formulando hipóteses, validando comportamentos dos dados e registrando descobertas significativas. Prepare-se para exercitar sua curiosidade, seu olhar crítico e sua autonomia analítica — porque agora começa a parte prática da nossa aventura.

HANDS ON

Vamos aplicar todo o fluxo de EDA sobre o IDHM usando o notebook em Python. Começaremos carregando a base, entendendo a estrutura e validando a qualidade dos dados (tipos, faltantes, duplicados e valores fora de faixa). Em seguida, partimos para estatísticas descritivas e distribuição das variáveis ligadas a educação, longevidade e renda, sempre comparando períodos (quando disponíveis) e recortes geográficos. A ideia é transformar curiosidade em perguntas testáveis: como o IDHM varia entre regiões? Há municípios que destoam de seus estados? O que muda quando olhamos medianas em vez de médias?

Depois, investigaremos relações entre variáveis para descobrir padrões: correlações, diferenças entre grupos e comportamentos atípicos que merecem atenção. Vamos visualizar os achados com histogramas, boxplots, scatter plots e um heatmap de correlação para destacar possíveis “drivers” do índice. Fechamos com um registro organizado das descobertas e hipóteses para próximas aulas — deixando claro o que aprendemos, o que ainda precisa ser verificado e quais caminhos de análise (inclusive de negócio/política pública) fazem sentido explorar a partir do IDHM.

SAIBA MAIS

Contexto e objetivo do EDA: por que explorar dados é o primeiro passo para fazer ciência de verdade

Quando recebemos um conjunto de dados, normalmente o primeiro impulso é abrir o Jupyter, carregar o dataset e começar a criar modelos superpoderosos para prever o futuro. Afinal, são os modelos que geram os resultados incríveis das grandes empresas, certo?

Na verdade... não exatamente. Antes de qualquer técnica avançada, o(a) cientista de dados precisa entender com o que está lidando. O que significam aqueles números, categorias e datas? Quem ou o que eles representam? Eles fazem sentido? Os dados contam uma história — e a nossa primeira missão é descobrir qual é essa história.

Essa etapa inicial da análise é chamada de EDA (Análise Exploratória de Dados) ou, em uma definição mais divertida: “a hora de bisbilhotar os dados sem compromisso, mas com muita curiosidade”. É nesse momento que nos tornamos investigadores(as) de dados. Perguntamos, comparamos, testamos, desconfiamos e tentamos montar este quebra-cabeça que é a realidade representada em uma planilha. Antes de tentar prever qualquer coisa, precisamos aprender a observar.

Um exemplo de vida real

Pense em uma situação típica do dia a dia de uma empresa: um e-commerce começa a receber reclamações internas sobre queda nas vendas e aumento no churn (cancelamento de clientes). Você recebe uma base com informações dos clientes e transações dos últimos meses.

De início, nada — absolutamente nada — garante que o churn esteja realmente aumentando, nem que as vendas diminuíssem por uma razão específica. É muito comum que a percepção inicial do problema não corresponda à realidade. E é exatamente nesse ponto que o EDA se torna essencial: ele valida ou confronta as narrativas que nos chegam (PROVOST; FAWCETT, 2016).

A análise exploratória nos permite responder perguntas como: “Os clientes que cancelaram eram mais fiéis ou eventuais?”, “Existe um período do ano em que o churn dispara?”, “Alguma categoria de produto contribuiu mais para o problema?”, “O que mudou na base de clientes recentemente?” etc.

Muitas vezes, esse primeiro mergulho já é suficiente para revelar o que está acontecendo — sem precisar de modelos complexos. A verdade é que o EDA, por si só, pode gerar insights suficientes para direcionar decisões importantes.

Cuidado: dados podem enganar

E por que isso é tão importante? Porque dados podem nos enganar. Uma tabela pode estar cheia de registros duplicados, valores faltantes ou inconsistências que distorcem toda a análise. Se ignorarmos essa etapa, corremos o risco de colocar informações com baixa qualidade dentro de modelos sofisticados que, no fim, entregam conclusões erradas com muita confiança — o que é ainda mais perigoso do que não ter nenhum modelo. A famosa frase **"garbage in, garbage out"** deveria estar escrita em letras gigantes em toda equipe de dados: se os dados estão errados, o resultado final também estará (PROVOST; FAWCETT, 2016).

Existe ainda um mito comum no imaginário popular de Data Science: se você tem dados, você tem respostas. Só que dados não pensam, não raciocinam, não analisam, eles apenas existem. Quem dá significado a eles somos nós. E quando não fazemos a lição de casa direito, o próprio dataset pode nos conduzir para direções completamente equivocadas (PROVOST; FAWCETT, 2016).

Por isso, no EDA assumimos uma postura essencial ao(à) Cientista de Dados: **desconfiar primeiro, confiar depois.**

O(a) cientista de dados não pode ser um(a) mero(a) consumidor(a) de dados; ele(a) precisa ser um(a) avaliador(a) crítico(a). Quando analisamos qualidade, completude, consistência e coerência dos dados, estamos garantindo que o futuro da análise — e as decisões estratégicas que surgirão dela — se sustentem em realidade, e não em ilusões estatísticas.

Revelar padrões e levantar hipóteses

Além de identificar problemas, o EDA também nos ajuda a revelar padrões e levantar hipóteses. Essa etapa permite que o(a) cientista de dados **observe o comportamento das variáveis**, compreenda **como elas se relacionam** e perceba **associações relevantes** que podem se tornar importantes nas fases seguintes da análise. Um simples histograma pode mostrar que determinada variável apresenta um comportamento totalmente diferente do esperado. Um gráfico de dispersão pode indicar uma relação interessante entre duas métricas. Uma análise de datas pode revelar tendências sazonais e impactos de eventos específicos. O(a) pesquisador(a) atento(a) sempre aproveita esses sinais.

É comum pensar que EDA se resume a gerar gráficos bonitos, mas isso é um equívoco. Embora a visualização seja parte fundamental do processo, ela não é o objetivo principal. Não estamos aqui para criar arte, e sim para pensar criticamente. Pensar como cientistas que tentam entender o mundo real por meio de dados (DUARTE, 2021).

Dando direção às próximas etapas

Outro papel essencial do EDA é fornecer clareza para os próximos passos. Quando terminamos essa etapa, passamos a entender melhor o que buscar e como avançar. Descobrimos quais variáveis realmente importam, quais precisam de tratamento mais cuidadoso e quais talvez devam ser descartadas. Também conseguimos enxergar se há indicadores relevantes ausentes e se precisaremos buscar novas fontes de dados. O fato é simples: o EDA transforma incerteza em direção (GRUS, 2021).

Se você lembra apenas de uma coisa deste capítulo, que seja isso: **EDA não é opcional. Ele é o coração da análise de dados.** Ele diferencia o “chutar e ver no que dá” do método científico. É o que tira o trabalho do piloto automático e coloca nas mãos de um(a) investigador(a) curioso(a) e atento(a).

É aqui que o(a) aluno(a) deixa de ser apenas um(a) operador(a) de ferramentas e começa a se tornar um(a) Cientista de Dados: alguém que questiona, interpreta, investiga e é capaz de conectar nuances dos dados com o mundo real.

Reconhecimento da estrutura do dataset

A frase “os dados são o novo petróleo” costuma aparecer sempre que falamos sobre Data Science. Mas a parte que ninguém lembra de dizer é que petróleo bruto não serve para quase nada — ele precisa ser refinado para ganhar valor. Com os dados, acontece exatamente o mesmo: antes de qualquer análise, precisamos saber que material temos em mãos.

Ao abrir um dataset pela primeira vez, não basta olhar rapidamente as primeiras linhas e assumir que está tudo claro. É fundamental compreender qual é a lógica daquela base: quem está sendo representado ali, que atributos descrevem esses registros, quando e como as informações foram capturadas e qual parte da realidade ficou de fora. Cada plano de análise começa por aí. Esses questionamentos iniciais fazem toda a diferença, pois definem o que podemos — e o que não podemos — inferir a partir dos dados. (GRUS, 2021)

Ignorar essa etapa é como tentar navegar sem mapa. Podemos até seguir em frente e construir modelos sofisticados, mas estaremos tomando decisões sem conhecer o território. Compreender a estrutura do dataset é o primeiro passo para garantir que toda a investigação posterior esteja baseada em algo sólido e bem definido. Antes de procurar respostas nos dados, precisamos ter certeza de que entendemos as perguntas que eles podem responder.

Unidade de análise: quem é o personagem principal?

Quando abrimos um dataset pela primeira vez, a sensação pode ser parecida com a de chegar a uma cidade desconhecida com um mapa incompleto. Existe um mundo inteiro a ser explorado, mas antes de avançar precisamos entender minimamente onde estamos pisando. Cada conjunto de dados possui um propósito, um recorte de realidade, uma lógica interna — e é essa lógica que precisamos identificar logo no início da análise.

Nesse momento inicial, o objetivo não é extrair conclusões, mas ganhar familiaridade com o material disponível. O(a) cientista de dados precisa observar as colunas, os tipos de variáveis, o tamanho da base e o formato em que a informação está organizada. Esse primeiro contato permite reconhecer se o dataset se refere a

peças, produtos, eventos, medições... e em qual nível essa representação acontece. É o passo que garante que estamos trabalhando com uma visão coerente do fenômeno estudado (GRUS, 2021).

Entender o território é fundamental porque, sem isso, qualquer análise pode se tornar precipitada. Uma interpretação apressada pode nos fazer acreditar que estamos investigando um comportamento estatístico, quando na verdade estamos apenas observando o efeito de uma forma específica de registro dos dados. Compreender o campo antes de explorá-lo é o que permite que o restante do trabalho avance com segurança, clareza e direção.

Entendendo os tipos de variáveis

Depois de identificar o personagem, precisamos conhecer como ele é descrito. Cada coluna é uma característica, e classificá-las corretamente é essencial:

Tipo de Variável	Exemplos	Cuidados
Numérica contínua	Valor gasto, peso, temperatura	Outliers impactam muito
Numérica discreta	Quantidade de itens	Pode exigir agrupamentos
Categórica nominal	Produtos, cidades	Não tem ordem
Categórica ordinal	Nível de satisfação, senioridade	Ordem importa!
Temporal	Datas, duração	Análises de tendência
Booleana	Sim/não	Alta utilidade para segmentação
Textual	Comentários	Insights de NLP
Tipo de Variável	Exemplos	Cuidados

Numérica contínua	Valor gasto, peso, temperatura	Outliers impactam muito
Numérica discreta	Quantidade de itens	Pode exigir agrupamentos
Categórica nominal	Produtos, cidades	Não tem ordem
Categórica ordinal	Nível de satisfação, senioridade	Ordem importa!
Temporal	Datas, duração	Análises de tendência
Booleana	Sim/não	Alta utilidade para segmentação
Textual	Comentários	Insights de NLP

Tabela 1 - Exemplo de utilização de variáveis e seus cuidados
Fonte: elaborado pelo autor (2025)

Essa classificação determina:

- Quais estatísticas fazem sentido;
- Quais gráficos usar;
- Quais técnicas de modelagem considerar;
- Como tratar valores ausentes.

Se confundimos uma variável ordinal com uma nominal ou um código com um número real, podemos distorcer completamente as conclusões.

Dicionário de dados: o manual que todos ignoram

Se você já tentou montar um móvel complicado sem olhar o manual, sabe exatamente o que pode acontecer: peças sobrando, estrutura frágil, tudo fora do lugar. Com dados, ocorre a mesma coisa. Sem o dicionário de dados, corremos um grande risco de interpretar informações de maneira completamente equivocada, mesmo achando que estamos no caminho certo.

O dicionário de dados é o documento que descreve de forma clara o que cada coluna representa, qual tipo de dado é esperado, quais valores são válidos, qual unidade está sendo usada e como aquela informação foi obtida ou calculada. Ele evita situações em que uma coluna com números seja tratada como valores monetários quando, na verdade, são apenas códigos internos do sistema — algo que pode gerar conclusões totalmente sem sentido (GRUS, 2021).

Na prática, esse dicionário raramente está disponível, atualizado ou completo. Quando ele não existe — e isso acontece com mais frequência do que se imagina — o papel do(a) cientista de dados é se tornar investigador(a): observar padrões dentro da base, conversar com quem conhece o domínio do problema, revisar processos de coleta e até testar hipóteses para descobrir o significado real por trás de cada variável. (GRUS, 2021).

No fim das contas, o dicionário de dados é o que nos permite entender o dataset de forma verdadeira. Ele é a ponte entre o mundo real e o mundo digital. Sem essa ponte, a análise pode até parecer tecnicamente impecável, mas desconectada da realidade que deveria representar. Interpretar dados corretamente depende, antes de tudo, de saber o que eles realmente querem dizer.

A história que os dados conseguem contar

Um dataset nunca mostra a realidade completa — ele revela apenas aquilo que foi possível registrar. E tudo o que ficou de fora também faz parte da história, ainda que em silêncio. Por isso, antes de começarmos a tirar conclusões, precisamos entender com clareza qual recorte da realidade está sendo representado pelos dados (GRUS, 2021).

Por exemplo, se estamos analisando dados de um hospital que contém apenas informações de pacientes internados, estamos observando apenas a parcela da população que necessitou de internação. Não sabemos nada sobre quem passou pelo pronto atendimento e voltou para casa ou quem procurou outra unidade de saúde. O mesmo acontece em um dataset de vendas que registra apenas compras bem-sucedidas: sem dados de devoluções ou abandono de carrinho, podemos acabar acreditando que tudo funciona perfeitamente, quando existe uma parte do problema que permanece invisível.

Períodos atípicos também podem distorcer interpretações. Dados coletados durante uma crise econômica, uma pandemia ou uma campanha agressiva de marketing refletem comportamentos excepcionais, que não necessariamente se sustentam nos meses seguintes. Se ignorarmos esse contexto, podemos generalizar conclusões que só fazem sentido naquele período específico (GRUS, 2021).

Por isso, ao olhar para um dataset, é fundamental questionar de onde ele veio, quem está incluído e, principalmente, quem não está. A análise só é realista quando sabemos o que estamos enxergando — e também o que está fora do nosso campo de visão.

Um(a) cientista de dados consciente entende que não existe dataset perfeito. Existe um conjunto de dados que precisa ser interpretado com conhecimento do contexto onde foi gerado. Quando reconhecemos as lacunas, os filtros naturais da coleta e as limitações de escopo, fortalecemos nossa análise e evitamos extrapolações que não se sustentam no mundo real (DUARTE, 2021).

No fim, interpretar dados é também interpretar silêncios: a história completa está sempre além da planilha.

Avaliação da qualidade dos dados: nem todo dado é confiável – é seu papel descobrir isso

Não adianta ter milhões de linhas se elas não refletem a realidade. Dados ruins geram conclusões ruins — e conclusões ruins geram decisões piores ainda (DUARTE, 2021).

Avaliar a qualidade dos dados é como fazer uma triagem antes do diagnóstico: verificamos se o material está em boas condições antes de analisá-lo. Um(a) Cientista de Dados precisa olhar para o dataset com desconfiança e perguntar: “Posso confiar nesses dados?”. Esse olhar crítico é o que separa o(a) analista apressado(a) do(a) cientista de dados de verdade.

Qualidade de dados significa que as informações são **completas, corretas, consistentes e atuais**. Em outras palavras, elas devem representar o fenômeno real sem distorções.

Os principais pilares são:

- **Completeness:** há dados faltando?
- **Consistência:** o mesmo registro aparece com valores diferentes?
- **Validade:** os dados seguem regras lógicas (ex.: idade não pode ser negativa)?
- **Precisão:** o valor registrado é fiel à realidade?
- **Atualidade:** o dado ainda é relevante ou já está desatualizado?

Quanto mais critérios forem atendidos, mais segura será a análise.

Detectando problemas na prática

Avaliar a qualidade dos dados não é algo filosófico ou abstrato. É um processo **mão na massa**, que começa com perguntas simples e ferramentas básicas do Python, principalmente com o pandas. É como fazer um check-up rápido antes de iniciar qualquer tratamento: primeiro observamos os sinais vitais para identificar se existe algo que precisa de atenção imediata (GRUS, 2021).

Quando carregamos um dataset, a primeira curiosidade não deveria ser “o que posso prever com isso?”, mas sim “o que está errado aqui?”. Essa mentalidade faz toda a diferença. Muitos problemas são sutis, e se não forem detectados logo no início podem contaminar a análise inteira — sem que você perceba.

Uma das verificações iniciais é a **contagem de valores faltantes**. Com uma linha de código como:

```
df.isnull().sum()
```

Já conseguimos descobrir quais colunas estão incompletas e o quanto isso afeta o dataset. Se uma variável crítica tem 40% de valores ausentes, isso muda completamente nossa estratégia. Talvez precisemos buscar uma fonte de dados extra. Talvez a ausência tenha significado importante. Talvez tenhamos que descartar aquela variável. Cada caso exigirá interpretação.

A seguir, analisamos **duplicidades**. Um registro duplicado pode parecer inofensivo, mas imagine duas linhas representando a mesma internação em um

hospital: isso pode dobrar custos, taxas de mortalidade ou indicadores clínicos. Com `df.duplicated().sum()`, rapidamente encontramos esse tipo de distorção.

Outro ponto essencial é verificar **coerência de valores**. Uma pessoa com 156 anos? Uma compra registrada com valor negativo? Uma data de nascimento em 2078? Essas situações não são raras — especialmente em bases preenchidas manualmente ou integradas de diferentes sistemas. É papel do(a) cientista de dados identificar valores que desafiam a lógica e investigar se são erros de digitação, falhas de processamento ou exceções que realmente fazem parte da realidade (GRUS, 2021).

Também é comum encontrar inconsistências de padronização, principalmente em dados categóricos: “SP”, “São Paulo”, “SaoPaulo”, “sp”, “Sp”...

Todos representam a mesma coisa, mas o Python não sabe disso até que você ajuste. A análise inicial ainda pode incluir:

- Contagem de categorias únicas (para ver se há ruídos);
- Verificação de limites numéricos (mínimos e máximos);
- Análise rápida de distribuição (para flagrar valores improváveis);
- Conferência do tipo das variáveis (object, float, int, datetime...).

Esses pequenos diagnósticos estruturam a visão inicial do dataset. Quanto mais cedo identificamos problemas, menos tempo desperdiçamos corrigindo análises futuras.

Ao final dessa etapa, o(a) cientista de dados tem uma noção clara da **saúde geral do dataset**. Ele sabe onde estão os pontos frágeis, os cuidados necessários e o que pode comprometer a confiabilidade da investigação.

Faltantes, duplicados e outliers: os vilões clássicos

Alguns problemas aparecem em praticamente todo dataset e que podem prejudicar bastante qualquer conclusão se não forem identificados a tempo. Um dos mais comuns são os dados faltantes. Antes de querer preenchê-los, precisamos entender por que eles não estão ali. Podemos começar avaliando quantos faltam em cada coluna:

```
df.isnull().sum()
```

Código-fonte 1 – Python
Fonte: Elaborado pelo autor (2025)

Essa linha simples já pode revelar que uma coluna crucial possui tantos valores ausentes que talvez precise ser removida ou substituída por outra fonte mais confiável. Por outro lado, a ausência também pode ser informativa: um paciente sem resultado de exame pode indicar que ele não precisou fazê-lo, e isso é um dado importante.

Registros duplicados também merecem atenção. Muitas vezes eles surgem por erros no processo de coleta e podem distorcer métricas. Felizmente, identificar esse problema é fácil:

```
df.duplicated().sum()
```

Código-fonte 2 – Python
Fonte: Elaborado pelo autor (2025)

Caso encontremos duplicidades, podemos removê-las com:

```
df.drop_duplicates(inplace=True)
```

Código-fonte 3 – Python
Fonte: Elaborado pelo autor (2025)

Mas, mais uma vez, antes de apagar qualquer coisa, precisamos avaliar o impacto da remoção.

Já os outliers — aqueles valores que fogem do padrão — exigem cuidado redobrado. Eles podem revelar erros absurdos (como peso igual a 800 kg), mas também podem representar eventos raros extremamente relevantes. Uma forma rápida de identificá-los é olhando estatísticas descritivas:

```
df.describe()
```

Código-fonte 4 – Python
Fonte: Elaborado pelo autor (2025)

Se a coluna mostra um mínimo ou máximo fora da realidade conhecida, investigamos antes de tomar qualquer decisão. Em resumo, esses três problemas precisam ser analisados com atenção e sempre com senso crítico.

Decidindo o que fazer com os erros

Após identificar os problemas, o(a) cientista de dados precisa decidir como tratá-los. Essa etapa exige sensibilidade e conhecimento do domínio. Às vezes, remover um registro pode ser a escolha mais segura. Outras vezes, preencher valores ausentes com uma mediana ou uma categoria “Não informado” faz mais sentido.

Exemplo de imputação simples para valores faltantes numéricos:

```
df['idade'] = df['idade'].fillna(df['idade'].median())
```

Código-fonte 5 – Python
Fonte: Elaborado pelo autor (2025)

Ou, se a coluna for categórica:

```
df['categoria'] = df['categoria'].fillna('Indefinido')
```

Código-fonte 6 – Python
Fonte: Elaborado pelo autor (2025)

Nada disso deve ser feito de forma automática ou padronizada. Cada escolha precisa ser justificada com base no que se sabe sobre o fenômeno. O pior erro que podemos cometer é “embelezar” os dados e criar uma falsa sensação de qualidade.

Assim como na medicina, o tratamento aplicado depende do diagnóstico correto. Documentar cada alteração feita é fundamental para garantir rastreabilidade e transparência. Sem isso, qualquer modelo ou insight que surgirem depois podem ser questionados — com razão.

O olhar crítico do(a) Cientista de Dados

Ferramentas como Python nos ajudam a tomar decisões melhores, mas a verdadeira qualidade do trabalho está na mente analítica por trás das teclas. Validar qualidade dos dados exige curiosidade, conhecimento de negócio e a habilidade de identificar algo fora do lugar — mesmo quando todos os números parecem “normais” (GRUS, 2021).

Uma prática simples de verificação estrutural pode revelar surpresas:

```
df.info()
```

Código-fonte 7 – Python
Fonte: Elaborado pelo autor (2025)

Esse comando mostra quantas linhas existem, tipos das variáveis e se há problemas óbvios já na estrutura do dataset. Muitas análises que deram errado poderiam ter sido evitadas com essa pequena primeira investigação.

No fim das contas, a missão do(a) Cientista de Dados é garantir que qualquer descoberta esteja apoiada em dados que representem a realidade da forma mais fiel possível. A avaliação de qualidade não é uma etapa burocrática, e sim o primeiro grande ato científico da análise. A ciência começa quando deixamos de acreditar em tudo que vemos — e passamos a verificar.

Estatísticas descritivas e exploração inicial dos dados

Entender a qualidade dos dados já nos dá segurança para seguir em frente. Agora, entramos em uma etapa em que começamos a enxergar o comportamento do dataset como um todo. Queremos descobrir não apenas se os dados estão corretos, mas como eles se distribuem, como variam, quais padrões apresentam e o que já podemos antecipar sobre o fenômeno estudado antes mesmo de construir gráficos mais complexos (GRUS, 2021).

Essa etapa marca o início de uma investigação mais rica. Ao examinar estatísticas simples — como médias, medianas, frequências e intervalos — já

conseguimos identificar tendências e relações iniciais que guiarão os próximos passos do EDA.

Como começar a explorar o dataset

Mesmo antes de mergulhar nas análises estatísticas, vale fazer um primeiro reconhecimento geral do terreno. Um comando muito importante em Python é:

```
df.info()
```

Código-fonte 8 – Python
Fonte: Elaborado pelo autor (2025)

Ele nos mostra quantas linhas e colunas existem, quais os tipos de dados e se há algum problema estrutural que passou despercebido. Em seguida, observamos os primeiros registros para sentir o formato das variáveis:

```
df.head()
```

Código-fonte 9 – Python
Fonte: Elaborado pelo autor (2025)

Esses dois comandos simples já ajudam a construir uma visão mental do dataset. Não estamos procurando insights profundos ainda — apenas nos familiarizando com os dados.

Estatísticas descritivas: uma visão panorâmica

A análise descritiva serve para entendermos como os valores se comportam. O pandas facilita isso com:

```
df.describe()
```

Código-fonte 10 – Python
Fonte: Elaborado pelo autor (2025)

Esse comando entrega estatísticas básicas como mínimo, máximo, média, mediana, desvio padrão e quartis. Um desvio padrão muito alto, por exemplo, pode indicar que a variável possui grandes variações, possivelmente por causa de grupos com comportamentos distintos (GRUS, 2021).

Com essa primeira leitura, perguntas já começam a surgir:

- A distribuição é muito assimétrica?
- Existem grupos com características extremas?
- Esse valor mínimo faz sentido no contexto do negócio?

Só de observar essa tabela de resumo, podemos detectar padrões importantes — como a idade média de clientes, o valor típico de uma compra, ou o quanto vendas variam entre períodos.

Conhecendo a distribuição das variáveis

Depois das estatísticas iniciais, queremos entender como os valores se espalham. Uma coisa é saber que a média de idade é 45 anos; outra bem diferente é saber se a maioria realmente está perto de 45 ou se existem muitos casos muito abaixo ou acima disso.

Podemos visualizar rapidamente essa distribuição com um histograma:

- `import matplotlib.pyplot as plt`
- `df['idade'].hist(bins=20)`
- `plt.show()`

Esse simples gráfico já pode revelar se os dados são concentrados em um intervalo específico, se há assimetrias, caudas longas ou agrupamentos inesperados. Quando analisamos, por exemplo, a duração de internações ou os valores de compras, essas formas podem indicar perfis distintos que merecem ser explorados com mais profundidade.

Frequência e análise de valores únicos

As variáveis categóricas também precisam ser exploradas. Saber quantas vezes cada categoria aparece nos dá pistas imediatas sobre o comportamento do dataset. Em Python, é assim:

```
df['categoria_produto'].value_counts()
```

Código-fonte 11 – Python
Fonte: Elaborado pelo autor (2025)

Se uma categoria aparece muito pouco, talvez ela represente um nicho interessante — ou apenas um erro de registro. Se uma categoria domina os dados, precisamos ter cuidado para não deixar que ela “puxe” todas as conclusões. Essa etapa ajuda a identificar desequilíbrios, gaps e grupos que precisam ser analisados separadamente mais adiante (GRUS, 2021).

Já começamos a enxergar padrões

A partir dessas primeiras análises, algumas perguntas já começam a se formar:

- Por que alguns valores parecem muito dispersos?
- Por que apenas um pequeno grupo comprou tal produto?
- Há diferenças claras entre faixas específicas?

Essas perguntas são essenciais para o papel do(a) Cientista de Dados.

Antes mesmo de cruzar variáveis, já abrimos um leque de hipóteses iniciais que vão guiar o restante da exploração.

Podemos, por exemplo, agrupar as estatísticas por segmento de cliente:

```
df.groupby('segmento')['valor_compra'].describe()
```

Código-fonte 12 – Python
Fonte: Elaborado pelo autor (2025)

Assim descobrimos que um grupo compra bem mais do que outro, ou que um deles apresenta variação muito maior. Esses sinais começam a contar a história do dataset — e cabe a nós interpretá-los.

Relação entre variáveis e descoberta de padrões

Até aqui, analisamos cada variável separadamente para entender seu comportamento, sua distribuição e qualidade. Mas dados raramente contam histórias completas quando vistos individualmente. O que realmente nos permite descobrir padrões mais ricos é observar como as variáveis se relacionam umas com as outras. É nessa etapa do EDA que começamos a investigar possíveis mecanismos, influências e comportamentos conjuntos dentro do dataset.

Por exemplo: será que clientes mais jovens compram produtos diferentes dos mais velhos? Pacientes com maior tempo de internação têm custos muito elevados? Será que uma variável ajuda a explicar algo inesperado que vimos na análise descritiva? Agora, deixamos de olhar os dados como peças isoladas e começamos a montar o quebra-cabeça.

Relações entre variáveis numéricas

Quando temos duas variáveis numéricas — como valor de compra e número de itens, ou tempo de internação e idade — a primeira análise visual que costuma ser feita é o gráfico de dispersão. Ele mostra como os dados se distribuem em relação a dois eixos:

```
df.plot.scatter(x='idade', y='valor_compra')
```

Código-fonte 13 – Python
Fonte: Elaborado pelo autor (2025)

Muitas vezes, apenas olhando esse gráfico já percebemos se existe uma tendência geral: quando uma variável aumenta, a outra aumenta também? Ou será que não têm qualquer conexão aparente? Nem toda relação é linear — e às vezes a falta de padrão é a descoberta mais importante.

Para complementar, calculamos a correlação, que expressa numericamente o grau de associação entre as variáveis:

```
df[['idade', 'valor_compra']].corr()
```

Código-fonte 14 – Python
Fonte: Elaborado pelo autor (2025)

Quando encontramos uma correlação forte, isso pode indicar uma hipótese interessante para investigar mais a fundo. Mas é sempre importante lembrar: correlação não significa causalidade. Uma variável pode acompanhar outra simplesmente porque ambas dependem de um terceiro fator que não conhecemos ainda (GRUS, 2021).

Relações entre variáveis categóricas

Variáveis categóricas exigem outro tipo de abordagem. Em vez de tendências numéricas, estamos interessados em frequências e proporções. Uma forma simples de começar é observar quantos registros existem em cada combinação de categorias:

```
pd.crosstab(df['segmento'], df['produto'])
```

Código-fonte 15 – Python
Fonte: Elaborado pelo autor (2025)

Esse cruzamento já pode revelar que um grupo de clientes tende a usar mais um determinado produto, enquanto outro grupo prefere opções diferentes. Se estamos trabalhando com saúde, uma análise cruzada entre tipo de atendimento e desfecho pode mostrar quais procedimentos têm maior chance de internação ou retorno ao hospital.

Quando visualizamos essa relação em gráficos de barras segmentadas, fica ainda mais claro se existe concentração ou dispersão entre os grupos. Pequenos detalhes podem melhorar muito essa interpretação; muitas vezes, a diferença está justamente nas categorias menos frequentes.

Relações entre numéricas e categóricas

Quando cruzamos uma variável numérica com uma categórica, buscamos entender se grupos diferentes apresentam comportamentos também diferentes. Um exemplo simples é verificar se clientes de segmentos distintos compram valores muito diferentes entre si:

```
df.boxplot(column='valor_compra', by='segmento')
```

Código-fonte 16 – Python
Fonte: Elaborado pelo autor (2025)

Os boxplots ajudam a observar mediana, variação e presença de outliers dentro de cada grupo. Essa comparação inicial pode identificar onde está concentrada a maior parte do faturamento e quais grupos apresentam maior variabilidade no consumo. Em um contexto hospitalar, isso pode mostrar quais perfis de pacientes geram maior ocupação ou custos mais elevados.

Essa análise é uma das principais portas de entrada para hipóteses futuras, porque ao notar diferenças significativas entre grupos, automaticamente nos perguntamos:

Por que essa diferença existe? Qual o fator explicativo?

Começam a surgir histórias

O objetivo aqui não é provar nada ainda — é descobrir possibilidades. Relações encontradas nessa etapa servem como pistas, direcionando o olhar investigativo para fenômenos mais ricos. Podemos encontrar:

- Variáveis que parecem estar diretamente ligadas;
- Grupos com comportamento inesperado;
- Associações fortes que exigem validação posterior;
- Padrões que ajudam a explicar resultados do negócio.

E é justamente esse despertar de novas perguntas que mostra que a análise está ganhando profundidade.

O dataset começa a revelar sua lógica interna — e revelar também aquilo que ainda não conseguimos enxergar.

A partir desse ponto, cada insight deve ser encarado como uma hipótese preliminar: **“Será que isso realmente influencia aquilo? Ou é apenas coincidência?”**

O(a) bom(a) cientista se emociona com as pistas, mas só toma decisões após comprovar.

Visualização exploratória dos dados

Datasets grandes podem enganar. Muitas vezes, olhando apenas estatísticas ou tabelas, não percebemos relações importantes que estão ali o tempo todo. O olhar humano é extremamente eficiente para reconhecer padrões visuais, e por isso os gráficos se tornam ferramentas fundamentais durante o EDA — não para “embelezar” a análise, mas para revelar informações que números sozinhos não mostram (GRUS, 2021).

Na visualização exploratória, buscamos clareza e compreensão. Não estamos produzindo dashboards ainda, nem apresentações para diretoria. O objetivo aqui é enxergar o que está realmente acontecendo dentro dos dados, mesmo que ainda seja de forma bruta — para confirmar suspeitas ou descobrir detalhes que estavam invisíveis.

Visualizar é investigar

Um ótimo ponto de partida são os gráficos de distribuição, que mostram como os valores se espalham dentro de uma variável. Um histograma pode indicar se precisamos segmentar a análise:

```
df['idade'].hist(bins=20)
```

Código-fonte 17 – Python
Fonte: Elaborado pelo autor (2025)

Quando vemos uma curva mais concentrada, sabemos que aquele grupo domina a amostra. Quando a distribuição é muito aberta ou assimétrica, já imaginamos que podem existir diversos perfis escondidos dentro da mesma variável.

Outra ferramenta útil nesse início é o boxplot, que mostra variação e possíveis outliers com rapidez:

- `import seaborn as sns`
- `sns.boxplot(x=df['valor_compra'])`

Esse simples gráfico pode revelar que uma parte dos clientes compra valores muito superiores à média — e que isso merece uma investigação específica.

Visualizando relações entre duas variáveis

A visão conjunta de duas variáveis pode transformar completamente nossa percepção dos dados. Um scatter plot (gráfico de dispersão) ajuda a ver tendências ou agrupamentos:

```
sns.scatterplot(data=df, x='idade', y='valor_compra')
```

Código-fonte 18 – Python
Fonte: Elaborado pelo autor (2025)

Mesmo que a correlação seja fraca no cálculo numérico, visualmente podemos identificar padrões não lineares, clusters de comportamento ou mesmo problemas: valores estranhos, escalas diferentes ou pontos claramente errados.

Se uma variável for categórica, migramos para algo como o boxplot segmentado:

```
sns.boxplot(data=df, x='segmento', y='valor_compra')
```

Código-fonte 19 – Python
Fonte: Elaborado pelo autor (2025)

Essas comparações entre grupos enriquecem muito a interpretação e começam a direcionar hipóteses mais específicas.

Explorando múltiplas variáveis ao mesmo tempo

Quando queremos observar a relação entre várias variáveis numéricas simultaneamente, uma boa alternativa é o heatmap de correlação:

```
sns.heatmap(df.corr(), annot=True)
```

Código-fonte 20 – Python
Fonte: Elaborado pelo autor (2025)

Ele permite identificar blocos de variáveis que se movimentam juntas e direcionar o olhar para possíveis fatores explicativos do fenômeno estudado. Esse tipo de visualização é especialmente útil quando estamos tentando encontrar variáveis-chave para modelos futuros.

Para entender várias relações de uma só vez, podemos também usar o pairplot, que mostra vários gráficos de dispersão automaticamente:

```
sns.pairplot(df[['idade', 'valor_compra', 'tempo_cadastro']])
```

Código-fonte 21 – Python
Fonte: Elaborado pelo autor (2025)

Assim, em uma única figura, já temos uma visão ampla de como diferentes dimensões do dataset interagem entre si.

Quando o gráfico muda a história

Visualizações têm o poder de revelar comportamentos que passariam despercebidos olhando apenas tabelas. Por exemplo: duas categorias podem aparentar ter médias semelhantes em um resumo estatístico, mas ao visualizar a distribuição percebemos que uma tem grande concentração em torno de um valor, enquanto a outra é muito mais espalhada. Isso altera completamente nossa interpretação sobre os dois grupos (DUARTE, 2021).

Às vezes, é um gráfico que revela um problema grave na base: dados desalinhados no tempo, valores duplicados em ondas, clusters inesperados que podem representar erros de registro. Um único scatter plot pode salvar semanas de trabalho ao expor algo que não fazia sentido.

Por isso, visualizar é também questionar, validar suposições e descobrir o que ainda não sabíamos que existia.

O papel do(a) cientista de dados nesta etapa

O gráfico é apenas a janela; quem observa é o(a) cientista. Interpretar visualizações requer perguntar constantemente:

- O que esse padrão está me dizendo?
- Por que estou vendo esse comportamento?
- Há algo que contradiz o esperado?

Acima de tudo, a visão crítica continua presente: não é porque algo parece estar relacionado que realmente está. A visualização exploratória não encerra a análise — ela a direciona.

É quando os dados saem da abstração e começam a ganhar forma.

Registro das descobertas e hipóteses

Depois de explorar os dados sob diferentes perspectivas — avaliando qualidade, analisando distribuições, identificando possíveis relações e visualizando padrões — chegamos a um momento decisivo: registrar tudo o que aprendemos até agora. E não apenas como anotações soltas, mas como um conjunto de conclusões provisórias e hipóteses que orientarão as próximas análises (DUARTE, 2021).

Essa documentação não é uma formalidade. Ela é o elo que conecta a investigação exploratória com qualquer análise futura, seja teste de hipótese, modelagem preditiva ou tomada de decisão no negócio. Sem esse registro, corremos o risco de esquecer descobertas valiosas ou, pior, repetir caminhos já percorridos.

Por que registrar tudo?

O EDA é cheio de insights rápidos e, às vezes, surpreendentes. Mas o que parece óbvio no momento pode se perder no meio de tantas análises. Por isso, o registro serve para:

- Garantir que observações relevantes não desapareçam;
- Definir o que já é conhecido e o que ainda precisa ser investigado;
- Ter material concreto para apresentar ao time ou stakeholders;
- Criar uma linha lógica de raciocínio que guia a investigação.

Quando documentamos, estamos dizendo: “Aqui começam as teorias que vamos colocar à prova.”.

Formulando hipóteses iniciais

Uma hipótese nasce quando identificamos um padrão que pode ter uma explicação. Não é certeza — é o início de uma pergunta melhor estruturada.

Exemplos:

- Clientes mais antigos parecem ter maior ticket médio;
- Pacientes com maior tempo de permanência têm maior uso de antibióticos;
- Segmento X apresenta mais devoluções que os demais;
- Determinados produtos vendem muito mais em épocas específicas do ano.

Podemos registrar hipóteses com pequenas evidências visuais ou estatísticas, como:

```
df.groupby('segmento')['valor_compra'].median()
```

Código-fonte 22 – Python
Fonte: Elaborado pelo autor (2025)

Esses resultados iniciais reforçam que a hipótese tem algo ali que merece ser estudado com mais rigor depois, usando técnicas adequadas.

Estruturando as descobertas

O registro não precisa ser complexo. Um formato simples já organiza muito bem o raciocínio:

- Observação: o que vimos?
- Evidência: o que demonstrou isso?
- Hipótese associada: o que isso pode significar?
- Próximos passos: o que precisamos investigar melhor?

Exemplo aplicado:

- Observação
 - O segmento “Premium” apresenta valor médio de compra consideravelmente mais alto.
- Evidência
 - `df.groupby('segmento')['valor_compra'].mean()` mostra diferença de dois dígitos entre Premium e outros segmentos.
- Hipótese
 - O ticket maior pode estar relacionado ao número de itens ou categorias mais caras.
- Próximo passo
 - Investigar categorias compradas e frequência de compras por segmento.

Esse tipo de síntese cria clareza e direciona esforço analítico.

Comunicação científica é parte da ciência

Comunicar bem faz parte da própria essência do trabalho de cientistas de dados. Não adianta encontrar insights valiosos se ninguém consegue entender ou

usar essas descobertas para tomar decisões. O EDA não é apenas uma etapa técnica: ele é também uma etapa de interpretação e de explicação (DUARTE, 2021).

Quando registramos o que descobrimos, precisamos garantir que alguém de fora do processo consiga compreender o raciocínio do início ao fim. Isso inclui não apenas o resultado, mas também o que nos levou até ele: qual era a pergunta original, o que vimos nos dados e por que aquilo chamou atenção. Comunicação científica é justamente transformar uma observação pontual em uma peça de conhecimento que pode ser discutida, criticada, melhorada e levada adiante.

Além disso, compartilhar achados preliminares durante o EDA ajuda a alinhar expectativas com o time e com as áreas de negócio envolvidas. Ao comunicar um insight inicial, abrimos espaço para que especialistas validem se aquilo faz sentido na prática. Uma descoberta pode parecer excelente do ponto de vista analítico, mas totalmente irrelevante para o problema real — e quanto antes esse desalinhamento aparecer, melhor para o projeto.

Por isso, um(a) Cientista de dados precisa sempre se perguntar:

- O que acabei de encontrar é compreensível? É relevante? Está bem contextualizado?

Documentar pensamentos, hipóteses e evidências de forma clara cria uma trilha lógica do processo. Se alguém precisar continuar o trabalho, estará em condição de entender o que foi feito e qual direção seguir. Essa organização não é apenas boa prática: é uma exigência de ciência. Afinal, se o conhecimento não pode ser comunicado, ele nunca se torna realmente conhecimento (DUARTE, 2021).

MERCADO, CASES E TENDÊNCIAS

Recomendamos a leitura do livro “Storytelling com Dados”, de Cole Nussbaumer Knafllic (2019), que reforça a importância da comunicação eficaz dos resultados, explorando técnicas visuais e narrativas para engajar tomadores de decisão.



O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você aprendeu que a Análise Exploratória de Dados (EDA) é o primeiro passo essencial de qualquer investigação em Data Science. Mais do que carregar uma base no Python e começar a rodar modelos, o cientista de dados precisa entender profundamente o que está analisando: quem são os registros, que contexto está representado, qual parte da realidade ficou de fora e quais limitações podem distorcer as conclusões. Essa consciência inicial transforma simples dados em uma peça confiável de conhecimento.

Você também percebeu que o EDA é uma jornada investigativa: começamos entendendo a estrutura do dataset, analisando o significado de cada variável e verificando a qualidade dos registros. Depois, exploramos o comportamento dos dados com estatísticas descritivas, estudamos distribuições, comparamos grupos e visualizamos relações entre variáveis para revelar padrões que antes estavam escondidos. Cada gráfico e cada número ajudam a construir uma narrativa que começa a explicar o fenômeno estudado.

Por fim, vimos que a análise só se torna ciência quando é bem comunicada: registrar descobertas, hipóteses e raciocínios garante continuidade, alinhamento e decisões mais assertivas. Ao longo do EDA, não buscamos respostas definitivas, mas sim perguntas melhores — e são essas perguntas que direcionam as próximas etapas do projeto, como testes estatísticos ou construção de modelos de machine learning. A partir de agora, você não interpreta dados apenas como um operador de ferramentas, mas como um Cientista de Dados: alguém capaz de investigar, questionar e compreender a realidade que os dados tentam representar.

REFERÊNCIAS

PROVOST, F; FAWCETT, T. **Data Science Para Negócios**. Rio de Janeiro: Alta Books, 2016. 408 p.

DUARTE, N. **Data Story: Explique Dados e Inspire Ações Por Meio de Histórias**. Rio de Janeiro: Alta Books, 2021. 316 p.

GRUS, J. **Data Science do Zero: Noções Fundamentais com Python**. 2. ed. Rio de Janeiro: Alta Books, 2021. 336 p.

EMANIP

PALAVRAS-CHAVE

Dados. Exploração de Dados. Estatística.

EMAP



POSTECH