

AI SCIENTIST

FASE 1 | AULA 03 -

COMO REPRESENTAR AS INFORMAÇÕES COM OS MELHORES GRÁFICOS

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
MERCADO, CASES E TENDÊNCIAS	20
O QUE VOCÊ VIU NESTA AULA?	21
REFERÊNCIAS.....	22

EMANIP

O QUE VEM POR AÍ?

Nesta aula, vamos além da ideia de que visualização é apenas a fase "bonita" da análise de dados. Você vai entender como gráficos se tornam ferramentas de investigação, como ajudam a formular e testar hipóteses e como podem distorcer conclusões quando mal construídos. O objetivo é formar o olhar do(a) cientista de dados que não apenas escolhe gráficos corretos, mas constrói visualizações que sustentam decisões reais, conectadas ao contexto de negócio e ao método científico.

Ao longo desta aula, vamos discutir o papel da visualização dentro do fluxo analítico, a importância de compreender os dados antes de representá-los, quais famílias de gráficos melhor respondem cada tipo de pergunta e quais práticas garantem clareza, honestidade e impacto. Também veremos erros comuns que comprometem análises, o processo de transformar dados em insight visual e ferramentas práticas em Python para implementar essas ideias. Ao final, você estará pronto(a) para representar informações de maneira crítica, responsável e estratégica.

Vamos nessa?

HANDS ON

Vamos explorar o IDHM (Índice de Desenvolvimento Humano Municipal) sob a ótica da visualização de dados. A proposta é transformar indicadores em representações gráficas que revelem histórias sobre o desenvolvimento social no Brasil.

Começaremos carregando a base no Python e realizando um breve diagnóstico visual da estrutura dos dados — identificando colunas, tipos de variáveis, períodos e dimensões geográficas. Em seguida, construiremos as primeiras visualizações exploratórias, usando histogramas, boxplots e gráficos de dispersão para entender a distribuição e o comportamento das dimensões Educação, Longevidade e Renda.

Nosso objetivo será investigar visualmente como o IDHM se comporta entre diferentes regiões e ao longo do tempo, buscando padrões e contrastes. Vamos aprender a representar desigualdades regionais com mapas temáticos, comparar médias e medianas de indicadores entre estados e identificar municípios que destoam do padrão. Além disso, criaremos gráficos de correlação e heatmaps para descobrir relações entre variáveis — por exemplo, se municípios com alto índice de educação também apresentam altos valores de renda e longevidade. Cada gráfico será uma hipótese visual e um ponto de partida para pensar o desenvolvimento humano com base em evidências.

Por fim, consolidaremos os resultados em um pequeno painel analítico, reunindo as visualizações mais significativas e suas interpretações. A ideia é exercitar o olhar crítico sobre o que cada gráfico realmente comunica — evitando distorções e destacando insights que possam apoiar políticas públicas ou análises sociais. Mais do que gerar imagens bonitas, o desafio aqui é construir visualizações que expliquem o Brasil em cores, formas e contextos.

SAIBA MAIS

Papel da visualização na ciência de dados

A visualização de dados não é um adorno que entra no final do projeto para deixar o resultado apresentável. Ela é parte central do processo de pensar com dados. Cada gráfico funciona como uma lente que revela padrões, tendências, quebras de comportamento e anomalias que dificilmente seriam percebidos em uma tabela numérica bruta. Quando a pessoa cientista de dados observa um gráfico, ela não está apenas vendo formas e cores, mas testando hipóteses sobre o fenômeno representado (STRACHNYI,2023).

Em muitos projetos, os primeiros insights relevantes aparecem a partir de uma simples visualização: uma curva que não segue o padrão esperado, uma concentração inesperada de casos em determinado grupo, um cluster distinto em um scatter plot. Esses sinais visuais acionam perguntas melhores: por que isso acontece aqui e não ali? O que mudou neste período? Existe um erro na base ou um comportamento real do sistema? Visualizar é, portanto, uma forma de investigar. É a etapa em que o(a) cientista confronta narrativas, válidas percepções iniciais e abre caminho para análises mais profundas.

Além do papel exploratório, a visualização também é uma poderosa ferramenta de comunicação. Decisores raramente têm tempo para percorrer extensas tabelas ou interpretar métricas complexas sem apoio visual. Um gráfico bem construído sintetiza evidências, torna explícitas relações importantes e facilita a tomada de decisão. Mas isso só acontece quando a visualização é honesta, clara e alinhada à pergunta central do problema. O(a) cientista de dados profissional domina essa dualidade: usa gráficos para descobrir e para comunicar (DUARTE, 2021).

Entendendo os dados antes de escolher o gráfico

Nenhum gráfico é neutro. Toda visualização é uma escolha sobre o que destacar, o que comparar e o que deixar em segundo plano. Antes de decidir entre barras, linhas, dispersões ou mapas, a pessoa cientista de dados precisa compreender profundamente o que está sendo representado. Isso começa pela leitura

cuidadosa do dataset: quais são as variáveis disponíveis, em que unidade estão medidas, qual é a granularidade dos registros e que parte da realidade foi capturada ali (DUARTE, 2021).

Ao analisar o conjunto de dados, é fundamental identificar o tipo de cada variável e suas implicações visuais. Variáveis numéricas contínuas, como renda ou tempo, pedem abordagens diferentes de variáveis categóricas, como estado civil ou segmento de cliente. Variáveis ordinais carregam uma hierarquia implícita que não pode ser ignorada na visualização. Datas e séries temporais exigem cuidado com periodicidade, sazonalidade e lacunas. Cada escolha incorreta de gráfico aumenta o risco de interpretações erradas.

Outro ponto-chave é a granularidade. Não é o mesmo representar cada transação individual ou a soma por mês; cada recorte responde a perguntas diferentes. Visualizar dados hiperagregados pode esconder desigualdades importantes. Por outro lado, mostrar cada ponto sem síntese pode criar ruído e impedir conclusões. O papel do(a) cientista é encontrar o nível adequado para a pergunta do negócio (GRUS, 2021).

Assim, antes de abrir qualquer biblioteca de visualização, voltamos à pergunta essencial: "O que eu quero entender ou demonstrar com este gráfico?". A resposta a essa pergunta orienta a escolha do tipo de gráfico, do recorte, da escala e do destaque visual. Visualizar com responsabilidade começa muito antes do primeiro eixo ser desenhado (GRUS, 2021).

Melhores gráficos por tipo de problema analítico

Escolher o gráfico certo é como escolher a lente certa para observar o mundo: cada visualização destaca um aspecto específico da realidade. Em Ciência de Dados, essa decisão não é estética — é científica. A forma como representamos os dados pode revelar padrões escondidos ou, ao contrário, mascarar relações importantes. Por isso, o(a) cientista precisa dominar o raciocínio por trás de cada tipo de gráfico e entender qual pergunta ele responde melhor (KNAFLIC, 2019).

O primeiro passo é reconhecer que todo gráfico é uma resposta visual a uma pergunta analítica. Quando queremos comparar grupos, a pergunta é "quem é maior

ou menor?”. Quando queremos entender a variação de uma variável, perguntamos “como esses valores se distribuem?”. Já quando queremos explorar relações entre variáveis, buscamos responder “há conexão entre elas?”. O tipo de gráfico é, portanto, consequência direta da natureza da pergunta.

No bloco de código, vou deixar uma base de dados fictícia para que vocês consigam ter um conjunto de dados para aplicar nos gráficos abaixo.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

np.random.seed(42)

n = 1000

df = pd.DataFrame({
    # Idade inteira entre 18 e 70 anos (distribuição normal)
    "idade": np.random.normal(35, 10, n).clip(18, 70).round().astype(int),

    # Renda mensal com duas casas decimais
    "renda_mensal": np.random.normal(5000, 2000, n).clip(800, 20000).round(2),

    # Score com duas casas decimais
    "score": np.random.normal(650, 80, n).clip(300, 900).round(2),

    # Variáveis categóricas
    "segmento": np.random.choice(["Clássico", "Gold", "Premium"], size=n, p=[0.5, 0.3, 0.2]),
    "regiao": np.random.choice(["Sul", "Sudeste", "Centro-Oeste", "Nordeste", "Norte"], size=n),
})

# Gasto mensal proporcional à renda (mantendo 2 casas)
df["gasto_mensal"] = (df["renda_mensal"] * np.random.uniform(0.2, 0.6, n)).round(2)

# Datas mensais fictícias
df["mes"] = np.random.choice(pd.date_range("2023-01-01", "2023-12-31", freq="MS"), size=n)

# Ajuste visual para gráficos
sns.set(style="whitegrid")
```

```
plt.rcParams["figure.figsize"] = (8, 5)

df.head()
```

Código-fonte 1 – Criando um dataset genérico em Python
Fonte: Elaborado pelo autor (2025)

	idade	renda_mensal	score	segmento	regiao	gasto_mensal	mes
0	40	7798.71	595.99	Premium	Centro-Oeste	4237.29	2023-01-01
1	34	6849.27	638.44	Premium	Sudeste	2640.04	2023-11-01
2	41	5119.26	586.61	Clássico	Norte	2629.81	2023-01-01
3	50	3706.13	625.36	Premium	Sul	2144.93	2023-05-01
4	33	6396.45	498.51	Clássico	Nordeste	1983.33	2023-10-01

Figura 1 – Imagem do dataset genérico
Fonte: elaborado pelo autor (2025)

Comparações: quem se destaca

As comparações são o tipo mais comum de análise — afinal, o ser humano entende o mundo comparando. Queremos saber qual produto vende mais, qual região apresenta maior crescimento ou qual grupo performa melhor em determinado indicador. Para isso, recorremos a gráficos de barras, verticais ou horizontais, que traduzem quantidades em alturas ou comprimentos facilmente perceptíveis. (KNAFLIC, 2019)

Quando as categorias têm nomes longos ou são muitas, barras horizontais facilitam a leitura. Já quando queremos mostrar variação ao longo do tempo, as barras verticais se encaixam melhor. Em contextos mais analíticos, o boxplot ganha destaque: ele mostra não apenas a média, mas também a dispersão, a mediana e os outliers — permitindo identificar desigualdades ou comportamentos extremos dentro dos grupos. Um(a) cientista atento percebe que cada barra e cada linha contam uma história sobre variação e consistência, não apenas sobre valores absolutos.

```
plt.figure()
df_segmento=
df.groupby("segmento")["gasto_mensal"].mean().sort_values()

sns.barplot(
    x=df_segmento.index,
```



```
y=df_segmento.values  
)  
  
plt.title("Gasto mensal médio por segmento")  
plt.xlabel("Segmento")  
plt.ylabel("Gasto mensal médio (R$) ")  
plt.tight_layout()  
plt.show()
```

Código-fonte 2 – Gráfico de Comparação (Barra)

Fonte: Elaborado pelo autor (2025)




Figura 2 – Gráfico de Comparação (Barra)

Fonte: Elaborado pelo autor (2025)

```
plt.figure()  
sns.boxplot(data=df, x="segmento", y="renda_mensal")  
plt.title("Renda mensal por segmento")  
plt.xlabel("Segmento")  
plt.ylabel("Renda mensal (R$) ")  
plt.tight_layout()  
plt.show()
```

Código-fonte 3 – Gráfico de Comparação (Boxplot)

Fonte: Elaborado pelo autor (2025)




Figura 3 – Gráfico de Comparação (Boxplot)
Fonte: Elaborado pelo autor (2025)

Distribuição: o retrato do comportamento

Entender a distribuição de uma variável é como observar o terreno antes de caminhar por ele. O histograma é a ferramenta clássica para isso: ele mostra como os valores se espalham, onde se concentram e quais faixas apresentam maior ou menor frequência. Essa simples visualização já pode revelar muito — desde dados enviesados até a presença de múltiplos grupos escondidos na mesma variável.

Quando buscamos uma visão mais suave, usamos o gráfico de densidade (KDE), que desenha uma curva contínua sobre o histograma, facilitando a comparação entre diferentes grupos. Já o violin plot combina o melhor dos dois mundos: mostra a densidade e, ao mesmo tempo, as estatísticas descritivas. Ele é especialmente útil quando queremos entender a distribuição completa de diferentes categorias, revelando padrões que médias sozinhas jamais mostrariam (KNAFLIC, 2019).

O olhar da pessoa cientista, nesse momento, deve ser investigativo: um histograma assimétrico pode indicar concentração de renda; uma cauda longa pode

sugerir desigualdade; uma distribuição bimodal pode esconder dois comportamentos distintos em um mesmo conjunto.

```
plt.figure()
sns.histplot(df["renda_mensal"], bins=30, kde=True)
plt.title("Distribuição da renda mensal")
plt.xlabel("Renda mensal (R$)")
plt.ylabel("Frequência")
plt.tight_layout()
plt.show()
```

Código-fonte 4 – Gráfico de Distribuição – Histograma + KDE

Fonte: Elaborado pelo autor (2025)




Figura 4 – Gráfico de Distribuição – Histograma + KDE

Fonte: elaborado pelo autor (2025)

Correlação: quando uma variável influencia a outra

Raras são as análises em que olhamos variáveis isoladamente. A verdadeira riqueza dos dados está nas relações — quando um fenômeno parece acompanhar outro. É aí que entra o gráfico de dispersão (scatter plot), talvez o mais científico de todos os gráficos. Ele mostra, ponto a ponto, como duas variáveis se comportam juntas.

Cada ponto é um registro real, e o padrão que surge no conjunto revela muito sobre a relação: se os pontos formam uma linha, há correlação; se se espalham aleatoriamente, talvez não exista relação alguma. Inserir uma linha de tendência ajuda a visualizar a direção dessa associação. Já o heatmap de correlação amplia esse raciocínio: em vez de olhar duas variáveis por vez, analisamos todas simultaneamente, identificando blocos de variáveis que se movem juntas e podem representar um mesmo fenômeno.

Mas é aqui que o(a) cientista precisa de cautela: correlação não é causalidade. O fato de duas variáveis se moverem juntas não significa que uma causa a outra. Visualizações servem para levantar hipóteses, não para confirmar verdades.

```
plt.figure()
sns.scatterplot(
    data=df,
    x="renda_mensal",
    y="gasto_mensal",
    hue="segmento",
    alpha=0.7
)
plt.title("Renda vs Gasto mensal")
plt.xlabel("Renda mensal (R$)")
plt.ylabel("Gasto mensal (R$)")
plt.tight_layout()
plt.show()
```

Código-fonte 5 – Gráfico de Correlação – Scatterplot
Fonte: Elaborado pelo autor (2025)




Figura 5 – Gráfico de Correlação – Scatterplot
Fonte: Elaborado pelo autor (2025)

```
plt.figure(figsize=(8,5))

sns.regplot(
    data=df,
    x="renda_mensal",
    y="gasto_mensal",
    scatter_kws={"alpha": 0.4, "color": "#4A6FA5"}, #
    pontos azul acinzentado
    line_kws={"color": "red", "lw": 2} # linha
    de tendência vermelha
)

plt.title("Renda vs Gasto Mensal (com linha de tendência)",
          fontsize=12, weight="bold")
plt.xlabel("Renda mensal (R$)", fontsize=11)
plt.ylabel("Gasto mensal (R$)", fontsize=11)
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

Código-fonte 6 – Gráfico de Correlação – Scatterplot com linha de tendência
Fonte: Elaborado pelo autor (2025)




Figura 6 – Gráfico de Correlação – Scatterplot com linha de tendência
Fonte: Elaborado pelo autor (2025)

```
plt.figure(figsize=(7, 5))
corr = df[["idade", "renda_mensal", "score",
           "gasto_mensal"]].corr()

sns.heatmap(
    corr,
```

```
    annot=True,  
    fmt=".2f",  
    cmap="coolwarm",  
    vmin=-1,  
    vmax=1  
)  
  
plt.title("Matriz de correlação")  
plt.tight_layout()  
plt.show()
```

Código-fonte 7 – Gráfico de Correlação – Headmap de Correlação
Fonte: Elaborado pelo autor (2025)




Figura 7 – Gráfico de Correlação – Gráfico de Correlação – Headmap de Correlação
Fonte: Elaborado pelo autor (2025)

Tendência: o tempo como variável

Quando o tempo entra na equação, o gráfico precisa respeitar sua continuidade. A forma mais natural de representar uma série temporal é a linha — uma trajetória que conecta o passado ao presente e insinua o futuro. Gráficos de linha nos ajudam a enxergar ciclos, sazonalidades, rupturas e tendências de crescimento ou declínio (KNAFLIC, 2019).

Um gráfico de área pode reforçar o volume total acumulado, mostrando não apenas a direção da variação, mas também sua magnitude. Em análises mais

detalhadas, é comum aplicar médias móveis, que suavizam flutuações e destacam tendências reais escondidas no ruído dos dados diários ou semanais.

Essas representações são essenciais para análises de desempenho, vendas, custos ou indicadores sociais — qualquer fenômeno que evolua com o tempo.

```
plt.figure(figsize=(7, 5))
gasto_mensal = (
    df.groupby("mes") ["gasto_mensal"]
    .mean()
    .sort_index()
)

plt.figure()
plt.plot(gasto_mensal.index, gasto_mensal.values,
marker="o")
plt.title("Evolução do gasto médio mensal")
plt.xlabel("Mês")
plt.ylabel("Gasto médio (R$)")
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```

Código-fonte 8 – Gráfico de Tendência – Série Temporal

Fonte: Elaborado pelo autor (2025)



Figura 8 – Gráfico de Correlação – Gráfico de Tendência – Serie Temporal

Fonte: elaborado pelo autor (2025)

Composição: partes de um todo

Muitas vezes, a pergunta não é “quanto temos?”, mas “de que é feito o total?”. É o caso das análises de composição, em que buscamos entender a proporção que cada parte representa no conjunto. Aqui, o gráfico de barras empilhadas é uma escolha eficaz: ele permite ver a contribuição de cada categoria sem perder a comparação entre grupos.

O treemap é outra forma poderosa — ele mostra proporções hierárquicas de forma compacta, ideal para conjuntos complexos. Já o waterfall ilustra como ganhos e perdas se acumulam até formar o resultado.

Por outro lado, o gráfico de pizza, embora muito usado, deve ser tratado com cuidado. O olho humano não mede bem ângulos, e quanto mais fatias houver, mais difícil se torna interpretar corretamente. Na dúvida, opte por barras ou áreas.

```
np.random.seed(42)
df["produto"] = np.random.choice(["Serviço A", "Serviço B",
                                   "Serviço C"], size=n)

# Tabela de composição por segmento
tabela_comp = pd.crosstab(df["segmento"], df["produto"],
                           normalize="index")

plt.figure()
tabela_comp.plot(kind="bar", stacked=True)
plt.title("Composição de produtos por segmento")
plt.xlabel("Segmento")
plt.ylabel("Proporção")
plt.legend(title="Produto")
plt.tight_layout()
plt.show()
```

Código-fonte 9 – Gráfico de Composição (Barras Empilhadas)
Fonte: elaborado pelo autor (2025)




Figura 9 – Gráfico de Composição (Barras Empilhadas)
Fonte: elaborado pelo autor (2025)

Boas práticas de visualização profissional

Visualizações profissionais respeitam a forma como as pessoas percebem informações. Um gráfico eficiente é simples sem ser simplista. Ele reduz ruídos, destaca o essencial e não compete com a mensagem. Isso significa evitar gradientes desnecessários, sombras exageradas, efeitos 3D e elementos decorativos que não carregam significado (KNAFLIC, 2019).

O uso de cores deve ser intencional. Cores servem para criar contraste, agrupar elementos relacionados ou destacar pontos de atenção. Misturar muitas cores semelhantes ou usar paletas sem considerar acessibilidade pode confundir mais do que esclarecer. Escalas numéricas precisam ser consistentes e transparentes: iniciar em zero quando a comparação depende de proporções, indicar claramente mudanças de escala quando necessário, e evitar cortes que ampliem artificialmente pequenas diferenças.

Rotular e contextualizar também faz parte das boas práticas. Um gráfico sem título claro, sem indicação de unidades, sem legenda adequada ou sem fonte dos dados exige esforço extra de interpretação e abre espaço para leituras equivocadas. Visualizações profissionais contam ao leitor o que está sendo visto, em que contexto

e com que limites. Elas carregam responsabilidade: alguém tomará decisões com base nelas (KNAFLIC, 2019).

Erros comuns e o que evitar

Os erros mais perigosos em visualização de dados não são os gráficos feios, mas os gráficos enganosos. Algumas escolhas distorcem a percepção e sugerem conclusões erradas, mesmo quando os dados estão tecnicamente corretos. Entre os problemas mais comuns estão: escalas quebradas sem indicação clara, uso inadequado de eixo secundário, gráficos de pizza com muitas categorias, proporções irreais, sobreposição excessiva de séries e comparações entre coisas que não são diretamente comparáveis.

Outro erro frequente é a ausência de pergunta. Gráficos que são criados apenas porque "é legal mostrar", sem clareza do que se espera responder, resultam em um painel visualmente carregado e cognitivamente vazio: muitos elementos, poucos insights. Em um contexto de Ciência de Dados, isso não é inofensivo; é desperdício de atenção e, em alguns casos, ruído que atrapalha decisões importantes (KNAFLIC, 2019).

O(a) cientista de dados precisa desenvolver um radar para identificar esses problemas, tanto nos próprios gráficos quanto nos materiais que recebe de outras áreas. Visualizações ruins são um alerta: talvez a análise por trás delas também seja frágil. Questionar o gráfico é uma forma de proteger a qualidade das decisões.

```
# Distribuição de regiões (para exemplo de pizza ruim)
dist_regiao = df["regiao"].value_counts()

plt.figure()
plt.pie(dist_regiao.values, labels=dist_regiao.index,
autopct="%1.1f%%")
plt.title("Exemplo: gráfico de pizza com muitas
categorias")
plt.tight_layout()
plt.show()
```

Código-fonte 10 – Gráfico de Pizza
Fonte: elaborado pelo autor (2025)

Exemplo: gráfico de pizza com muitas categorias




Figura 10 – Gráfico de Pizza
Fonte: 3laborado pelo autor (2025)

De dados ao insight – Processo analítico

Visualizar é uma etapa do processo analítico, não um evento isolado. A jornada que leva dos dados brutos a um insight começa com a exploração, passa pela formulação de hipóteses, segue com testes e validações e culmina na comunicação estruturada. Em cada uma dessas fases, gráficos desempenham um papel específico.

Na fase exploratória, buscamos padrões e anomalias. Na fase de teste, usamos visualizações para verificar se relações observadas se mantêm diante de diferentes recortes, períodos ou métricas de controle. Na comunicação, escolhemos poucos gráficos-chave para contar a história de forma direta. Um bom relatório não é aquele que mostra tudo, mas aquele que mostra o necessário para sustentar uma conclusão sólida.

Transformar dados em insight é um ato de síntese. Envolve decidir o que entra e o que fica de fora da narrativa visual. Esse julgamento exige conhecimento técnico, entendimento do problema e ética. O(a) cientista de dados maduro(a) entende que toda visualização é uma tradução — e toda tradução carrega responsabilidade.

MERCADO, CASES E TENDÊNCIAS

O mercado contemporâneo exige do(a) Cientista de Dados muito mais do que domínio técnico de algoritmos. Espera-se um(a) profissional capaz de traduzir a complexidade dos dados em narrativas visuais que inspirem decisões seguras e estratégicas. Em organizações de tecnologia, saúde, varejo, finanças e governo, a visualização é hoje uma ferramenta essencial para compreender comportamentos, monitorar indicadores em tempo real e antecipar anomalias. Dashboards bem projetados e relatórios visuais precisos reduzem incertezas, aumentam a confiança e aproximam dados de pessoas — transformando a análise em uma linguagem acessível e estratégica.

Em **A Cor dos Dados** (Kate Strachnyi, 2023), a autora aprofunda a dimensão estética da análise, mostrando que cores não são apenas adornos, mas uma linguagem poderosa que direciona a atenção e reforça a mensagem central.

Essa obra representa uma mensagem: o(a) Cientista de Dados do futuro é também um(a) contador(a) de histórias visuais. Ele(a) pensa criticamente, entende o contexto do negócio e comunica evidências de forma ética, clara e empática. Ao dominar o uso de gráficos, narrativas e cores, o(a) profissional transforma dados em conhecimento, e conhecimento em impacto — tornando a visualização não apenas uma etapa da análise, mas um diferencial competitivo no mercado de dados.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, você viu que visualização de dados é parte essencial do trabalho do(a) Cientista de Dados — tanto para explorar quanto para comunicar. Entendeu que não existe gráfico neutro ou escolha inocente: cada decisão visual influencia a forma como as pessoas interpretam a informação.

Você aprendeu a importância de conhecer o dataset antes de representá-lo, a relacionar tipos de perguntas com tipos de gráficos e a identificar erros comuns que distorcem análises. Também refletiu sobre como o processo de transformar dados em insight passa por uma sequência estruturada de exploração, teste e síntese visual.

A partir daqui, o desafio é aplicar esse olhar crítico em todo projeto: questionar gráficos prontos, desenhar visualizações mais honestas e garantir que cada evidência mostrada tenha fundamento sólido. Não se trata apenas de fazer gráficos bonitos, mas de criar representações visuais que respeitam a realidade e ajudam a tomar decisões melhores.

REFERÊNCIAS

DUARTE, N. **DataStory**: explique dados e inspire ações por meio de histórias. Rio de Janeiro: Alta Books, 2021.

GRUS, J. **Data Science do Zero**: noções fundamentais com python. 2. ed. Rio de Janeiro: Alta Books, 2021.

KNAFLIC, C. **Storytelling com Dados**: um guia sobre visualização de dados para profissionais de negócios. Rio de Janeiro: Alta Books, 2019.

PROVOST, F; FAWCETT, T. **Data Science Para Negócios**. Rio de Janeiro: Alta Books, 2016.

STRACHNYI, K. **A Cor dos Dados**: um guia para o uso de cores em storytelling de dados. São Paulo: Novatec, 2023.

PALAVRAS-CHAVE

Dados. Gráficos. Estatística. *Insight*

EXEMPLO

The background is a dark, teal-colored abstract composition. It features a complex, symmetrical pattern of glowing blue lines and rectangular shapes that resemble a digital or architectural structure. The lines are arranged in a way that creates a sense of depth and perspective, with some elements appearing to recede into the distance. In the center of the image, the word "POSTECH" is written in a white, stylized, sans-serif font. The letters are slightly offset from the background pattern, making them stand out. The overall aesthetic is futuristic and technological.

POSTECH