

AI SCIENTIST

FASE 1 | AULA 01 -

INTRODUÇÃO AO CRISP DM

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	17
REFERÊNCIAS.....	18

O QUE VEM POR AÍ?

Nesta aula, vamos compreender o que é o CRISP-DM e por que ele se tornou o método mais adotado para conduzir projetos de ciência de dados. Nossa missão é traçar um panorama claro: entender o que é esse método, sua origem, suas fases e, principalmente, por que ele continua sendo tão relevante mesmo em um cenário dominado por inteligência artificial e automação.

Ao longo da aula, seguiremos um roteiro, que parte do contexto histórico que deu origem ao CRISP-DM, passando por suas seis fases fundamentais e chegando às suas aplicações no mundo moderno, onde se conecta a práticas como Agile, Design Thinking e MLOps.

HANDS ON

Neste capítulo, o Hands On acontece dentro da própria lógica do negócio. Não vamos abrir o editor de código, mas mergulhar na prática que antecede qualquer modelagem: a compreensão do problema. É aqui que a ciência de dados realmente começa. Ao longo dos exemplos, veremos como as decisões empresariais, as métricas de sucesso e os objetivos estratégicos moldam todas as fases do CRISP-DM.

Nos exemplos que percorrem esta aula, você verá como esse raciocínio se traduz em decisões analíticas, como hipóteses, validações e interpretações que sustentam projetos sólidos de ciência de dados. O exercício aqui é de raciocínio, não de sintaxe — e é exatamente esse olhar estratégico que transforma dados em valor.

SAIBA MAIS

A história do CRISP-DM

Antes de mergulhar no método em si, é fundamental compreender o **contexto** que o tornou indispensável. O CRISP-DM não é apenas um conjunto de etapas; ele nasceu como uma resposta direta a um período de intensa transformação tecnológica e um desafio crescente: a explosão de dados corporativos.

Durante os anos 1990, a popularização de bancos de dados relacionais e o surgimento das primeiras ferramentas de mineração trouxeram consigo um **volume de informações sem precedentes** para as corporações. No entanto, o entusiasmo inicial era ofuscado pela falta de padronização. Cada organização abordava a mineração de dados de forma isolada, criando seus próprios jargões, processos e ciclos de vida de projetos.

Essa abordagem fragmentada invariavelmente resultava em graves problemas: retrabalho constante, inconsistências entre departamentos e, o mais crítico, projetos que, apesar do investimento, raramente produziam resultados práticos e aplicáveis ao negócio. Foi nesse cenário de caos e ineficiência que a necessidade de um padrão comum se manifestou com urgência.

Em 1996, um consórcio europeu formado por empresas como SPSS, Daimler-Benz, NCR e OHRA uniu forças com o apoio da Comissão Europeia para criar uma metodologia padrão que pudesse ser aplicada a qualquer setor. O projeto foi batizado de **Cross-Industry Standard Process for Data Mining**, ou simplesmente **CRISP-DM**.

Dois anos depois, em 1998, os primeiros resultados do projeto foram publicados, e em 2000 foi lançada oficialmente a versão 1.0 do guia CRISP-DM, documento que até hoje é referência mundial.

O que o consórcio criou não foi apenas um processo técnico, mas uma **filosofia de trabalho colaborativo e estruturado**. O CRISP-DM foi pensado para unir áreas de negócio, estatística e tecnologia em um fluxo lógico que garantisse entregas

consistentes. Tornou-se assim, o primeiro grande padrão aberto da era analítica, antecedendo frameworks corporativos como o ASUM-DM da IBM e o SEMMA da SAS.

Ao longo das décadas seguintes, mesmo com o avanço da inteligência artificial e do aprendizado de máquina, o CRISP-DM permaneceu como a base conceitual dos projetos de dados. Suas seis fases se mantiveram relevantes justamente porque tratam de **princípios universais: compreender o negócio, entender os dados, preparar, modelar, avaliar e entregar valor**. É um método que atravessa gerações tecnológicas porque está fundamentado no pensamento analítico e não em ferramentas passageiras.

Hoje, ao observar o CRISP-DM sob a ótica moderna, percebemos que ele antecipou muito do que veio a se consolidar nas práticas de Data Science e MLOps. É uma metodologia que sobreviveu às mudanças de linguagem, à ascensão do big data e à transformação digital — um verdadeiro marco histórico que continua apoiando cientistas de dados e engenheiros(as) em todo o mundo.

Como o CRISP-DM funciona e suas principais fases




Figura 1 – CRISP-DM
Fonte: gerado por Inteligência Artificial (2025)

O CRISP-DM é uma **metodologia aberta, flexível e iterativa** criada para guiar o ciclo de vida completo de um projeto de análise de dados. Seu principal propósito é conectar o que o negócio precisa com o que a equipe técnica constrói, garantindo que o resultado final realmente gere impacto.

Uma metodologia viva

O ponto mais fascinante do CRISP-DM é que ele não dita ferramentas, linguagens ou tecnologias. Ele propõe uma forma de pensar. É justamente por isso que, mesmo décadas depois de sua criação, ele continua relevante em projetos de data science, analytics e machine learning. Pense nele como um idioma comum que ajuda analistas, engenheiros(as) e executivos(as) a se entenderem. Quando dizemos “estamos na fase de Data Understanding”, todos sabem o que isso significa e o que deve ser entregue. Essa clareza reduz retrabalho, facilita a comunicação e traz previsibilidade ao processo.

Os pilares do processo

CRISP-DM se apoia em três pilares principais: **clareza de propósito, disciplina de dados e experimentação controlada**. O primeiro nos lembra de que nenhum modelo faz sentido sem um objetivo de negócio bem definido. O segundo reforça que qualidade e compreensão dos dados são indispensáveis — afinal, a “garbage in, garbage out” ainda é uma máxima verdadeira, e o terceiro pilar nos ensina que modelar é experimentar, testar hipóteses e validar resultados, sempre de forma mensurável e crítica.

O ciclo e suas fases

O método se organiza em seis grandes fases interdependentes que formam um ciclo contínuo de aprendizado e melhoria.

1. **Compreensão do negócio:** o ponto de partida é entender o problema de negócio, traduzindo objetivos estratégicos em perguntas analíticas claras e mensuráveis.
2. **Compreensão dos dados:** investigamos os dados disponíveis, identificando o que realmente existe, o que está ausente e o que precisa ser coletado.

3. **Preparação dos dados:** a fase mais trabalhosa do processo. Aqui, limpamos, transformamos e estruturamos os dados para que façam sentido e estejam prontos para a modelagem.
4. **Modelagem:** aplicamos técnicas estatísticas e algoritmos de aprendizado de máquina para gerar previsões, classificações ou insights relevantes.
5. **Avaliação:** verificamos se o modelo não apenas atinge bom desempenho técnico, mas também resolve o problema original e gera impacto real no negócio.
6. **Implantação:** a última etapa leva a solução à prática — seja em um dashboard, uma API, um sistema operacional ou qualquer ambiente onde o modelo gere valor concreto para a organização.

A natureza iterativa




Figura 2 – Ciclo Iterativo do CRISP-DM
Fonte: gerado por Inteligência Artificial (2025)

Nenhuma dessas fases é estanque. Em um bom projeto, você está constantemente revisitando etapas anteriores. Descobriu um problema nos dados? Volte à preparação. O modelo não performou? Reavalie a definição do problema. Esse movimento de ida e volta é natural e saudável. Ele garante aprendizado e maturidade

ao processo, e é exatamente o que diferencia o CRISP-DM de metodologias lineares tradicionais.

Um mapa, não uma prisão

O CRISP-DM não é uma receita, e sim um mapa. Ele oferece orientação sem engessar. Em projetos acadêmicos, consultorias ou squads ágeis, ele se adapta às particularidades de cada contexto. E mais importante: ajuda você a justificar suas decisões. Quando um stakeholder pergunta “por que escolhemos esse modelo?”, é o CRISP-DM que fornece o roteiro lógico da resposta — porque esse modelo foi definido a partir de um problema de negócio, com dados analisados, preparados, modelados e avaliados de forma transparente.

Business Understanding

A primeira fase do CRISP-DM é também a mais estratégica de todas: entender o problema de negócio. É aqui que tudo começa — antes mesmo de olhar para os dados, precisamos compreender qual é a dor real que estamos tentando resolver. Muitas vezes, essa dor não está expressa claramente. Um gestor pode dizer que quer “reduzir inadimplência”, mas o que isso significa na prática? Reduzir o número absoluto de clientes inadimplentes, ou diminuir o valor médio das dívidas? A resposta muda completamente o tipo de análise que será feita.

Por isso, o papel do(a) cientista de dados neste momento é de tradução. É necessário traduzir o problema de negócio em um problema analítico. Em projetos reais, isso significa conduzir entrevistas com as áreas, mapear os indicadores estratégicos e compreender como o sucesso será medido. O objetivo é sair desta etapa com perguntas claras — aquelas que podem ser respondidas por meio dos dados. É essa definição que guiará todas as fases seguintes.

Quando conseguimos definir bem o problema, evitamos um dos maiores erros de um projeto de dados: o desalinhamento entre o que a empresa precisa e o que o modelo entrega. É comum encontrar times que criam modelos com ótima acurácia, mas que não geram impacto algum porque não respondem à pergunta certa. Por isso, nesta fase, mais importante do que abrir um notebook, é abrir uma boa conversa.

Exemplo prático: imagine que uma rede varejista quer prever cancelamentos de pedidos online. A definição ingênua seria “criar um modelo de previsão de cancelamento”.

Mas a pergunta certa talvez seja “**quais fatores influenciam o cancelamento e como podemos atuar preventivamente?**”. Repare como a segunda formulação abre espaço para ação e aprendizado, não apenas para previsão.

Essa mudança de mentalidade é o coração do Business Understanding. Nela, o time estabelece os objetivos de negócio, define as métricas de sucesso, identifica restrições e riscos, e registra tudo em um documento vivo — o brief do projeto. Esse artefato será a bússola de todo o ciclo do CRISP-DM.

Data Understanding

Com o problema de negócio definido, entramos na segunda fase: compreender os dados. Esta é a etapa de descoberta, em que o(a) cientista de dados se comporta como um(a) explorador(a). O objetivo aqui não é modelar ainda, mas entender o terreno onde o projeto vai pisar.

A primeira ação é fazer um **inventário das fontes de dados**. Elas podem estar em bancos relacionais, planilhas, APIs ou sistemas legados. Cada uma delas conta uma parte da história. Entender de onde vêm esses dados é fundamental para avaliar sua confiabilidade. Depois, coletamos **amostras iniciais** e começamos a **fazer perguntas**: há campos faltantes? Há valores inconsistentes? Os dados fazem sentido entre si?

Essa é também a hora de aplicar **estatísticas descritivas básicas**: médias, medianas, dispersões, contagens. Esses números nos revelam padrões e outliers, e ajudam a identificar erros de coleta ou digitação. Mas o ponto mais importante é a visualização. Ao representar graficamente os dados, conseguimos enxergar tendências e comportamentos que seriam invisíveis em uma tabela. Um simples histograma ou gráfico de dispersão pode revelar muito sobre o que realmente está acontecendo.

Exemplo prático: voltando ao caso da previsão de inadimplência, imagine que descobrimos que 80% dos inadimplentes têm menos de um ano de relacionamento

com o banco. Isso, por si só, já é um insight valioso que pode orientar políticas de crédito e retenção. Perceba que ainda não há modelo algum — há interpretação, e é isso que dá sentido ao trabalho.

Ao final desse processo, devemos ter um relatório de qualidade dos dados, um inventário atualizado e hipóteses iniciais sobre o que eles nos dizem. Também é importante documentar as limitações encontradas, pois elas influenciarão diretamente o que será possível fazer nas próximas fases. O Data Understanding é, portanto, o momento de escutar o que os dados têm a dizer antes de tentar ensiná-los a falar.

Data Preparation

Agora que já conhecemos o problema e o terreno dos dados, entramos na fase mais artesanal do processo: a **preparação dos dados**. Essa é a parte que exige paciência, atenção e muito cuidado, pois qualquer erro aqui se propaga para as fases seguintes.

O objetivo da preparação é transformar dados brutos em um conjunto limpo, estruturado e pronto para a modelagem. Isso envolve selecionar as variáveis relevantes, tratar valores ausentes, padronizar formatos e criar novas features que capturem relações mais profundas. É o momento de decidir o que fica e o que sai.

Durante essa fase, práticas como **normalização**, **padronização** e codificação de variáveis categóricas (como o **one-hot encoding**) se tornam parte da rotina. Também é comum realizar a **integração de diferentes fontes** — por exemplo, cruzar dados de vendas com registros de clientes ou de logística. Essa integração é o que transforma pedaços de informação em conhecimento contextualizado.

Exemplo prático: em um projeto de varejo, podemos combinar a base de clientes com a de transações e a de suporte. Só então percebemos que reclamações de entrega estão fortemente associadas a cancelamentos futuros. Esse tipo de insight nasce da preparação — de enxergar conexões que antes estavam dispersas.

Outro ponto essencial é a documentação do pipeline de preparação. Cada transformação deve ser registrada, seja em um notebook ou em um script versionado. Isso garante rastreabilidade e facilita a reprodução dos resultados, algo crítico em ambientes corporativos e acadêmicos.

Ao final dessa etapa, temos um dataset limpo, consistente e documentado — o insumo fundamental para a próxima etapa. A preparação de dados é onde a teoria encontra a prática, e onde o cuidado técnico se transforma em base para a descoberta. É também onde percebemos que **boa parte da inteligência de um projeto não está no modelo, mas na maneira como tratamos os dados que o alimentam.**

Modeling

Chegamos à fase que costuma despertar mais curiosidade: a modelagem. É aqui que aplicamos técnicas estatísticas e algoritmos de aprendizado de máquina para transformar dados em previsões, classificações ou recomendações. Mas antes de mergulhar nos modelos, é essencial lembrar que eles são apenas uma parte do processo. A modelagem é poderosa, mas sua eficácia depende diretamente da clareza das fases anteriores — o entendimento do negócio, a qualidade dos dados e o cuidado na preparação.

Nesta etapa, o papel da pessoa cientista de dados se aproxima do de um(a) engenheiro(a). É preciso escolher algoritmos apropriados ao tipo de problema — regressão para estimar valores contínuos, classificação para categorizar, agrupamento para segmentar, séries temporais para prever comportamentos ao longo do tempo. Cada escolha traz implicações técnicas e de negócio. Um modelo de alta complexidade pode gerar resultados impressionantes, mas ser difícil de interpretar; outro, mais simples, pode entregar valor rápido e confiável.

A modelagem envolve experimentação controlada. Criamos conjuntos de treino, validação e teste para evitar que o modelo memorize os dados, buscando generalização. Aplicamos técnicas como cross-validation e ajustamos hiperparâmetros para encontrar o equilíbrio entre viés e variância. O objetivo não é encontrar o modelo “perfeito”, mas aquele que se mantém estável e explicável.

Exemplo prático: imagine novamente o projeto de inadimplência. Podemos testar desde uma regressão logística até uma árvore de decisão. A primeira oferece interpretabilidade — cada variável revela seu peso sobre o resultado. Já a segunda captura relações não lineares e interações entre variáveis. O(a) cientista de dados

precisa avaliar: qual dessas abordagens ajuda mais o time de crédito a agir? Às vezes, um modelo levemente menos preciso, mas mais compreensível, gera mais impacto.

Modelar é, portanto, um ato de equilíbrio entre técnica e propósito. Exige documentação rigorosa, registro de experimentos e clareza de critérios de comparação. É nesse ponto que a maturidade do profissional faz diferença: entender que cada número e cada métrica têm um contexto.

Evaluation

Depois de modelar, precisamos avaliar. Essa é a fase de análise crítica — o momento em que verificamos se o modelo realmente cumpre o propósito do negócio. Avaliar não é apenas olhar para métricas técnicas, mas **compreender o que elas significam para quem tomará decisões** com base nelas.

Aqui, revisitamos o que foi definido lá na fase de Business Understanding. Quais eram as metas do projeto? Se o objetivo era reduzir a inadimplência, por exemplo, uma acurácia alta pode não ser suficiente se o modelo errar justamente nos casos mais críticos. Por isso, usamos métricas adequadas ao problema: precision, recall, F1-score, AUC-ROC, RMSE ou MAE, dependendo do tipo de tarefa.

A avaliação também envolve **testar a robustez do modelo**. Como ele reage a novos dados? Está sofrendo de overfitting? Faz sentido estatisticamente e operacionalmente? E, talvez o mais importante, os resultados podem ser explicados? **Um modelo que não pode ser interpretado dificilmente será adotado por áreas de negócio ou auditoria.**

Exemplo prático: no caso do banco, um modelo que prevê inadimplência com 92% de acurácia pode parecer excelente. Mas se errar os 8% justamente em clientes com grandes valores, o prejuízo é alto. Avaliar, portanto, é medir impacto, não só desempenho. É equilibrar o olhar técnico com o olhar estratégico.

Essa fase fecha o ciclo analítico do CRISP-DM e prepara o terreno para a entrega de valor. O relatório final de avaliação deve reunir as métricas, limitações e recomendações — o que o modelo faz bem, onde ele falha e como pode ser aprimorado. **A boa avaliação é aquela que permite tomar decisões informadas, não apenas celebrar números.**

Deployment

Por fim, chegamos à etapa que concretiza todo o esforço: a **implantação**. É aqui que o trabalho deixa de ser apenas análise e se transforma em impacto real. O deployment pode assumir muitas formas: um dashboard em Power BI, uma API em produção, um relatório executivo ou um sistema automatizado que consome o modelo e gera decisões diárias.

Implantar não é apenas colocar o modelo no ar. É garantir que ele será usado corretamente, que terá manutenção e que os resultados serão monitorados. É aqui que o **CRISP-DM** se conecta naturalmente ao **MLOps** — práticas que trazem controle de versões, monitoramento de performance e pipelines automatizados.

Um bom deployment prevê o ciclo de vida completo: o modelo precisa ser reavaliado periodicamente, pois dados mudam, contextos se transformam e o que funcionava ontem pode se tornar obsoleto amanhã. Também é essencial preparar os usuários: fornecer documentação, dashboards explicativos e canais de feedback.

Exemplo prático: voltando ao nosso exemplo de varejo, o modelo que prevê cancelamentos pode ser integrado diretamente ao CRM. Sempre que um cliente apresentar perfil de risco, o sistema gera uma notificação automática para o time de retenção, que pode agir preventivamente. Esse é o valor final do processo: transformar aprendizado em ação.

Encerrar o CRISP-DM com o deployment não significa o fim — é o recomeço. Cada entrega traz novos dados, novos comportamentos e novas oportunidades de melhoria. O ciclo continua, e o aprendizado se retroalimenta. Assim, o método mantém sua força: porque **não é sobre concluir um projeto, e sim sobre criar um processo vivo e contínuo de inteligência de dados**.

CRISP-DM + Agile, Design Thinking e MLOps

Uma das grandes forças do CRISP-DM está na sua capacidade de se conectar e evoluir junto com outras metodologias. Ele não é um modelo isolado, mas sim um alicerce sólido sobre o qual outras práticas podem ser construídas. No cenário atual de ciência de dados e engenharia de machine learning, é necessária colaboração multidisciplinar, entregas rápidas e sistemas confiáveis. Por isso, o CRISP-DM

conversa naturalmente com três abordagens que o complementam: Agile, Design Thinking e MLOps.

Integração com Agile

O Agile traz para o CRISP-DM a cadência e o foco em valor incremental. Em vez de esperar meses para entregar um modelo final, as fases do CRISP-DM podem ser distribuídas em sprints curtos, com entregas parciais e revisões constantes.

O ciclo ágil permite que o aprendizado ocorra de forma contínua: uma sprint pode se concentrar em Data Understanding, outra em Modelagem e Avaliação, e assim por diante. Ao final de cada iteração, há feedback real e mensurável — do time técnico e dos stakeholders. Isso mantém o projeto vivo e ajustado às necessidades do negócio.

Trabalhar dessa forma também muda a mentalidade da equipe. Cada sprint é uma oportunidade de aprendizado, e o backlog passa a refletir não apenas tarefas técnicas, mas hipóteses a validar. Essa aproximação entre o CRISP-DM e o Agile cria um ambiente mais colaborativo e menos linear, no qual a **experimentação é vista como parte do processo e não como erro**.

Conexão com Design Thinking

Se o Agile nos ensina a entregar valor mais rápido, o Design Thinking nos lembra para quem estamos entregando esse valor. Essa abordagem coloca o ser humano no centro da solução, começando pela empatia. Quando a equipe aplica teste Design Thinking dentro do CRISP-DM, o foco não é apenas resolver um problema técnico, mas **compreender as motivações, dores e necessidades das pessoas envolvidas**.

Na prática, as fases do Design Thinking — Empatia, Definição, Ideação, Prototipagem e Teste — se encaixam de forma natural nas fases do CRISP-DM. A empatia e a definição ajudam a enriquecer o Business Understanding, a ideação orienta a exploração de hipóteses durante o Data Understanding e a prototipagem se alinha às fases de Modelagem e Avaliação, em que os experimentos são construídos e validados. Por fim, o teste está diretamente relacionado ao Deployment, quando o modelo é colocado em uso e observamos como ele se comporta no mundo real.

Integrar Design Thinking ao CRISP-DM é uma forma de garantir que os projetos não se tornem frios ou distantes da realidade do usuário. O(a) cientista de dados passa a atuar também como um(a) designer de soluções, alguém capaz de entender a experiência humana por trás dos números.

O elo com MLOps

Se o Agile e o Design Thinking ampliam o alcance humano e iterativo do CRISP-DM, o MLOps é o elo que garante sua sustentação técnica a longo prazo. Ele leva o método da fase de Deployment até o ciclo completo de operação, monitoramento e melhoria contínua. O MLOps incorpora práticas de DevOps, automação e controle de versões, trazendo previsibilidade e governança para modelos em produção.

Com o MLOps, cada entrega do CRISP-DM se torna parte de um sistema reprodutível e escalável. Pipelines automatizados garantem que o processo de treinamento e validação possa ser repetido com consistência. Ferramentas de monitoramento acompanham métricas de drift, acurácia e performance, alertando quando o modelo começa a se desalinhar da realidade. Esse ciclo fecha a lógica de inteligência: novos dados retroalimentam o processo, iniciando uma nova rodada de Business Understanding e permitindo que o projeto evolua continuamente.

Uma nova visão integrada

O verdadeiro poder do CRISP-DM contemporâneo está na sua capacidade de integração. Quando combinamos sua estrutura metodológica com a agilidade dos sprints, a empatia do Design Thinking e a robustez operacional do MLOps, criamos um ecossistema completo. O projeto deixa de ser uma sequência de etapas e passa a ser um **ciclo vivo**, onde tecnologia, negócio e experiência humana caminham juntos.

Essa é a essência da ciência de dados moderna: processos que aprendem, equipes que colaboram e soluções que evoluem junto com o mundo ao redor. O CRISP-DM continua sendo o ponto de partida essencial, mas hoje atua como elo entre o raciocínio analítico e o desenvolvimento de produtos, unindo código e propósito estratégico de forma viva e contínua.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, percorremos todo o ciclo do CRISP-DM, entendemos não apenas suas fases, mas também a filosofia por trás delas. Aprendemos que a ciência de dados não começa com o código, mas com o entendimento do problema de negócio. Discutimos como transformar dores e metas em perguntas analíticas e como os dados, quando bem compreendidos e preparados, se tornam uma base sólida para qualquer modelo.

Passamos pela modelagem, destacando a importância da experimentação controlada e da explicabilidade. Na avaliação, reforçamos a ideia de que métricas técnicas só têm valor quando estão conectadas ao impacto real no negócio. E, ao chegar ao deployment, percebemos que a entrega de um modelo é apenas o início de um ciclo vivo de aprendizado.

Também vimos como o CRISP-DM se mantém atual ao dialogar com metodologias modernas. O Agile trouxe agilidade e valor incremental; o Design Thinking, empatia e foco no humano; e o MLOps, estrutura e confiabilidade.

Em resumo, o que o CRISP-DM nos ensina é que ciência de dados é sobre propósito e processo. Não se trata apenas de criar modelos, mas de conectar pessoas, decisões e tecnologia em torno de um objetivo comum: transformar dados em conhecimento e conhecimento em ação.

Aproveitem as referências para se aprofundarem. Essas leituras são essenciais para complementar a base teórica e reforçar a ideia de que as metodologias funcionam como pontes, sendo o verdadeiro diferencial a forma como são aplicadas na prática, em diversos contextos.

REFERÊNCIAS

CHAPMAN, P. et al. **CRISP-DM 1.0: step-by-step data mining guide**. [S.l.]: [s.n.], 2000.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**. 3. ed. Sebastopol: O'Reilly Media, 2022.

PROVOST, F.; FAWCETT, T. **Data Science for Business**: what you need to know about data mining and data-analytic thinking. Sebastopol: O'Reilly Media, 2013.

SHIMAOKA, A. M.; FERREIRA, R. C.; GOLDMAN, A. **The evolution of CRISP-DM for Data Science**: methods, processes and frameworks. SBC Reviews on Computer Science, 2023. Disponível em: <https://journals-sol.sbc.org.br/index.php/reviews/article/view/3757>. Acesso em: 25 nov. 2025.

PALAVRAS-CHAVE

Palavras-chave: CRISP-DM, Data Mining, Data Science.

CRISP

The background is a dark, abstract digital space. It features a complex network of glowing blue lines and patterns that resemble a circuit board or a data network. The lines are arranged in a way that creates a sense of depth and perspective, with some lines converging towards the center and others branching out. The overall effect is a futuristic, high-tech aesthetic.

POSTECH