

AI SCIENTIST

**FASE 1 | AULA 02 -
DEFINIÇÃO DO PROBLEMA DE
NEGÓCIO E COMO DEFINIR O ALVO
DA MODELAGEM PREDITIVA
(TARGET)**

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
O QUE VOCÊ VIU NESTA AULA?	14
REFERÊNCIAS.....	15

O QUE VEM POR AÍ?

Já tivemos uma introdução sobre o mapa do CRISP-DM — suas fases, a natureza iterativa e como uma etapa alimenta a seguinte. Agora vamos aprofundar no primeiro passo, Business Understanding, para transformar intenção estratégica em problema analítico e preparar o terreno para todo o ciclo.

A ciência de dados não começa no algoritmo, começa na pergunta. No CRISP-DM, a fase de Business Understanding é o momento em que transformamos intenções estratégicas em um problema analítico que pode ser estudado, mensurado e melhorado.

O fio condutor desta aula é justamente essa tradução. Primeiro, estabelecemos o que o negócio deseja alcançar e quais decisões pretende embasar. Em seguida, convertemos esse propósito em uma variável-alvo — o target — que o modelo será capaz de aprender por meio de dados históricos. Por fim, conectamos a definição do target a métricas de sucesso e a práticas de MLOps, porque um alvo que não se sustenta em produção não é um alvo, é uma hipótese vaga.

HANDS ON

Vamos exercitar o pensamento analítico que antecede qualquer modelo. O CRISP-DM é cíclico e iterativo, e toda boa análise começa por entender o problema que o negócio realmente quer resolver.

Neste momento, o objetivo é compreender como traduzir metas empresariais em perguntas analíticas concretas. Vamos observar casos reais, analisar hipóteses e construir a lógica que sustenta um modelo antes que qualquer dado seja processado. Essa é a essência do Business Understanding: reconhecer que cada decisão, métrica ou objetivo estratégico molda as fases seguintes do CRISP-DM.

Nosso desafio aqui é aprender a formular as perguntas certas, porque é nelas que a ciência de dados começa de fato.

SAIBA MAIS

Business Understanding: a importância de definir claramente o problema de negócio

O ponto de partida da jornada de uma pessoa cientista de dados, antes mesmo de considerar algoritmos ou escrever a primeira linha de código, está em uma conversa aprofundada e estratégica para desvendar e compreender o objetivo central do negócio.



Figura 1 – Business Understanding
Fonte: gerado por Inteligência Artificial (2025)

Quando a liderança ou as áreas de negócio **expressam metas** de forma ampla e, por vezes, abstrata — como "**melhorar resultados**", "**otimizar a eficiência operacional**", "**aumentar o share de mercado**" ou "**reduzir perdas e custos**" — o papel crucial do profissional de dados transcende a análise técnica e se torna de consultoria estratégica.

Essa etapa inicial não é apenas um formalismo, é o alicerce que garantirá a relevância e o impacto do trabalho de dados. **A conversão de metas abstratas em objetivos tangíveis.**

Sem um entendimento profundo e formalizado das necessidades de negócio, o risco de se construir um modelo estatisticamente robusto, mas estrategicamente irrelevante, é elevadíssimo. A clareza no Business Understanding garante que o esforço subsequente em Data Understanding (Entendimento dos Dados), Data Preparation (Preparação dos Dados), Modeling (Modelagem), Evaluation (Avaliação) e Deploy (implementação) esteja perfeitamente alinhado com a geração de valor real para a organização.

Essa etapa define o próprio sucesso do modelo. Em vez de perguntar “**qual algoritmo usar?**”, a pergunta certa é “**que decisão o negócio precisa tomar e qual indicador queremos impactar?**”. Essa mudança de foco é o que separa um experimento acadêmico de um projeto de valor real. Quando compreendemos o contexto, as restrições e os objetivos, criamos o mapa que vai guiar cada decisão técnica.

Considere alguns exemplos práticos:

Um banco deseja “**reduzir a inadimplência**”. Essa frase ainda é vaga demais. O(a) cientista de dados precisa detalhar — estamos falando de atraso pontual ou de default total? Qual horizonte de tempo faz sentido? Três meses? Seis? A partir dessas respostas nasce um objetivo técnico: “prever a probabilidade de que um contrato entre em default até 90 dias após o vencimento”. Agora temos algo que pode ser modelado, validado e acompanhado no tempo.

Em marketing, o mesmo raciocínio vale. “**Queremos aumentar a retenção**” se torna “**prever a probabilidade de que um cliente cancele o serviço nos próximos 60 dias**”.

No varejo, “**aumentar o ticket médio**” se traduz em “**prever a probabilidade de que um cliente compre o produto X na próxima visita**”. Cada tradução aproxima o(a) analista da linguagem do negócio e evita que o modelo responda perguntas que ninguém fez.

No fundo, esta fase é sobre tradução e propósito. É o momento em que a ciência encontra o negócio, e a estatística ganha significado.

Do problema de negócio à variável alvo (Target)

Depois da definição do problema em termos de negócio, o próximo passo é traduzi-lo para um objetivo técnico de Data Science, ou seja, definir **o que exatamente o modelo irá prever** – esta será a nossa **variável alvo (target)**.



Figura 02– Problema de negócio - Variável Alvo
Fonte: gerado por Inteligência Artificial (2025)

A variável-alvo cumpre um papel central na estrutura de qualquer projeto de aprendizado supervisionado: ela é o elo entre o que o negócio quer alcançar e o que o modelo pode prever. Em termos práticos, o target representa o fenômeno que queremos que o algoritmo aprenda. Se a definição for ambígua, o modelo aprenderá uma ambiguidade; se for precisa, o modelo terá chance de generalizar.

A forma mais prática de estabelecer o target é uma fórmula simples, que sintetiza o raciocínio analítico: “a probabilidade de que **[Unidade]** irá **[Ação]** nos próximos **[Período]**”.

Essa estrutura ajuda a transformar objetivos genéricos em hipóteses mensuráveis, obrigando o(a) cientista de dados a responder três perguntas essenciais: quem é o sujeito da previsão, o que conta como evento e quando o evento ocorre.

Unidade define o nível de análise: cliente, conta, contrato, usuário, pedido ou transação. Essa escolha direciona toda a modelagem: prever churn no nível do cliente

é diferente de prever churn por assinatura; prever inadimplência por contrato é diferente de avaliar risco agregado por cliente.

A Ação descreve o evento ou comportamento que desejamos antecipar: cancelar, dar default, comprar, clicar, responder. Aqui, a precisão semântica é essencial: o que significa, na prática, “cancelar”? O que define “não pagar”? Um rótulo mal definido cria confusão e compromete o aprendizado do modelo.

O Período estabelece o horizonte temporal da previsão: 30, 60, 90 dias, um ciclo de faturamento, a próxima visita. É o elemento que ancora a previsibilidade no tempo. Sem um período explícito, não há rótulo estável; com ele, o modelo aprende sob uma lógica temporal clara, que orienta treino, validação e monitoramento.

Exemplos setoriais: o mesmo raciocínio em contextos distintos

Imagine três histórias que poderiam estar acontecendo em qualquer empresa. Em uma área de marketing, por exemplo, o time percebe que **muitos clientes estão cancelando o serviço e a direção quer entender o motivo**. É aí que entra a pessoa cientista de dados, que reformula a questão de forma mais precisa: “Qual a probabilidade de que um cliente cancele o serviço nos próximos 60 dias?”. Note como o foco muda: deixamos de falar de uma frustração genérica para trabalhar com algo mensurável. O(a) analista define o que é cancelamento — se é a inatividade por um período, o encerramento formal da conta ou a ausência de compras. Cada escolha muda a forma como o modelo aprende e, portanto, as ações que o negócio tomará depois.

Em outra cena, um **banco quer reduzir a inadimplência**. A diretoria afirma: “precisamos de um modelo que identifique clientes de risco”. O(a) cientista de dados, então, transforma a intenção em uma hipótese de análise: “qual a probabilidade de que um contrato entre em default até 90 dias após o vencimento?”. Essa definição traz clareza — a unidade é o contrato, o evento é o atraso superior a 90 dias e o horizonte de tempo é pós-vencimento. Com esse raciocínio, a equipe consegue reconstruir o histórico, distinguir quem apenas atrasou de quem realmente não pagou e preparar dados consistentes para o modelo.

Já em uma grande rede de varejo, o desafio é outro: entender o comportamento de compra. A pergunta do negócio é ampla — **“como aumentar o ticket médio?”**. O(a) cientista de dados aproxima a questão da realidade analítica e propõe: **“qual a probabilidade de que um cliente compre o produto X na próxima visita ou nos próximos 30 dias?”**. A análise passa a ser feita no nível cliente-produto, permitindo personalizar ofertas e medir resultados de campanhas. Ao final, o(a) gestor(a) percebe que prever comportamento **não é adivinhar o futuro, mas entender padrões** que já estão escondidos nos dados.

Esses três cenários exemplificam como o mesmo raciocínio se aplica a diferentes setores. O segredo está em traduzir a linguagem do negócio em perguntas específicas, observáveis e com horizonte definido — é esse tipo de formulação que transforma dados em decisões estratégicas.

Armadilhas na definição do target

Os maiores erros de um projeto costumam surgir nesta etapa, não por falta de técnica, mas por excesso de suposições. Quatro armadilhas são particularmente comuns e comprometem a credibilidade dos resultados.

Viés e fairness: quando o rótulo usado no treinamento carrega distorções históricas — avaliações subjetivas, desigualdades regionais, critérios enviesados — o modelo apenas as replica. É por isso que precisamos questionar constantemente: **o que estamos realmente medindo?** O fenômeno em si ou sua sombra? Revisar rótulos, auditar variáveis sensíveis e testar impacto por grupo é parte essencial do processo.

Proxy Incorreto: quando o verdadeiro fenômeno é difícil de medir, criamos substitutos — os proxies —, mas eles nem sempre representam o que importa. Usar o NPS para medir satisfação, por exemplo, é conveniente, mas pode levar o modelo a otimizar um sinal fraco, que não reflete a experiência real do cliente. Um bom proxy precisa estar alinhado ao resultado desejado e ser constantemente reavaliado.

Leakage (Vazamento): o uso de informações que, na prática, não estariam disponíveis no momento da previsão. É como se o modelo tivesse acesso ao futuro. Isso pode acontecer quando variáveis como “número de parcelas pagas” ou “status de pagamento” entram no treino de um modelo de crédito.

Apesar de ser um bom preditor, ele é inútil na prática, pois quando emprestamos, não sabemos quantas parcelas a pessoa vai pagar. O resultado é uma performance artificialmente alta e uma queda brusca em produção.

Em vez de usar “número de parcelas pagas”, que é uma informação do futuro, podemos usar variáveis que já existem no momento da concessão do crédito ou que vêm do histórico anterior do cliente como “quantidade de contratos anteriores”, “maior tempo em atraso”.

A solução está em respeitar a linha do tempo e **garantir que todas as features estejam disponíveis apenas até o ponto de decisão.**

Dado indisponível ou pobre para o Target: uma outra armadilha é a indisponibilidade ou baixa qualidade de dados. Em teoria, a definição do target pode ser perfeita, mas sem dados consistentes ela se torna inviável. Prever fraude real, por exemplo, exige investigações demoradas; por isso, muitas empresas utilizam alvos aproximados, como fraude reportada ou chargeback, até obter confirmação. O importante é documentar as limitações e revisar periodicamente essas definições.

Definições Mutantes

As definições mudam quando o próprio conceito do evento é alterado. Por exemplo, um banco pode redefinir default de 90 para 60 dias; ou uma empresa pode passar a considerar **churn** após seis meses de inatividade, em vez de três. Na prática, isso significa que o **significado do target é alterado** e um modelo treinado com a definição antiga está agora desalinhado com o novo critério. Nesse caso, **é necessário reformular o modelo com a nova lógica.**

Target Drift

O target drift ocorre quando a distribuição do evento muda ao longo do tempo, mesmo que sua definição permaneça a mesma. Em outras palavras, o conceito não muda — o contexto, sim. Por exemplo, imagine que o critério de churn de uma empresa continua o mesmo, mas a **proporção de clientes** que “churnan” aumentou drasticamente em função do mercado. O modelo pode continuar prevendo com a mesma lógica, mas perde performance por que foi treinado em outra base.

Class Imbalance (Desequilíbrio de Classes)

Muitos problemas de negócio lidam com eventos raros, ou seja, que ocorrem em uma pequena fração dos casos (por exemplo, menos de 1% das vezes). Essa situação é chamada de desequilíbrio de classes (imbalance) e é comum em áreas como detecção de fraudes, diagnóstico de doenças raras ou previsão de falhas de equipamentos.

Quando um evento é extremamente raro, modelá-lo torna-se um grande desafio. Algoritmos de aprendizado de máquina tendem a focar na classe mais comum (a não ocorrência do evento), resultando em modelos com alta acurácia geral, mas que falham miseravelmente em identificar o evento raro de interesse.

O problema não é apenas a falta de dados, mas o risco de o modelo não conseguir aprender padrões que diferenciem o evento raro. Para contornar isso, usamos técnicas especiais, como:

- Sobre/Subamostragem (aumentar dados da classe rara ou diminuir da comum);
- Algoritmos sensíveis ao custo (dando mais importância ao erro na classe rara);
- Métricas de avaliação alternativas (como F1-Score, Recall e AUC-PR, em vez da simples Acurácia).

CrITÉRIOS de sucesso e custo/benefício

A utilidade de um modelo depende do equilibrar entre acertos e erros. Em churn, um falso positivo significa oferecer um desconto a quem não sairia; em crédito, um falso negativo representa conceder empréstimo a quem não pagará. A matriz de custo traduz esses impactos em valores e permite ajustar limiares de decisão. Assim, a análise deixa de ser apenas estatística e passa a ser econômica. O(a) cientista de dados precisa considerar o custo/benefício de cada decisão e avaliar se o ganho técnico realmente se converte em resultado de negócio.

Integrações contemporâneas

A definição do target se conecta diretamente a práticas de Agile e experimentação, orientando pilotos, rollouts graduais e testes A/B que mensuram o impacto real de cada modelo. Também se relaciona ao design de métricas, pois escolher a métrica correta é decidir o comportamento que será recompensado. Por fim, integra-se a artefatos modernos de documentação, como Model Cards e Data Sheets, que registram de forma padronizada o que foi previsto, como foi rotulado e sob quais suposições o modelo opera.

Conexão com MLOps: mantendo o target consistente em produção

A disciplina de MLOps lida com as práticas para operacionalizar e manter modelos de ML de forma confiável. Uma das boas práticas é assegurar que a definição de **variável alvo** permanece **consistente do treinamento à produção e durante toda a vida do modelo**.

Reprodução do target em produção

Na prática, significa que o sistema de produção deve ser capaz de calcular o mesmo target nos dados novos, seguindo exatamente a mesma definição usada no treinamento. Para conseguirmos isso é importante codificarmos a lógica de definição do target de forma reutilizável.

Se essa definição for complexa, documente e versione essa definição. Qualquer alteração deve ser tratada como atualização da versão do modelo.

Disponibilidade e latência de labels

Em produção, muitas vezes há um delay para se obter o valor verdadeiro do target. Com MLOps, podemos construir pipelines que passado o tempo necessário, **coletam resultados finais e comparam com as previsões**

Drift de Target (Deriva do Alvo)

O monitoramento de estatísticas via MLOps permite a identificação de desvios. Se os dados ultrapassarem o intervalo esperado, um alerta é disparado, sinalizando a potencial necessidade de revisar o modelo ou de reavaliar a compreensão do problema original.

Governança e documentação do target

Desde o CRISP-DM original, recomenda-se **registrar objetivos, definições e resultados**. Hoje, essa prática evoluiu para uma disciplina de **governança**. É essencial **documentar e versionar a definição do target**, associando-a aos conjuntos de dados e modelos que a utilizam. Em setores regulados, como finanças e saúde, essa rastreabilidade garante **transparência e conformidade**. Além disso, possibilita compreender decisões passadas: quando sabemos qual versão da definição estava em uso, **podemos explicar** por que um cliente foi classificado de determinada maneira.

Por fim, a **consistência entre times e modelos**. Organizações maduras mantêm **definições unificadas** em **feature stores** e **catálogos compartilhados**. Isso evita divergências silenciosas e assegura que todos falem a mesma língua.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, fizemos uma verdadeira imersão no raciocínio que transforma um problema de negócio ainda nebuloso em uma variável-alvo clara, concreta e útil. Vimos que essa transição é essencial: é ela que dá forma e direção a todo o projeto de modelagem preditiva. Quando o problema é bem definido, conseguimos escolher os dados certos, aplicar o algoritmo adequado e interpretar resultados com sentido para o negócio.

Refletimos também sobre o papel colaborativo do(a) cientista de dados na fase de Business Understanding: compreender o contexto, traduzir metas estratégicas em perguntas analíticas, definir um target mensurável e estabelecer critérios de sucesso que conectem técnica e propósito. Pelos exemplos de marketing, risco e varejo, percebemos que, apesar das diferenças de cenário, o princípio é o mesmo — **um modelo de machine learning só gera valor se responder à pergunta certa.**

Abordamos ainda sobre os cuidados necessários ao definir o target: evitar vieses, escolher bons proxys, prevenir vazamentos de informação e lidar com limitações dos dados. Esses cuidados não são apenas detalhes técnicos, mas parte do compromisso ético e intelectual que se espera de um cientista de dados.

Por fim, conectamos esse entendimento ao restante do ciclo do modelo. Um target bem definido precisa permanecer consistente quando o sistema entra em produção. É essa sintonia entre Business Understanding e MLOps que fecha o ciclo virtuoso da ciência de dados: modelos que resolvem problemas reais, acompanhados e evoluídos com o tempo para continuar entregando valor de forma confiável.

REFERÊNCIAS

GÉRÓN, Aurélien. Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow. 3. ed. Sebastopol: O'Reilly Media, 2022.

CHAPMAN, P.; et al. CRISP-DM 1.0: Step-by-step data mining guide. Documento original do consórcio europeu que formalizou o método, 2000.

PROVOST, F.; FAWCETT, T. Data Science for Business. Sebastopol: O'Reilly Media, 2013.

SHIMAOKA, A. M.; FERREIRA, R. C.; GOLDMAN, A. The evolution of CRISP-DM for Data Science: Methods, Processes and Frameworks. SBC Reviews on Computer Science, São Paulo, v. 4, n. 1, 2023. DOI: 10.5753/reviews.2024.3757.

PALAVRAS-CHAVE

Palavras-chave: CRISP-DM; Business Understanding; Variável-alvo (Target); Churn/Default; Feature Engineering; MLOps; Governança.

CRISP-DM



POSTECH