

AI SCIENTIST

FASE 1 | AULA 03 -  
**METAS DE NEGÓCIO  
VS. METAS  
ANALÍTICAS.**

---

## SUMÁRIO

|                                  |    |
|----------------------------------|----|
| O QUE VEM POR AÍ? .....          | 3  |
| HANDS ON .....                   | 4  |
| SAIBA MAIS.....                  | 5  |
| O QUE VOCÊ VIU NESTA AULA? ..... | 20 |
| REFERÊNCIAS.....                 | 21 |

EMANIP

## O QUE VEM POR AÍ?

Nesta aula, avançamos do entendimento para a régua de sucesso. Com o terreno já mapeado e a variável-alvo definida nos capítulos anteriores, o foco agora é conectar metas de negócio e metas analíticas e mostrar como essa conexão governa escolhas técnicas, decisões operacionais e, no fim, o valor entregue.

O princípio fundamental é simples: métricas técnicas são o caminho, enquanto os KPIs de negócio são o destino. Ao estabelecer essa clara linha de visão, os modelos deixam de competir apenas em classificações e passam a gerar resultados concretos em produção.

## HANDS ON

Em projetos sérios de dados, a ciência começa antes do Python: começa quando traduzimos uma meta empresarial em perguntas analíticas testáveis. Nosso objetivo aqui é treinar essa tradução com casos curtos e extrair, de cada um, critérios de sucesso que guiam o restante do ciclo.

Esta é a essência do Business Understanding: cada decisão, métrica e objetivo estratégico molda as fases seguintes. Quando formulamos as perguntas certas, o restante do CRISP-DM ganha direção.

## SAIBA MAIS

### O MODELO ESTÁ PRONTO. E AGORA?

Nos capítulos anteriores, vimos a importância de entender o problema de negócio e definir corretamente os targets (variáveis-alvo) dentro do processo CRISP-DM. Agora, daremos continuidade à discussão sobre como alinhar metas de negócio e metas analíticas em projetos de ciências de dados.



Figura 1 – O modelo está pronto. E agora?  
Fonte: gerado por Inteligência Artificial (2025)

Agora que temos um modelo, como saber se ele realmente valeu a pena? No framework CRISP-DM, ainda na fase de Business Understanding, é fundamental garantir que as **metas de negócio** e **metas analíticas caminhem juntas** desde o início do projeto.

### DIFERENCIANDO METAS DE NEGÓCIO E METAS ANALÍTICAS

Além de pensarmos sobre o que medir, é importante falar o que queremos alcançar com isso. Podemos pensar nas **métricas como termômetro** e nas **metas como a temperatura ideal** que queremos atingir.

## METAS DE NEGÓCIO

São os objetivos estratégicos ou **operacionais** que a organização deseja alcançar com o projeto. Em geral, são formulados em termos de indicadores de negócio ou KPI (Key Performance Indicators).

Exemplos:

- **Aumentar a receita** em X%;
- **Reduzir o churn** (taxa de cancelamento de clientes) para Y% ao ano;
- **Diminuir perdas** por fraude em Z milhões de reais;
- **Melhorar a satisfação** do cliente medida por NPS;
- **Otimizar** o uso de recursos para reduzir custos.

Essas metas são mensuráveis no contexto do negócio e representam o **porquê** de um projeto de machine learning existir. Uma característica importante é que elas costumam ser traduzíveis em impacto financeiro ou em vantagem competitiva (por exemplo: a redução de churn leva a maior faturamento, enquanto a diminuição de fraude evita prejuízos).

Também podem incluir objetivos menos tangíveis, como insights acionáveis (“Entender os fatores que levam ao churn”). Nesses casos, é recomendável definir critérios de sucesso do negócio para avaliar se o resultado do projeto foi útil, mesmo que de forma qualitativa.

## METAS ANALÍTICAS (OU TÉCNICAS)

São os objetivos do projeto de Data Science em si, geralmente expressos na forma de métricas de modelo ou resultados técnicos. É por meio delas que conseguimos medir, de forma objetiva, se o modelo está funcionando bem.

Exemplos comuns incluem:

- Maximizar o recall em um classificador;
- Reduzir a taxa de falsos positivos em um detector de fraude;
- Melhorar a AUC de um modelo para acima de 0,90;
- Alcançar um RMSE abaixo de determinado valor em regressão;

- Treinar um modelo de clustering que segmenta os clientes em grupos com alto poder preditivo.

Essas metas servem como proxy técnico para o sucesso, elas determinam como vamos medir, do ponto de vista analítico, se nosso modelo ou análise foi bem-sucedido.

Por exemplo, se a meta de negócio é reduzir fraudes, uma meta analítica associada pode ser “desenvolver um modelo de detecção de fraude com **precisão de pelo menos 98% e taxa de falsos positivos (FPR) abaixo de 1%**”.

Da mesma forma, a meta de negócio de aumentar retenção de clientes pode levar a uma meta analítica de “prever churn com 85% de recall com determinado custo máximo por falso alerta”.

## ESCOLHENDO MÉTRICAS ANALÍTICAS ALINHADAS AOS OBJETIVOS DO NEGÓCIO

A métrica analítica escolhida funcionará como uma bússola durante o desenvolvimento, se for bem escolhida, vai direcionar o modelo rumo ao impacto desejado. Se mal escolhida, pode levar a soluções pouco eficientes ou mesmo inúteis ao negócio. Desde o design do projeto, é fundamental optar por métricas que melhor refletem o objetivo final. Isso evita a armadilha de otimizar um modelo às cegas.

**Não existe métrica “universal” de performance. A escolha depende completamente do contexto do problema, dos custos associados, aos erros e das metas de negócio envolvidas.**

Em outras palavras, um projeto orientado à redução de fraudes pode justificar o sacrifício de um pouco de *recall* para obter maior precisão, evitando falsos alarmes que prejudiquem clientes. Já em um projeto de saúde voltado à detecção de doenças graves, a decisão pode ser oposta: buscar o *recall* máximo, mesmo à custa de menor precisão, pois deixar de identificar um caso positivo é muito mais grave do que gerar um alarme falso.

O alinhamento inicial também auxilia no planejamento de projeto e na análise de viabilidade. Por exemplo, já na fase de determinar os objetivos do projeto, é útil

conduzir uma análise de custo-benefício aproximada: **“Qual é o potencial ganho financeiro ou operacional se atingirmos as metas?”**.

Essa avaliação inicial garante que as metas analíticas propostas façam sentido do ponto de vista econômico. Se for identificado que, mesmo com um modelo “perfeito” o benefício financeiro seria limitado, o projeto pode precisar ser repensado ou outras metas de negócio, mais impactantes, devem ser priorizadas.

A seguir, vejamos alguns exemplos de métricas comuns e quando elas se alinham (ou não) aos objetivos reais.

**Threshold (ponto de corte):** é o valor limite que usamos para decidir quando uma previsão do modelo deve ser considerada como **“positiva”**. Mas por que o threshold importa?

Um threshold tende a identificar mais casos positivos, mas também aumenta a quantidade de falsos positivos. Já um threshold alto reduz os falsos positivos, elevando a precisão, porém ao custo de deixar passar alguns casos relevantes.

**Acurácia geral:** embora seja uma métrica popular, pode ser enganosa em muitos cenários, especialmente quando há desbalanceamento entre as classes.

Se a meta de negócio for, digamos, detectar transações fraudulentas tipicamente raras, com por exemplo menos de 1% das operações, um modelo trivial que nunca sinaliza fraude teria 99% de acurácia, o que seria tecnicamente alto, mas fracassa completamente em atingir o objetivo de negócio, que era reduzir perdas identificando fraudes.

Quando as classes estão desbalanceadas ou os custos de erro diferem, a acurácia bruta não reflete o que o negócio precisa. Use acurácia apenas se todos os erros têm custo similar e a distribuição de classes é equilibrada, o que é raro em problemas críticos de negócio.

**Precision (precisão) e Recall (sensibilidade):** métricas derivadas da matriz de confusão, mais informativas do que a acurácia quando há trade-offs entre tipos de erro. Em termos práticos, otimizar a precisão tende a reduzir falsos positivos, enquanto otimizar o *recall* tende a reduzir falsos negativos.



**Precision** responde à pergunta: dentre as previsões positivas do modelo, quantas de fato eram casos positivos?

**Recall** indica: dentre todos os casos positivos existentes, quantos o modelo conseguiu capturar?

Por exemplo: em detecção de fraude, um **falso positivo** (classificar uma transação legítima como fraudulenta) gera frustração para o cliente e retrabalho para a equipe de suporte, enquanto um **falso negativo** (deixar passar uma fraude) causa perda financeira direta. Se o negócio considera mais prejudicial acusar injustamente um cliente do que perder algumas fraudes de baixo valor, pode-se priorizar alta precisão, mesmo que isso implique sacrificar o recall).

Já em cenários como a detecção de doenças ou a identificação de *churn* de clientes VIP, um **falso negativo** (deixar de identificar um caso real) tende a ser muito mais custoso. Nesses contextos, o *recall* torna-se crítico, ainda que isso resulte em mais falsos alarmes.

**F1-Score: equilíbrio entre** precisão e sensibilidade. É a média harmônica entre Recall e Precision.

A média harmônica é uma forma especial de calcular uma média, usada quando queremos dar mais peso a valores menores. No caso do F1-Score, isso significa que penalizamos modelos que apresentam desempenho muito ruim em um dos dois aspectos.

Na prática, o F1 premia modelos equilibrados: se o recall ou a precision forem baixos, o F1 também será baixo, se ambos forem bons, o F1 será alto.

**AUC-ROC (area sob a curva ROC):** muito utilizada para avaliar modelos de classificação de forma independente de um ponto de corte específico. Avalia o quão bem um modelo consegue separar as classes, independente do threshold.

Um AUC alto (próximo de 1.0) indica que o modelo, de forma consistente, atribui probabilidades maiores aos casos positivos do que aos negativos, ou seja, ele consegue distinguir bem entre as duas classes.

Use AUC para seleção e comparação de modelos, mas na hora de definir thresholds ou estimar impacto, considere métricas de ponto de corte ou métricas de custo costumam ser mais relevantes. AUC é uma métrica “proxy” de desempenho

global; a meta de negócio final pode exigir maximizar outro indicador derivado (lucro, retenção etc.) que não cresce linearmente com AUC.

Em resumo, AUC é valiosa para comparar modelos de forma geral, mas **não garante, por si só, o ponto de decisão ótimo para o negócio.**

## **MÉTRICAS DE CUSTO E BENEFÍCIO (ROI, EXPECTED VALUE, CUSTO DO ERRO)**

No dia a dia do negócio, é essencial traduzir métricas em valores financeiros ou utilidade para orientar a decisão. Isso significa que acertos e erros do modelo precisam ser mensurados em dinheiro ou impacto real no negócio.

**ROI (Retorno sobre o Investimento):** é o retorno financeiro obtido com o uso do modelo, comparado ao custo de implementação. Perguntas típicas que surgem: **“O modelo se paga? Qual é seu impacto econômico real?”.**

Muitas vezes, manter ou aumentar o ROI é a prioridade. Nesse caso, o melhor modelo não é necessariamente o que apresenta maior precisão ou recall, mas aquele que gera **mais lucro**.

Por exemplo, se descobirmos que falsos negativos **custam muito mais caro** que falsos positivos, fica claro que Recall (reduzir falsos negativos) deve ser a prioridade na métrica de avaliação possivelmente até introduzindo um peso maior para esse erro no treino do modelo.

Em contrapartida, se falsos alarmes geram perdas altas (por exemplo: no caso de bloquear clientes bons em sistemas de crédito, o que pode afugentá-los para concorrentes), a métrica deve incorporar isso, seja através de Precision ou de um cálculo de custo que penalize severamente falsos positivos.

Em resumo: mapear métricas para valores financeiros ou utilidade do negócio a escolher a métrica de otimização de forma racional. Ferramentas como curva de ganhos (gain chart) e lift também são úteis aqui.

**Lift:** Mede o quanto o modelo identifica positivos melhor do que uma seleção aleatória.

Exemplo: um lift de 3 no top 10% indica que essa fatia contém 3 vezes mais casos positivos (clientes responsivos, fraudulentos etc.) do que se escolhêssemos 10% da base aleatoriamente.

Maximizar o lift em um segmento específico pode ser uma meta analítica, especialmente quando o negócio só pode atuar sobre uma parte da base (por restrição de orçamento). Assim, o lift traduz diretamente **quantos resultados adicionais serão obtidos graças ao modelo**, conectando claramente à efetividade da campanha ou ação de negócio.

**Expected Value:** estimativa do lucro ou benefício médio que se espera ao aplicar o modelo considerando erros e acertos. Essa métrica ajuda a escolher o melhor modelo ou ponto de corte com base no retorno esperado.

**Custos do erro:** impacto financeiro ou operacional de cada tipo de erro: falso positivo ou falso negativo. Ele ajuda na decisão de qual métrica analítica priorizar.

## MÉTRICAS DE REGRESSÃO

Essas métricas são usadas quando o modelo prevê valores contínuos, como vendas, demanda, preço, tempo. Não basta só olhar para o número, precisamos entender o impacto no negócio.

**MAE (Erro Absoluto Médio):** mede o erro médio entre o valor previsto e o valor real. Por exemplo, se o erro médio entre o valor previsto e o valor real for R\$5,00 esse é o erro por previsão. Por isso é importante sempre olhar o impacto no negócio, um erro médio (MAE) de \$5 pode ser ótimo ou péssimo dependendo se estamos prevendo vendas de \$50 ou de \$5000. Portanto, aqui também convém relacionar o erro a impactos: Qual diferença de X unidades é tolerável para a decisão?

**MAPE (Erro Percentual Médio):** muitas vezes converte-se o erro em percentual para ter noção relativa, facilitando a comparação entre diferentes contextos.

**RMSE (Raiz do Erro Quadrático Médio):** parecido com o MAE, mas penaliza mais os erros grandes. Útil quando grandes erros podem causar prejuízos maiores.

As melhores práticas recomendam inclusive usar múltiplas métricas e ferramentas diagnósticas para ter visão completa, mas sempre tendo em mente qual métrica final representa o sucesso.

## **CASES: QUANDO O MODELO É TECNICAMENTE BOM, MAS FALHA EM GERAR VALOR**

Nem todo modelo com métricas elevadas cumprirá o que o negócio espera. Infelizmente, é possível declarar vitória prematuramente com base em métricas de validação e depois descobrir que os ganhos reais não vieram. Aqui discutimos alguns cenários comuns onde desalinhamentos entre métricas técnicas e valor de negócio causam problemas e como evitá-los:

### **Caso 1: acurácia enganosa e a classe rara**

Já mencionamos o problema de um modelo ter acurácia de 99% mas falhar no objetivo (fraudes não detectadas, por exemplo). Esse é um exemplo clássico de modelo tecnicamente “bom” na métrica errada. Outro exemplo: um modelo de classificação de churn apresenta AUC excelente ( $>0.85$ ) e uma acurácia alta no test set. Entretanto, ao implantá-lo, constata-se que ele prioriza clientes que de fato têm alta chance de churn, porém muitos desses já iriam sair de qualquer jeito e as ações do time pouco conseguem reter (talvez por serem clientes de baixo valor ou já insatisfeitos irreversíveis).

Enquanto isso, clientes “persuadíveis” que poderiam ser salvos não foram priorizados porque tinham score de churn um pouco menor. Ou seja, o modelo maximizou AUC e até recall, mas o critério de sucesso de negócio, reduzir churn efetivamente, não foi alcançado, pois as intervenções não geraram retenção.

Esse tipo de situação realça a importância de incluir considerações de negócio na avaliação de modelos. Uma possível solução seria incorporar no processo de modelagem um modelo de propensão ao impacto (uplift modeling) ou pelo menos avaliar o lift do modelo em identificar clientes retidos vs. não retidos após ação. O ponto chave é: uma métrica técnica ótima (AUC 0.85) não garante impacto se não

houver congruência com o mecanismo de negócio (quem será abordado, com qual oferta, etc.).

Por isso, o CRISP-DM separa a avaliação técnica do modelo da avaliação dos resultados de negócio na fase de Evaluation. Primeiro examina-se se o modelo atende aos critérios técnicos definidos; depois, verifica-se se ele atende aos objetivos do negócio e se existe alguma razão pela qual, apesar de tecnicamente bom, o modelo seja inadequado do ponto de vista do negócio.

Nessa segunda etapa podem surgir questões como:

- “O modelo faz suposições que não se sustentam no mundo real?”
- “Há restrições operacionais não consideradas?”
- “O resultado é acionável e útil para quem vai usá-lo?”

Se a resposta for “não”, o projeto pode precisar iterar de volta para a fase de entendimento ou até reformular o problema.

## CASO 2: OTIMIZANDO A MÉTRICA ERRADA (OBJETIVO MAL ALINHADO)

Imagine um modelo de recomendação cujo objetivo técnico foi maximizar cliques em ofertas. Essa métrica (CTR) apresentou aumento significativo. No entanto, as vendas efetivas permaneceram estáveis, revelando que muitos dos cliques eram motivados apenas por curiosidade, sem intenção real de compra.

**O problema aqui foi definir “clique” como objetivo do modelo**, quando o **objetivo do negócio era aumentar vendas**. Nesse caso, houve um desalinhamento claro: o modelo fez bem o que lhe pediram (gerar cliques), mas esse não era o proxy correto para vendas.

Esse exemplo reforça definir bem o target (variável alvo) e a métrica de sucesso técnica é determinante. Métricas de proxy devem ser escolhidas com muito cuidado.

**Solução:** quando não é viável treinar diretamente para o evento final (como a venda, que pode ser mais raro ou demorado), podem ser utilizadas métricas intermediárias mais próximas do objetivo de negócio, como **taxa de conversão pós-clique**, **receita gerada por clique** ou **valor médio por usuário impactado**. Além

disso, é fundamental monitorar a métrica de negócio real por meio de **testes A/B**, a fim de validar se o ganho técnico se converteu em resultado econômico.

**Se não ocorreu, o modelo “falhou” para o negócio, independentemente de seu acerto interno.**

### **CASO 3: COMPLEXIDADE EXCESSIVA VS. USO PRÁTICO.**

Às vezes um modelo apresenta métricas levemente melhores do que outra solução mais simples, porém é tão complexo (ou tão caro de rodar) que na prática não compensa. Suponha que um modelo X de deep learning atinja 0.92 de AUC, superando um modelo Y mais simples com 0,90. Entretanto, o modelo X demora cerca de 10 segundos por previsão e exige uma infraestrutura pesada, enquanto o modelo Y responde de forma praticamente instantânea. Se a aplicação exigir respostas em tempo real para milhares de usuários, o modelo mais simples pode gerar maior valor para o negócio, justamente por se integrar à operação sem fricção.

Aqui, a meta de negócio, por exemplo, é satisfazer o cliente com respostas rápidas ou economizar custo computacional, não foi considerada na otimização puramente focada em AUC. Assim, o deploy do modelo complexo acaba não acontecendo ou ocorrendo de forma limitada, perdendo-se o potencial ganho.

A lição é incorporar constraints reais do negócio (latência, interpretabilidade, custo computacional) como parte dos critérios de sucesso do projeto. Sempre questione:

**“Este modelo poderá ser implementado de forma a atingir o KPI esperado?”**

Se ele viola alguma condição necessária (tempo de resposta, compliance, etc.), então sua ótima métrica não se converterá em ROI.

**Modelos que “performam bem no papel, mas não no mundo real” são uma conhecida fonte de desperdício de tempo, recursos e potencial de negócio.**

## **CASO 4: FOCO ESTREITO NA MÉTRICA DO MODELO E EFEITO COLATERAL NO NEGÓCIO**

Um exemplo comum em algumas empresas envolve modelos de detecção de fraude em pagamentos online. Esses modelos foram calibrados para reduzir ao máximo o chargeback (prejuízo com fraude). Conseguiu-se reduzir fraudes, mas as regras e modelos se tornaram tão agressivos que muitos clientes bons tiveram suas compras recusadas (alto número de falsos positivos).

O resultado? A perda de receita causada por clientes frustrados superou o ganho com fraudes evitadas. Novamente, a falha foi não equilibrar a métrica técnica (reduzir fraude quase a zero) com o KPI de negócio final (maximizar lucro ou receita líquida). O objetivo correto seria minimizar fraudes sem afetar demais as vendas legítimas. Nesse caso, a métrica de sucesso poderia considerar ambos os fatores, por exemplo:  $\text{lucro líquido} = \text{receita aprovada} - \text{custo de fraude}$ .

Esse caso ilustra problemas menos ótimos ("subótimos") que não são os mais fáceis de corrigir (de "segunda ordem") podem surgir: otimizar isoladamente um departamento ou indicador (fraude) em detrimento de outro (vendas) destrói valor total.

Em projetos de Machine Learning, isso deve ser antecipado: é importante envolver diferentes áreas do negócio para definir restrições e metas múltiplas, se necessário. Métricas compostas ou múltiplas métricas de avaliação podem ser empregadas para captar esse equilíbrio. Ferramentas de negócios como ROI e custo de oportunidade ajudam a garantir que o modelo, ao cumprir sua meta local, não prejudique o desempenho global da empresa.

## **ALINHAMENTO DE MÉTRICAS E KPIS NAS DECISÕES, DEPLOY E ROI**

Quando métricas técnicas e objetivos de negócio estão corretamente alinhados, eles influenciam todas as principais decisões do ciclo de desenvolvimento de modelos:



Figura 2 – Mais alinhamentos?  
Fonte: gerado por Inteligência Artificial (2025)

**Seleção de modelos e ajustes:** durante a etapa de modelagem, podemos experimentar diversos algoritmos e configurações. A escolha do “melhor modelo” deve ser guiada pela métrica de avaliação alinhada ao negócio. Se definimos que a métrica de sucesso é, por exemplo, o lucro esperado ou o custo médio do erro, é possível que o modelo com maior acurácia ou AUC não seja o preferido, mas sim aquele que otimiza o indicador de negócio (mesmo que para isso ele sacrifiquem alguns pontos em métricas genéricas). Essa perspectiva muda a forma de ranquear modelos.

Guiar-se pelo expected value ou outro KPI alinhado garante que a decisão técnica (qual modelo/threshold usar) maximize a meta empresarial.

**Nota:** em alguns casos, utiliza-se um conjunto de métricas para comparar modelos – tudo bem, desde que fique claro qual peso cada uma tem conforme os objetivos. Por exemplo, “selecionaremos o modelo com maior recall, desde que a precisão não fique abaixo de X%, pois esse equilíbrio nos traz maior retenção líquida”.

## DECISÃO DE PONTO DE CORTE (THRESHOLD) E ESTRATÉGIA DE AÇÃO

Modelos de classificação entregam score, não vereditos. A decisão nasce quando definimos o ponto de corte (threshold), e esse valor não sai do chapéu: ele é escolhido para otimizar o resultado de negócio dado o custo do erro. Em churn, por exemplo, eu varro diferentes thresholds e calculo o ROI de cada cenário: um corte mais baixo aumenta cobertura (+ recall) e também os falsos positivos (mais gente



abordada sem necessidade); um corte mais alto economiza custo (+ precisão), mas perde casos valiosos (+ falsos negativos).

**O threshold de deploy é o que maximiza lucro/retenção líquida sob as restrições do negócio (budget, capacidade operacional, experiência do cliente).**

Se a **diretriz** for “priorizar recall”, isso **precisa estar assumido no business case**: aceita-se mais falsos positivos e provisiona processo e orçamento para lidar com eles. Em fraude, o raciocínio é simétrico: calibrar demais para reduzir chargeback pode derrubar conversão ao bloquear clientes bons. seu corte tem de maximizar lucro líquido (receita aprovada – custo de fraude – custo operacional), não apenas “acerto” do modelo.

Em resumo: o threshold é o botão de sensibilidade do produto analítico. Você escolhe onde operar, e documenta isso usando curvas de custo ou lucro esperado (ou top-K quando só dá para agir sobre uma fatia da base). A métrica alinhada ao KPI determina o corte e o restante da configuração operacional como quem abordar, quando, com que oferta ou regra é consequência.

## GO/NO-GO DA IMPLANTAÇÃO - DEPLOY E GOVERNANÇA

Ao final da fase de avaliação, com métricas em mãos, a pergunta é: “**Vamos implementar esse modelo?**”.



Figura 3 – Modelo Errado  
Fonte: gerado por Inteligência Artificial (2025)

No **CRISP-DM**, é na fase de evaluation que vamos tomar essa decisão.

**ROI e Priorização de Projetos:** novamente temos o ROI como nossa bússola. No longo prazo, o que sustenta a ciência de dados em uma empresa é a capacidade de mostrar retorno sobre o investimento.

**Escalabilidade e Apoio Executivo:** times com resultados consistentes conquistam mais confiança e apoio da liderança. Isso cria um ciclo positivo: **+ investimentos > + resultados > + credibilidade > + ..**

## **MLOPS, MONITORAMENTO CONTÍNUO EM PRODUÇÃO**

No CRISP-DM, após a fase de evaluation, vem a fase de deployment. Não é apenas colocar o modelo no ar, envolve também monitorar, manter e avaliar continuamente os resultados em produção. **MLOps é a área que garante que modelos em produção continuem funcionando bem e gerando valor.**

Um aspecto fundamental de MLOps é o monitoramento contínuo de métricas, tanto métricas técnicas quanto métricas de negócio. Na prática, isso significa que após o deploy criam-se dashboards ou sistemas de acompanhamento onde figuram indicadores como: acurácia atual do modelo coletando dados recentes, taxas de erro, distribuição de previsões, data drift, etc., ao lado de indicadores de negócio como taxa de churn atual, receita incremental, fraudes detectadas vs. ocorridas, satisfação do usuário, etc. Dessa forma, a equipe pode observar se melhorias técnicas correspondem a melhorias nos KPIs e muitas vezes vamos ter que fazer testes A/B para separar o efeito do modelo de outros fatores.

## **GOVERNANÇA E AJUSTE CONTÍNUO**

O MLOps fecha o ciclo também com a ideia de governança: se o KPI de negócio mudar (talvez a empresa decida que agora o foco não é mais volume de vendas e sim margem de contribuição, por exemplo), os parâmetros ou até o objetivo do modelo podem precisar ser revistos. Esse é outro motivo para não se fixar em métricas técnicas estáticas: elas podem ser recalibradas para refletir novas prioridades.

Em suma, o alinhamento entre metas analíticas e de negócio deve perdurar por todo o ciclo de vida do modelo, desde a concepção até a manutenção em produção. Projetos bem-sucedidos normalmente apresentam essa característica: objetivos claros, métricas bem escolhidas, avaliação contextual e acompanhamento pós-implantação.

Essa é a essência da união entre CRISP-DM e MLOps. **Planejar para o valor desde o início e fechar o ciclo garantindo que o valor seja entregue até no fim.**

CRISP-DM

## O QUE VOCÊ VIU NESTA AULA?

Nesta aula, vimos como alinhar metas de negócio e metas analíticas é essencial para o sucesso de projetos de ciência de dados e machine learning. Essa sintonia fina garante que o trabalho técnico seja direcionado para aquilo que realmente importa para a organização, seja aumentar receita, reduzir riscos ou melhorar a satisfação do cliente.

Vimos também que uma meta de negócio bem definida deve inspirar a definição das métricas analíticas correspondentes, e que escolher a métrica de avaliação correta pode fazer a diferença entre um “modelo campeão de leaderboard” e um modelo que **de fato entrega ROI**. Exploramos exemplos práticos onde a falta de alinhamento levou a modelos tecnicamente bons fracassarem em gerar valor, reforçando a necessidade de sempre validar resultados em termos de impacto e por fim como MLOps traz para projetos de IA, muito mais chance de gerar impacto positivo e sustentável.

## REFERÊNCIAS

CHAPMAN, P. et al. **CRISP-DM 1.0: step-by-step data mining guide**. [S.l.]: [s.n.], 2000.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**. 3. ed. Sebastopol: O'Reilly Media, 2022.

PROVOST, F.; FAWCETT, T. **Data Science for Business**: what you need to know about data mining and data-analytic thinking. Sebastopol: O'Reilly Media, 2013.

SHIMAOKA, A. M.; FERREIRA, R. C.; GOLDMAN, A. **The evolution of CRISP-DM for Data Science**: methods, processes and frameworks. SBC Reviews on Computer Science, 2023. Disponível em: <https://journals-sol.sbc.org.br/index.php/reviews/article/view/3757>. Acesso em: 25 nov. 2025.

## **PALAVRAS-CHAVE**

CRISP-DM; Business Understanding; Variável-alvo (Target)

EMASP



POSTECH