

AI SCIENTIST

FASE 1 | AULA 04 -

COMO TRANSFORMAR UMA DOR DE NEGÓCIO EM SOLUÇÃO DE DADOS

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
O QUE VOCÊ VIU NESTA AULA?	30
REFERÊNCIAS.....	31

EMANIP

O QUE VEM POR AÍ?

Nos capítulos anteriores, percorremos pelas bases que sustentam um projeto sólido de ciência de dados: estudamos o CRISP-DM como metodologia estruturante, entendemos como formular targets que representem fenômenos reais e aprofundamos a relação entre métricas técnicas e valor de negócio.

Todo esse percurso tem um propósito: preparar o terreno para o momento decisivo em que deixamos a teoria e entramos no território onde a ciência realmente encontra sua utilidade: **conectar uma dor de negócio concreta a uma solução de dados completa.**

HANDS ON

Demonstraremos como uma dor de negócio se transforma em um problema analítico bem formulado e, finalmente, em uma solução de dados capaz de gerar impacto real.

Você verá, passo a passo, como alinhar expectativa, escopo e estratégia, como navegar as nuances do CRISP-DM quando aplicado ao mundo real e como conectar análise, modelagem e operação em um fluxo contínuo. Esta aula é o elo final entre intenção e execução.

SAIBA MAIS

O QUE É UMA “DOR DE NEGÓCIO” E COMO RECONHECÊ-LA?

No contexto de Ciência de Dados, é comum enfatizarmos algoritmos, gráficos e ferramentas. No entanto, o verdadeiro valor de um projeto de dados está em traduzir uma dor de negócio em uma pergunta analítica e, depois, converter os resultados da análise em recomendações acionáveis para a organização.



Figura 1 – O ponto de partida
Fonte: gerado por Inteligência Artificial (2025)

Uma dor de negócio é aquilo que fere diretamente a capacidade de uma organização avançar em seus objetivos estratégicos. Trata-se de um tipo de problema que não apenas se manifesta nos indicadores, mas que gera tensão, inquietação e urgência entre os tomadores de decisões. Às vezes, surge como um KPI que despenca sem aviso; outras, como um processo que já não acompanha o ritmo da operação; em certos casos, surge como uma oportunidade de mercado evidente que a empresa simplesmente não consegue aproveitar.

Reconhecer uma dor não é um exercício puramente técnico, é um ato que requer **escuta ativa e análise de contexto**. Muitas vezes, a dor se revela primeiro na fala dos(as) gestores, mas quase nunca vem formulada da maneira adequada. O(a) gestor costuma trazer o **pedido no formato de solução, não de problema**:

- “Precisamos de um modelo de churn”;
- “Queremos um dashboard de fraude”;
- “Construam uma recomendação melhor”.

Esses enunciados comunicam a ansiedade, mas não o fenômeno que queremos estudar. Nesse momento, o papel do(a) cientista de dados é compreender o contexto por trás da solicitação, questionando, por exemplo: Por que essa demanda surgiu agora? Que impacto concreto ela está causando no negócio? Qual é a decisão que o gestor precisa tomar, mas hoje não consegue?

É preciso pedir que o(a) stakeholder narre o que está acontecendo de forma completa: onde está o incômodo, o que mudou, quais sinais reforçam a preocupação, e de que forma a solução esperada poderia transformar a tomada de decisão.

A partir dessa conversa, quase sempre descobrimos que o pedido inicial esconde uma necessidade mais profunda. O(a) gestor que pede “um modelo de churn” talvez queira, na verdade, entender quais tipos de clientes estão prestes a abandonar o serviço e quais fatores explicam essa tendência. O(a) diretor que solicita “um sistema de recomendação” talvez esteja tentando resolver o problema de baixa conversão em vendas adicionais, provocado por sugestões irrelevantes ou por perda de contexto no comportamento de navegação.

A maturidade analítica começa exatamente aqui: saber distinguir a dor verdadeira da ansiedade difusa, o problema estrutural da suposição precipitada eo sintoma visível da causa real.

DA DOR AO PROBLEMA DE DADOS: PREDITIVO, DESCRITIVO OU PRESCRITIVO?

Depois que a dor de negócio está claramente compreendida, o passo seguinte é traduzi-la em um tipo específico de problema de dados, trata-se de escolher o

enquadramento correto que permitirá compreender, prever ou intervir no fenômeno. Em Ciência de Dados, geralmente classificamos os problemas em três categorias: **descritivo, preditivo ou prescritivo**. A natureza da pergunta determina qual dessas abordagens é a mais apropriada.

PROBLEMAS DESCRITIVOS – O QUE ACONTECEU?

Os problemas descritivos são aqueles em que a organização ainda está tentando entender o que aconteceu ou o que está acontecendo. São investigações que iluminam padrões, distribuições e relações nos dados, ajudando o time de negócio a enxergar o presente com clareza e o passado com profundidade.

Uma análise descritiva robusta pode revelar, por exemplo, que o aumento de churn se concentra em um segmento muito específico de clientes, ou que certos tipos de fraude surgem de combinações recorrentes de atributos que antes passavam despercebidos. Também pode mostrar que determinados produtos têm correlações sazonais de venda que influenciam o comportamento de compra sem que isso tenha sido percebido. Quando o interesse muda de compreender o passado e o presente para antecipar o futuro, entramos no território dos problemas preditivos.

PROBLEMAS PREDITIVOS – O QUE VAI ACONTECER?

Um modelo preditivo permite estimar quais clientes têm maior risco de cancelar, quais transações são mais propensas a serem fraudulentas ou qual será a demanda de um produto no mês seguinte. Ele transforma a história registrada nos dados em probabilidades que dão ao negócio uma vantagem essencial: a capacidade de agir e tomar ações proativas antes que o evento se concretize.

A empresa deixa de reagir ao churn quando o cliente já se foi, e passa a agir antes. Deixa de sofrer a fraude quando o golpe já ocorreu, e passa a evitá-lo. Deixa de perder vendas por ruptura, e passa a ajustar estoques preventivamente. A predição é, em essência, uma forma de antecipação estratégica.

Mas há casos em que não basta compreender, nem basta prever. É preciso decidir. E é aqui que surgem os problemas prescritivos.

PROBLEMAS PRESCRITIVOS – O QUE FAZER?

São problemas que focam em recomendar ou decidir ações ótimas a partir de determinadas previsões ou objetivos. Eles se apoiam, muitas vezes, em previsões, mas vão além: incorporam otimização, simulação, lógica de negócio e restrições operacionais para indicar qual ação deve ser tomada.

É nesse nível que decidimos, por exemplo, qual oferta enviar para cada cliente de alto risco dentro de um orçamento limitado, quais produtos recomendar, levando em conta preferências, histórico, margem e objetivos de venda, ou ainda, qual preço definir em tempo real para maximizar receita sem prejudicar a competitividade. O prescritivo é onde dados e decisão finalmente se encontram.

Escolher entre esses três caminhos é uma etapa crítica, pois cada dor exige um tipo diferente de resposta. Nem todo problema requer machine learning. Em muitos casos, o(a) stakeholder está sofrendo com uma dor que só precisa ser iluminada. Por isso, antes de iniciar qualquer projeto, é fundamental alinhar as expectativas com o stakeholder e perguntar explicitamente que tipo de resposta ele busca. Ele quer entender os motivos e padrões? Quer uma lista de casos prioritários? Ou quer uma recomendação automatizada de ação? Cada uma dessas possibilidades aponta para uma abordagem diferente.

Vale destacar ainda que essas três abordagens não são mutuamente exclusivas. Ao contrário: muitos problemas reais atravessam todas elas em etapas naturais. Primeiro descrevemos o que está acontecendo, depois prevemos o que pode acontecer e, por fim, decidimos o que fazer com base nisso.

MONTANDO UMA SOLUÇÃO DE DADOS DE PONTA A PONTA

Agora que temos uma dor de negócio bem definida e sabemos qual abordagem analítica faz sentido para enfrentá-la, podemos finalmente traçar o caminho para construir a solução de dados completa. Essa jornada envolve múltiplas etapas que correspondem ao ciclo iterativo do CRISP-DM




Figura 2 – CRISP-DM
Fonte: Wikipedia (s.d)

ENTENDIMENTO DO NEGÓCIO E FORMULAÇÃO DE PERGUNTAS

Falamos bastante sobre dor de negócio, que corresponde à etapa de refinar nossa compreensão do problema. Uma técnica recomendada é a realização de uma reunião inicial com os(as) principais stakeholders, com o objetivo de fazer perguntas e coletar o máximo de contexto. É importante ouvir não apenas o que eles querem, mas também o porquê. Muitas vezes, nesse bate-papo inicial descobrimos nuances da dor que não estavam claras no pedido original.

Em seguida, parte-se para explorar o contexto do negócio: entender como o processo funciona hoje, quais dados a empresa já coleta sobre isso, quais métricas monitoram essa dor e quais fatores internos/externos podem influenciá-la. Por exemplo, se o problema for churn de clientes, devemos aprender quais fatores de satisfação ou insatisfação já são conhecidos, como é o ciclo de vida do cliente, quais ações de retenção existem, etc. Se for fraude, entender o fluxo de autorização de transações, os tipos de fraude mais comuns, e assim por diante.

A imersão profunda no domínio é essencial. Ela impede que os insights gerados pelo modelo sejam irrelevantes ou superficiais. Um(a) cientista de dados com

conhecimento do negócio consegue formular hipóteses significativamente mais pertinentes.

Com base nesse entendimento, traduzimos o problema em perguntas de negócio claras e em hipóteses. Esta etapa é essencial: antes de sair coletando dados a esmo, definimos que perguntas queremos responder e que suposições podemos testar. Por exemplo:

- “Quais características distinguem os clientes que cancelam dos que permanecem?”;
- “Se monitorarmos a frequência de uso do serviço, conseguimos antecipar quem vai abandonar?”;
- “Transações acima de certo valor têm probabilidade maior de serem fraudes?”.

Para cada pergunta, podemos antever que tipo de dado e de análise seriam necessários. Também formulamos hipóteses, suposições que, segundo a intuição de negócio, poderiam explicar o problema. Exemplo:

- “Hipótese: clientes com baixo engajamento nos primeiros 3 meses tendem a chunar”;
- “Hipótese: pedidos feitos de madrugada têm mais chance de ser fraudulentos”.

Essas hipóteses vão nos guiar na exploração dos dados posteriormente, pois buscaremos confirmá-las ou refutá-las. Um fluxo ideal antes de qualquer análise, seria:

Passo 1: reunião inicial com stakeholders para entender a dor. Passo 2: estudo do contexto (processos, métricas, restrições). Passo 3: formulação de perguntas de negócio investigáveis. Passo 4: definição de hipóteses esperadas. Passo 5: só então partir para a coleta e análise de dados.

Essa abordagem garante alinhamento e economiza tempo, pois direciona os esforços de dados apenas para o que realmente importa para o negócio.

DATA UNDERSTANDING E DATA PREPARATION

Com as perguntas de negócio em mente, entramos na fase de Data Understanding e Data Preparation. Primeiro, listamos quais dados são necessários para responder às perguntas e testar as hipóteses levantadas. Nesta etapa, vale mapear todas as fontes de dados disponíveis na organização (bancos de dados, planilhas, dados de terceiros, APIs) e avaliar quais são relevantes.

Muitas vezes, a **identificação de gaps de dados é inevitável**, por exemplo, pode ser que descubramos que certos dados importantes simplesmente não estão sendo coletados, isso gera uma decisão: “É possível obter esses dados de alguma forma (ex. começar a registrar um log, adquirir externamente) ou teremos que seguir sem eles?”

Após identificar as fontes, partimos para a coleta e integração dos dados. Esse passo envolve acessar bancos de dados internos (por exemplo, o CRM para dados de clientes, o sistema de transações para vendas, etc.), possivelmente realizar queries SQL, exportar arquivos, consumir APIs, etc. Podemos precisar combinar dados de múltiplas fontes (por exemplo, juntar a tabela de clientes com a tabela de cancelamentos e com logs de uso). Essa integração às vezes requer colaboração com a engenharia de dados ou TI, especialmente se os dados estiverem dispersos em diferentes sistemas.

Uma vez obtidos os dados brutos iniciais, é hora de examinar a qualidade e realizar a limpeza. Não é incomum encontrarmos valores faltantes (missing), inconsistências (um mesmo cliente cadastrado duas vezes com IDs diferentes), outliers estranhos, dados desatualizados, erros de registro, entre outros problemas.

Como sempre falamos em dados, “garbage in, garbage out”. Sem tratar essas questões, qualquer modelo resultante poderá ser inválido, portanto, aplicamos técnicas de limpeza: remover ou corrigir registros inválidos, padronizar formatos (datas, categorias), lidar com duplicatas, imputar valores faltantes de forma adequada (ou removê-los, dependendo do caso), entre outras.

EXPLORAÇÃO E O REFINAMENTO DAS HIPÓTESES

Com os dados em mão, é útil fazer uma **análise exploratória dos dados (EDA)** para conhecer suas características básicas: como distribuições, estatísticas resumidas, correlações simples. Isso ajuda a validar ou refinar hipóteses iniciais. Por exemplo, ao explorar os dados de churn, podemos descobrir que clientes de determinada região apresentam uma taxa de cancelamento muito maior, o que pode se tornar um insight acionável ou direcionar o modelo a incorporar essa variável.

O dado bruto raramente conta a história completa, então é também nessa fase que surge o feature engineering, a arte de criar variáveis derivadas que capturam nuances do comportamento.

A partir de logs de acesso, podemos transformar eventos dispersos em métricas como dias desde o último login, tempo médio entre sessões ou intensidade de uso. A partir de transações, podemos construir indicadores como variação do gasto nos últimos meses, concentração de compras em categorias específicas ou anomalias na frequência de compras. **Variáveis bem construídas carregam poder explicativo e podem elevar drasticamente o desempenho do modelo.**

Quando os dados finalmente estão limpos, integrados e compreendidos, preparamos o terreno para avaliação futura. Em problemas preditivos, isso significa estabelecer um plano de separação entre treino, validação e teste, preferencialmente com recortes temporais que simulem a realidade operacional do problema.

DEFINIÇÃO DO TARGET E MÉTRICAS DE SUCESSO

Um elemento central na construção de uma solução de dados é definir claramente qual será o objetivo preditivo (target) e como medimos o sucesso do projeto tanto em termos técnicos quanto de negócio. Esse tópico foi coberto em detalhe nos capítulos anteriores, mas vamos recapitulá-lo no contexto de “dor para solução”.

Quando lidamos com problemas preditivos, o target representa o evento que o modelo tentará prever, então ele precisa refletir com precisão a dor de negócio que motivou o projeto. No caso da dor de evasão de clientes, por exemplo, o target pode

ser definido como “cliente que cancelou sua assinatura nos próximos três meses”, representado como sim ou não. Essa definição aparenta ser simples, mas contém armadilhas importantes que precisam ser endereçadas, por exemplo, é necessário especificar exatamente o que caracteriza um cancelamento, como lidar com clientes que cancelam e retornam posteriormente, e quais exceções devem ser consideradas.

Um target bem definido precisa ser específico, mensurável e fiel ao fenômeno real que queremos modelar. **Quando ele é mal formulado, todo o restante da solução se distorce, pois o modelo aprenderá algo que não representa a dor original.**

MODELAGEM E CONSTRUÇÃO DA SOLUÇÃO

Chegamos à fase de modelagem, o ponto em que o esforço conceitual ganha forma e onde os dados preparados começam, de fato, a se transformar na solução que irá responder à dor de negócio. Dependendo do que buscamos resolver, essa solução pode assumir diversas naturezas: desde um modelo preditivo sofisticado até uma análise estatística, um algoritmo de recomendação ou mesmo um dashboard bem construído. A modelagem não é apenas a escolha de um algoritmo, mas a **materialização da estratégia analítica** que definimos anteriormente.

Quando tratamos de problemas preditivos, seguimos o caminho clássico do machine learning supervisionado. Partimos da seleção de algoritmos adequados ao tipo de pergunta e às características dos dados. Já em problemas descritivos, a “modelagem” assume outra forma: o objetivo não é prever, mas revelar estruturas ocultas. Técnicas como clusterização, análise de cestas ou métodos estatísticos exploratórios nos ajudam a segmentar clientes, identificar afinidades entre produtos ou compreender padrões que não são imediatamente visíveis.

E por onde começar? Aqui trago uma frase do Tim Peters, “Simple is better than complex” (“Simplicidade é melhor que complexidade”), renomado engenheiro de software e proeminente contribuidor da linguagem de programação Python. Ele é mais famoso por ser o autor de “The Zen of Python” e, na comunidade Python, era visto quase como uma figura mítica, conhecida por sua habilidade e vastas contribuições.



Figura 3 – Tim Peters at Pycon
Fonte: Openbookproject (2004)

Começamos testando modelos simples e interpretáveis, como regressão logística ou árvores de decisão, evoluindo conforme necessário para random forests, gradient boosting ou até redes neurais, dependendo da complexidade do fenômeno e do volume de dados disponíveis.

A tentação de iniciar pelo modelo mais complexo é comum, mas um baseline interpretável, costuma ser uma das ferramentas mais valiosas pois nos dá um ponto de comparação e ajuda a identificar sinais com explicabilidade imediata, sendo extremamente útil para que o stakeholder compreenda desde cedo quais fatores parecem influenciar o fenômeno.

Depois de iterar e testar os algoritmos, podemos recorrer à validação cruzada para evitar vieses, avaliando o quão bem o nosso modelo generaliza para nossos casos. Ajustamos hiperparâmetros por meio de busca em *grid* ou de métodos bayesianos.

Estes últimos se baseiam no Teorema de Bayes, calculando a probabilidade de um evento ocorrer dado um conjunto de evidências e permitindo que o modelo aprenda a atualizar as probabilidades conforme novas informações chegam. No

entanto, a escolha do método é sempre guiada pela métrica que representa o sucesso do negócio, e não pela métrica tecnicamente mais “bonita”.

Outro aspecto fundamental nesta fase é pensar, desde a modelagem, em como a solução será implementada. Um modelo preditivo pode ser tecnicamente excelente, mas completamente inviável operacionalmente se não considerarmos sua integração futura. Perguntas essenciais surgem: essa solução vai rodar em tempo real, dentro de um sistema existente, tomando decisões em milissegundos? Ou será utilizada de maneira offline, alimentando relatórios periódicos? Um algoritmo de recomendação será integrado ao site, ao aplicativo móvel, a ambos? Qual infraestrutura será necessária para suportar seu uso contínuo?

Essas reflexões moldam escolhas técnicas importantes, desde a complexidade do modelo até os requisitos de latência, peso computacional, ambiente de execução e formato da API.

AValiação DOS RESULTADOS

Com um ou mais modelos construídos, entramos na fase de avaliação. Aqui, analisamos criticamente para os resultados obtidos e verificamos se eles realmente resolvem a dor de negócio conforme os critérios definidos.

A avaliação ocorre em vários níveis:

Avaliação técnica do modelo: O primeiro olhar naturalmente recai sobre a performance técnica do modelo. Usamos dados de teste, nunca vistos durante o treino, para verificar se ele generaliza bem e se suas métricas fazem sentido para o problema em questão. Avaliar uma solução preditiva exige ir além dos números resumidos: é fundamental entender o comportamento do modelo em diferentes regiões do espaço de dados, inspecionar erros e identificar padrões de falha. Se os resultados técnicos forem ruins, possivelmente teremos que voltar à modelagem ou até à etapa de dados para melhorias.

Validação com stakeholders (revisão de negócio): Um modelo só tem valor se fizer sentido para quem vai utilizá-lo. É nessa etapa que traduzimos resultados em narrativas compreensíveis, mostramos os fatores que influenciam as previsões, explicamos por que determinados grupos se comportam de forma diferente e

ilustramos, de maneira visual, como o modelo separa bons e maus casos, ou como clusters e padrões emergem nos dados.

A pergunta central aqui é simples e direta: “Com este resultado em mãos, que decisão tomamos?”. Se a resposta não é clara, não é porque o modelo é ruim, mas porque ainda falta interpretação, tradução ou refinamento. A ciência só cumpre seu papel quando se torna ação.

Teste em pequena escala/PoC: Antes de avançar para a produção, é recomendável um teste em pequena escala que funcione como um experimento no mundo real. O objetivo é medir o impacto concreto do modelo fora do ambiente histórico.

Em churn, por exemplo, podemos usar as previsões para direcionar uma campanha de retenção para um grupo restrito de clientes e comparar os resultados com um grupo de controle. Em recomendação, podemos expor uma porcentagem de usuários ao novo algoritmo e medir engajamento e conversão contra o sistema anterior. Em fraude, podemos rodar o modelo em paralelo com o sistema tradicional e observar divergências.

Esses testes são reveladores: às vezes um modelo que apresenta ótimo desempenho nos dados históricos não gera impacto prático e isso pode indicar problemas na execução da ação, diferenças entre passado e presente ou variáveis externas que não estavam contempladas. A cultura de prova de conceito iterativa é uma das maiores proteções contra investimentos equivocados: ela aproxima áreas, coleta feedback real e expõe rapidamente os pontos que precisam ser revisados antes de escalar.

A avaliação também inclui uma revisão do próprio processo. Como recomenda o CRISP-DM, examinamos novamente todas as etapas: os dados continuam confiáveis? As premissas de negócio ainda são válidas? O escopo se manteve estável ou mudou conforme aprendemos mais? Há novas fontes de dados que possam enriquecer a solução?

Muitas vezes, ao chegar neste ponto, percebemos que a definição inicial do problema poderia ser aprimorada, ou que os objetivos precisariam ser ajustados com base nas descobertas.

IMPLEMENTAÇÃO E ENTREGA DE VALOR (AÇÃO DE NEGÓCIO)

A última etapa do ciclo é garantir que a solução de dados gere valor concreto, integrando-se às operações do negócio. No CRISP-DM, esta é a fase de Deployment e pode ser tão simples quanto um relatório final ou tão complexa quanto um sistema de machine learning automatizado, rodando continuamente em produção. **Independentemente da forma, o objetivo é que aquele conhecimento extraído dos dados se traduza em ação de negócio efetiva.**

É fundamental destacar a importância de definir papéis, estabelecendo claramente as responsabilidades ao integrar as soluções nas operações de negócio, monitorar com métricas, assegurando o acompanhamento contínuo por meio de indicadores, e manter a governança, garantindo-a através do registro e documentação completa de todo o processo.

O modelo ou análise não pode ficar como uma “caixa-preta” entendida apenas pelo cientista de dados que o construiu. Deve-se documentar as premissas, variáveis usadas, acurácia esperada, limitações conhecidas, e claro, passos de manutenção (por exemplo: “modelo deve ser retreinado a cada 3 meses com novos dados” ou “atualizar tabela de clientes semanalmente”).

CASES: DA DOR À SOLUÇÃO

Caso 1: churn em serviços (Telecom)

Dor do negócio: uma empresa de telecomunicações enfrenta um alto índice de cancelamento de contratos (churn). A cada mês, muitos clientes estão deixando o serviço, afetando a receita recorrente. **A dor é explícita: “Precisamos reduzir a evasão de clientes”.** A meta estratégica definida pela diretoria é clara: **reduzir os cancelamentos em 15% nos próximos seis meses.** Essa meta conecta diretamente o projeto de dados ao que importa para a empresa: **retenção de clientes e aumento de receita.**

Tradução para problema de dados: trata-se de um **problema preditivo de classificação** - identificar quais clientes têm maior propensão a cancelar em um futuro

próximo (digamos, nos próximos 1-3 meses), para que a empresa possa agir antes que eles se desliguem.

Além disso, **há um elemento descritivo** - entender por que os clientes cancelam, ou quais fatores estão associados ao churn, o que orienta melhorias de produto/serviço. Poderia até evoluir para prescritivo, recomendando ações específicas para cada perfil de cliente.

Pipeline de solução

Dados necessários: histórico de clientes que cancelaram e que permaneceram, com atributos como tempo de uso, plano contratado, volume de uso (minutos, dados, etc.), quantidade de reclamações feitas, atrasos em pagamento, região, idade do cliente, se possíveis indicadores de satisfação (ligações ao call center, pesquisas respondidas).

Integram-se dados de múltiplas fontes internas – CRM, billing, suporte, etc. Após coleta, muita atenção à qualidade ao explorar os dados: identificar se há clientes com informação faltante, normalizar campos para representar categorias de planos de forma consistente, remover registros inativos.

Target: variável binária indicando se o cliente cancelou o serviço num determinado período após a data de referência. Precisamos definir essa janela de previsão, por exemplo, “cancelou nos próximos 60 dias após a última interação registrada”. A definição precisa ser consistente, se for 10 muito curta, talvez não dê tempo de intervir, se muito longa, o modelo pode perder acurácia. No projeto, houve bastante discussão com o time de negócios para escolher essa janela ideal.

Modelagem: iniciou-se com um modelo de árvore de decisão para obter interpretabilidade e identificar os fatores mais influentes. Esse modelo inicial mostrou, por exemplo, que clientes com uso baixo de dados e atendimentos recentes no suporte técnico eram de alto risco, possivelmente indicando insatisfação com a qualidade do serviço. Em seguida, treinou-se um modelo de gradient boosting (XGBoost) para melhorar a performance preditiva. Validando com dados históricos, o modelo conseguia capturar ~80% dos cancelamentos futuros nos 20% de clientes de maior score (um precision/recall equilibrado para as necessidades da empresa).

Avaliação: tecnicamente, o modelo apresentou uma AUC em torno de 0.85, o que foi considerado um bom resultado. Em termos de negócio, simulou-se que, se a empresa abordasse os top 10% clientes de maior risco com ofertas de retenção, poderia reduzir o churn em cerca de 20% (estimativa baseada em suposições de taxa de sucesso das ofertas). Apresentou-se os resultados ao time de marketing e atendimento, explicando as principais variáveis. Houve validação: muitas batem com a intuição (ex: reclamações frequentes realmente indicam chance de saída), mas outras trouxeram novidade (ex: determinado segmento jovem com baixo uso de voz estava cancelando para migrar a concorrentes com planos de streaming – insight acionável para ajustar planos).

Ação de negócio: O modelo foi então implantado. A cada início de mês, ele pontuava todos os clientes ativos quanto ao risco de churn. A equipe de CRM recebia uma lista dos, digamos, 500 clientes mais propensos a sair e então disparava ações de retenção: ligações personalizadas, cupons de desconto, upgrade temporário de pacote, etc.

Esse processo foi monitorado ao longo de seis meses. Ao final, mediu-se que a taxa de churn mensal caiu daquele patamar inicial (por exemplo, 5% ao mês) para em torno de 4.2% ao mês – uma redução acumulada próxima da meta de 15%. Traduzido em números absolutos, isso significou centenas de clientes retidos e uma receita preservada significativa.

O projeto então foi considerado um sucesso e se tornou parte do **processo contínuo**: o modelo de churn permanece sendo usado regularmente, com revisão trimestral. Além disso, os insights gerados levaram a melhorias gerais, como reforço na qualidade do atendimento técnico e criação de novos planos de dados voltados ao segmento jovem, endereçando as causas raízes identificadas.

Este caso demonstra como, ao **definir claramente o problema** (reduzir churn em X%) **e alinhá-lo à estratégia**, a tecnologia entra como resposta e não como ponto de partida. O modelo preditivo de churn foi útil porque veio acompanhado de um plano de ação concreto (campanha de retenção) e métricas de negócio para acompanhar (redução do churn mensal) dessa forma fechando o ciclo da dor à geração de valor.

CASE 2: FRAUDE BANCÁRIA (PAGAMENTOS)

Dor do negócio: um banco ou empresa de cartões de crédito sofre perdas financeiras devido a transações fraudulentas. **A dor está em mitigar essas fraudes sem prejudicar a experiência dos clientes legítimos.** Ou seja, reduzir o volume de fraudes (idealmente pegar o máximo possível delas) mantendo baixo o número de transações legítimas indevidamente bloqueadas e a fricção para clientes.

A meta pode ser algo como **“reduzir as perdas por fraude em 30% no próximo ano, mantendo o índice de falsas rejeições abaixo de 2%”**.

Tradução para problema de dados: é um problema preditivo de classificação binária (fraude vs não fraude) em ambiente de anomalias raras. Cada transação pode ser analisada com base em seus atributos e histórico do cliente, para predizer se é potencialmente fraudulenta.

Há também um aspecto prescritivo: se detectada como fraude, a ação é bloquear ou submeter a revisão manual. Assim, **o algoritmo integra-se a uma decisão operacional.**

Pipeline de solução

Dados necessários: histórico de transações com indicação de quais foram posteriormente confirmadas como fraude (chargebacks, reclamações do cliente, detecção interna) e quais não. Os atributos podem incluir: valor da transação, hora do dia, geolocalização (país, cidade), tipo de estabelecimento, canal (cartão presente ou online), número de tentativas seguidas, histórico do cartão/conta (número de transações do cliente naquele dia, média mensal, etc.), e possivelmente dados agregados (por exemplo, se o dispositivo ou IP já esteve associado a fraude anteriormente).

Fontes: base de transações do banco e base de ocorrências de fraude. Precisamos juntar essas bases e rotular corretamente as transações. Um ponto de atenção é que a fraude confirmada muitas vezes é identificada dias depois, então para treinar o modelo, é necessário garantir a associação de cada transação ao rótulo fraude/não fraude conhecido posteriormente.

Preparação dos Dados: Devido à natureza massiva dos dados (podendo haver milhões de transações), a preparação dos dados envolveu técnicas de amostragem e balanceamento. Foi feita uma subamostra de dados não fraudulentos, mantendo todos os fraudulentos, para treinar o modelo sem viés extremo. Também se criou features derivadas importantes: por exemplo, diferença de tempo desde a última transação daquele cartão, valor médio das últimas compras do cliente, se o país da compra é diferente do país de residência do cliente, entre outras. Essas features comportamentais ajudam o modelo a capturar padrões suspeitos.

Adicionalmente, integrou-se uma lista de cartões previamente comprometidos (blacklist) e padrões conhecidos (como sequências rápidas de várias compras rejeitadas, etc.) que servem quase como regras manuais auxiliares.

Modelagem: foram testados modelos de classificação como árvores (por exemplo, Random Forest) e algoritmos de boosting, além de técnicas de detecção de anomalia não supervisionadas (como Autoencoders e isolation forest). No fim, um modelo de Gradient Boosting (LightGBM) apresentou melhor equilíbrio entre detecção de fraude e poucas falsas alarmes. Ele alcançava, nos dados de teste, algo como 92% de recall (detecção de fraudes) com 5% de falsos positivos (transações boas sinalizadas como suspeitas). Essa taxa foi considerada boa, pois reduziria significativamente as perdas mantendo a maioria dos clientes legítimos sem impacto relevante.

Avaliou-se também a capacidade do modelo em pontuar risco em vez de decisão binária; isso permite calibrar o limiar de corte conforme as políticas de negócio. Por exemplo, transações com score acima de 0.9 podem ser bloqueadas automaticamente, entre 0.7 e 0.9 podem exigir verificação adicional (3DSecure ou contato com cliente), e abaixo disso são aprovadas diretamente. Essa gradação é parte da estratégia para equilibrar segurança e conveniência.

Avaliação: O modelo foi validado com dados históricos e também em um simulador online antes da ativação real. Apresentou-se aos gestores de risco exemplos de transações que o modelo marcaria como fraude para ver se condiziam com expertise humana. Houve boa concordância o modelo, por exemplo, identificou automaticamente padrões como compra de alto valor em país diferente logo após

várias compras pequenas locais (típico de cartão clonado testando limites), o que os analistas já sabiam ser suspeito. Esse alinhamento gerou confiança.

Além disso, projetou-se o impacto financeiro: estimou-se que, se o modelo estivesse em operação no último ano, teria prevenido milhões em fraudes, ao custo de bloquear Y transações legítimas (potencialmente irritando alguns clientes). Esse trade-off foi considerado vantajoso, especialmente porque muitas transações legítimas bloqueadas poderiam ser recuperadas via contato rápido (por exemplo, SMS para confirmação da compra, prática comum no mercado).

Ação de negócio: o modelo foi implementado no fluxo de pagamentos do banco. Quando um cliente faz uma compra com cartão, as informações são enviadas ao modelo (hospedado como um microsserviço). Se o modelo responde “alto risco”, a plataforma automaticamente aplica as regras definidas: algumas transações são declinadas diretamente por segurança, enquanto outras são encaminhadas para um segundo fator de autenticação (ex: a tela do e-commerce pede uma confirmação via app ou SMS, isso é o protocolo 3D Secure, que melhora a segurança). Em paralelo, casos sinalizados alimentam uma fila para o time de prevenção à fraude revisar diariamente, ajudando a refinar o modelo e até investigando quadrilhas.

Importante mencionar que houve forte integração com MLOps: os logs de cada decisão do modelo são armazenados para acompanhamento, e está estabelecido um ciclo de re-treino mensal incorporando as fraudes novas (pois fraudadores criam novas táticas e o modelo precisa aprender). Os resultados após a implantação mostraram uma redução significativa das fraudes absorvidas pelo banco.

Em números hipotéticos: a taxa de fraude (fraude/volume) caiu de 0,3% para 0,1%, economizando milhões. Houve um leve aumento inicial nas reclamações de “compra bloqueada indevidamente”, mas com ajustes finos (ex.: elevando ligeiramente o limiar para certos segmentos), esse efeito foi minimizado para dentro da meta de 2% de falsos positivos. O balanço segurança vs. experiência do cliente foi continuamente monitorado como parte das operações regulares do negócio.

Este caso evidencia a importância de governança e monitoramento contínuos: sem políticas claras de acompanhamento, responsáveis pela manutenção do modelo

e métricas de sucesso definidas, até soluções tecnicamente sólidas podem falhar ou ficar obsoletas com o tempo. No banco, foi criada uma rotina de governança onde a área de risco, TI e data science se reúnem mensalmente para revisar as métricas do modelo, garantindo que ele continue saudável e ajustado aos objetivos do negócio.

CASO 3: SISTEMA DE RECOMENDAÇÃO EM VAREJO (E-COMMERCE)

Dor do negócio: uma grande varejista online deseja aumentar o engajamento e as vendas em seu e-commerce. Os diretores percebem que os clientes estão navegando, mas muitas vezes não encontram itens de seu interesse ou simplesmente compram um produto e saem, sem adicionar itens extras ao carrinho.

A dor de negócio pode ser resumida como **“baixa efetividade das recomendações de produtos”**, levando a menor faturamento por cliente do que o potencial.

O objetivo estratégico definido: melhorar a taxa de conversão de recomendações e o ticket médio por cliente em, digamos, 10%.

Tradução para problema de dados: aqui temos um problema de filtragem de informações que se traduz num sistema de recomendação – essencialmente preditivo (tentar prever que produtos o usuário teria interesse), mas também prescritivo no sentido de sugerir diretamente itens. É um caso típico de machine learning não supervisionado/supervisionado em larga escala, onde queremos recomendar itens relevantes para cada usuário com base em padrões de comportamento de muitos usuários.

Pipeline de solução

Dados necessários: o coração de um recomendador são os dados de interações usuário-produto. Isso inclui: histórico de compras de cada usuário, histórico de visualizações/clicks em produtos, itens adicionados ao carrinho, avaliações dadas (estrelas, reviews), e possivelmente dados demográficos ou de preferências explícitas do usuário (categorias favoritas, etc.). Além disso, informações dos produtos (categorias, preço, marca, descrição) podem ser úteis para métodos de recomendação que usam conteúdo.

No caso, o e-commerce já possuía logs de navegação e banco de pedidos, mas precisou-se consolidar e tratar esses dados. Qualidade e consistência aqui são cruciais: se os dados de comportamento de compra não estiverem bem estruturados ou atualizados, qualquer modelo terá dificuldade de gerar sugestões relevantes. Foi necessário mapear todas as fontes (web analytics, base transacional, etc.) e criar um pipeline de dados que unifica essas interações diariamente.

Preparação dos dados: um desafio comum foi o volume de dados, milhões de interações. Foi decidido filtrar para os últimos 2 anos e focar nos usuários e produtos mais ativos para a modelagem inicial (para não treinar em dados muito antigos ou extremamente esparsos). Também se tratou outliers, como usuários testes, e produtos descontinuados foram marcados para não recomendar. Foi criada uma tabela de relacionamento (uma "matriz") entre os usuários e os itens/produtos. Nessa tabela, cada célula mostra se um usuário interagiu com um produto (comprou ou visualizou) e quantas vezes isso ocorreu.

Além disso, os produtos foram "traduzidos" em códigos numéricos ("embeddings") que representam suas características. Isso foi feito analisando as descrições textuais dos produtos (usando técnicas de Processamento de Linguagem Natural, ou PLN) para extrair e codificar seus atributos principais. A preparação incluiu dividir um conjunto de validação: esconder algumas compras de cada usuário para testar se o sistema conseguiria recomendá-las, técnica típica de avaliar recomendadores.

Modelagem: Testaram-se duas abordagens:

A primeira foi filtragem colaborativa baseada em fatoração de matriz, utilizando, por exemplo, um algoritmo ALS – Alternating Least Squares – para fatorar a matriz usuário-item e obter “fatores latentes” representando preferências. Já a segunda foi modelo neural do tipo Deep Learning, com uma rede do tipo autoencoder ou um modelo sequencial que prevê próximo item baseado em sequência de cliques.

A filtragem colaborativa tradicional se saiu bem em capturar gostos parecidos de usuários (por exemplo, quem comprou A e B tende a gostar de C) sem precisar de muitos atributos. Já o modelo neural prometeu aproveitar sequências (padrões de navegação, ex: quem olha vários itens de categoria Eletrônicos acaba comprando X).

Após iterações, combinou-se as técnicas: um híbrido, onde o modelo de fatoração de matriz gera uma lista inicial de recomendados para cada usuário e o modelo neural reordena refinando (aprendendo a priorizar itens que o usuário de fato clicaria). Essa combinação melhorou a métrica de ranking (Hit Rate / Precision@K) em testes offline. Em números fictícios, a precisão@10 (percentual de vezes que pelo menos 1 item relevante está entre 10 recomendados) subiu de 0.25 (baseline com recomendações simples, tipo “mais vendidos gerais”) para 0.45 com o novo sistema.

Avaliação: Offline, esses números e métricas de ranking indicavam que o sistema conseguia sugerir itens significativamente mais alinhados ao usuário. Entretanto, a verdadeira avaliação seria online, via teste A/B. Antes de lançar, foi feito um beta test interno: funcionários usaram o site com o novo recomendador ativo e deram feedback qualitativo – as recomendações pareciam fazer sentido e não havia casos bizarros (como recomendar item esgotado ou repetido).

Também se testou o desempenho: latência para gerar recomendações mantida baixa (alguns modelos pesados demoravam segundos para gerar resultado, então optou-se por pré-computar recomendações para usuários frequentes diariamente, e usar o modelo rápido para novos usuários em tempo real). Com isso, partiu-se para um experimento controlado: 5% dos visitantes do site veem as recomendações geradas pelo novo modelo, enquanto o restante vê o sistema antigo de recomendação (que era mais simples, baseado apenas nos mais vendidos da categoria, por exemplo). **Esse teste A/B rodou por algumas semanas coletando métricas.**

Ação de negócio: os resultados do teste A/B mostraram um aumento na taxa de cliques em itens recomendados de ~30% para o grupo novo vs controle, e um aumento no ticket médio por sessão de ~8%, bem próximo da meta de 10% desejada. **Com essa evidência, a diretoria aprovou o lançamento para todos os usuários.** O sistema de recomendação personalizado tornou-se parte integral do e-commerce: cada página de produto passou a exibir “recomendados para você” com base no perfil e comportamento do usuário, e e emails marketing passaram a incluir itens sugeridos de acordo com compras anteriores.

No entanto, **implantar um recomendador é um compromisso contínuo.** Foi necessário estabelecer **monitoramento do sistema:** acompanhando se a taxa de

conversão das recomendações se mantém ou decai ao longo do tempo (o que pode indicar que o modelo precisa de atualização ou que as preferências mudaram). Também implementar governança de catálogo: se um produto entra em falta, o sistema deve parar de recomendá-lo rapidamente; se novos produtos são lançados, eles precisam ser incorporados às sugestões mesmo sem histórico (frio de início – aqui técnicas como conteúdo baseado em descrição ajudaram a recomendar novos itens similares a outros populares).

Um desafio aprendido foi que a qualidade dos dados precisa ser mantida: fluxos de ETL foram implementados para garantir que, por exemplo, compras offline em lojas físicas também fossem incorporadas (pois descobriram que clientes omnichannel tinham preferências que não apareciam só no online). Assim, a empresa investiu em um pipeline de MLOps para o recomendador, atualizando dados diariamente, re-treinando os modelos principais semanalmente e avaliando continuamente a performance.

Como resultado, o varejista viu um incremento de receita atribuível diretamente às recomendações e uma maior satisfação dos usuários que reportaram achar o site “mais personalizado”.

Este caso evidencia como uma dor relativamente ampla (“**melhorar recomendações**”) pode ser resolvida decompondo em perguntas de dados (**quem compra o quê, que itens tendem a ser comprados juntos ou por perfis semelhantes**) e construindo uma solução técnica robusta, acompanhada de experimentação e manutenção para garantir valor no longo prazo.

BOAS PRÁTICAS GERAIS DO PROJETO

Com base nos princípios e exemplos discutidos, podemos extrair algumas boas práticas gerais ao conduzir projetos de dados voltados a solucionar dores de negócio:

Focar no problema, não na tecnologia: pode parecer óbvio, mas é fácil se desviar. Sempre se pergunte: “**Qual dor específica estamos resolvendo? Como essa solução se conecta à estratégia da empresa?**”. Formalize isso por escrito no início do projeto e evite cair na tentação de explorar dados ou técnicas sem saber

claramente **que decisão ou ação aquilo vai suportar**. Aqui vale o reforço, **IA deve ser usada como meio, e não fim**.

Definir escopo e metas realistas: as dores de negócio às vezes podem ser muito amplas. É importante **quebrar em etapas e definir um escopo** manejável inicialmente. Foque em um **MVP** de dados, aquela solução inicial que já entrega algum valor, ainda que limitado, mas que possa ser implementada rapidamente para aprendizado. **Prometa menos e entregue mais – melhor superar uma meta modesta do que falhar uma muito ambiciosa**.

Itere com ciclos curtos e feedback constante: adote uma abordagem iterativa. Em vez de passar 6 meses desenvolvendo isoladamente para só então mostrar algo, tente entregar valor incremental periodicamente. Por exemplo, construa um pequeno painel com análises descritivas enquanto prepara o modelo preditivo – isso já engaja o negócio e pode até refinar requisitos. Cada iteração deve incluir feedback do time de negócio: reserve reuniões ou demonstrações para apresentar o que foi feito e ouvir opiniões. Envolve-os na validação intermediária (“esses insights fazem sentido?”). Projetos de dados bem-sucedidos costumam seguir quase um estilo ágil, com sprints, validações frequentes e capacidade de pivotar se algo não está funcionando. Essa abordagem inclusive é reforçada no conceito de PoC: uma Prova de Conceito bem estruturada tem propósito claro, métricas de sucesso definidas desde o início e formato iterativo – ajustando hipóteses e coletando feedback das áreas envolvidas continuamente. **Com iterações curtas, erros são descobertos mais cedo e podem ser corrigidos sem grandes prejuízos**.

Envolve o time de negócio ativamente: uma solução de dados não deve ser construída em uma “bolha técnica”. Desde o início, envolva pessoas do negócio na definição do problema, nas hipóteses, na discussão de resultados parciais. Se possível, inclua alguém do departamento relevante dentro da equipe de projeto ou faça workshops periódicos. **Isso garante duas coisas:** primeiro, o **conhecimento de domínio deles enriquece o modelo** (por exemplo, eles podem explicar outliers ou sugerir variáveis que você não imaginou). **Segundo, gera buy-in – quando o time de negócio se sente parte da construção, eles confiam e adotam mais a solução.** Evita aquele cenário de “TI fez esse modelo, mas ninguém usa porque não confiam”.

Validação constante com o negócio também ajuda no escopo: eles ajudam a dizer o que é prioritário e o que seria “nice to have”. E uma vez chegando na implementação, o time já estará treinado e ansioso para usar, porque acompanhou o nascimento da solução.

Monte equipes multidisciplinares: projetos de IA e dados efetivos raramente são trabalho de uma pessoa só. Envolve diferentes perfis: cientistas de dados para a modelagem, engenheiros de dados ou BI para acesso e preparação de dados, especialistas do domínio (marketing, finanças, etc.), pessoal de TI/devops para integrar a solução no sistema, e product owners ou gerentes de projeto para orquestrar conforme necessário.

Essa combinação garante que todos os ângulos sejam cobertos, técnico, de negócio e de implementação operacional. No exemplo do varejo, o time incluiu desenvolvedores frontend para embutir as recomendações no site; no caso do banco, incluiu o pessoal de segurança da informação para aprovar o modelo no pipeline transacional. Sem essa colaboração, é comum o projeto emperrar em alguma ponta (ex.: modelo pronto, mas TI não consegue colocar em produção; ou solução no ar, mas área de negócio não consegue usar).

Equipes multidisciplinares desde o início previnem essas lacunas e favorecem a adoção mais fluida do resultado.

Planeje a entrega e adoção desde cedo: já abordamos isso, mas reforçando: desde o começo, tenha em mente como o resultado será usado pelo negócio. Isso influencia decisões de design. Se for um relatório, pense no formato e visualização; se for um modelo, planeje APIs ou integração; se for um aplicativo interno, considere a UX. Inclua treinamento e documentação na entrega. Crie materiais simples explicando “Como interpretar o dashboard” ou “Como agir nos clientes sinalizados pelo modelo”. Faça um piloto controlado para permitir que o usuário final se acostume e dê feedback. Celebrar os quick wins iniciais ajuda a engajar – por exemplo, divulgar dentro da empresa o caso de um cliente que foi salvo pelo modelo de churn logo nas primeiras semanas. **Isso reforça a cultura orientada a dados e encoraja uso.**

Documente e compartilhe conhecimento: uma solução robusta, sobrevive e se adapta ao tempo. Vimos que transformar uma dor de negócio em solução é um processo multifacetado, que exige tanto habilidade técnica como entendimento

profundo do contexto empresarial, comunicação e gestão de mudança, tenha sempre um plano de governança e manutenção. Sem essa disciplina, até soluções brilhantes ficam obsoletas em pouco tempo.




Figura 4 – Old, not obsolete.
Fonte: gerado por Inteligência Artificial 2025)

Como reflexão final, vale lembrar uma lição fundamental que permeou todo o conteúdo: **A inteligência está no processo, não no modelo.** O papel do(a) cientista de dados moderno não é apenas treinar modelos sofisticados, mas sim ser um tradutor entre o mundo técnico e o mundo estratégico, garantindo que cada linha de código, cada gráfico ou modelo sirva para tomar melhores decisões e impulsionar a empresa na direção de suas metas. Quando o problema é bem definido e a solução bem implementada, a análise de dados deixa de ser um desafio técnico e passa a ser “apenas uma consequência lógica” para alcançar os objetivos.

O QUE VOCÊ VIU NESTA AULA?

Chegamos ao fim da nossa disciplina, você agora percorreu o ciclo completo de um projeto de Ciência de dados orientado ao negócio, desde a identificação do problema certo a ser resolvido, passando pela construção analítica até a efetiva resolução ou mitigação da dor através de ações informadas por dados.

Para aprofundar nestes temas, além da vivência prática no negócio, incentivo mais uma vez consultarem as referências. São materiais que com certeza vão servir de apoio na sua jornada como AI Scientist.

REFERÊNCIAS

CHAPMAN, P. et al. **CRISP-DM 1.0: step-by-step data mining guide**. [S.l.]: [s.n.], 2000.

GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**. 3. ed. Sebastopol: O'Reilly Media, 2022.

PROVOST, F.; FAWCETT, T. **Data Science for Business: what you need to know about data mining and data-analytic thinking**. Sebastopol: O'Reilly Media, 2013.

SHIMAOKA, A. M.; FERREIRA, R. C.; GOLDMAN, A. **The evolution of CRISP-DM for Data Science: methods, processes and frameworks**. SBC Reviews on Computer Science, 2023. Disponível em: <https://journals-sol.sbc.org.br/index.php/reviews/article/view/3757>. Acesso em: 25 nov. 2025.

PALAVRAS-CHAVE

Palavras-chave: Churn/Default; Feature Engineering; MLOps; Governança.

EMENDAS

The background is a dark, abstract digital space. It features a complex, symmetrical pattern of glowing blue lines and shapes that resemble a circuit board or a data network. The lines are arranged in a way that creates a sense of depth and perspective, drawing the viewer's eye towards the center. The overall color palette is dominated by dark blues and blacks, with the glowing blue elements providing a strong contrast.

POSTECH